

Universidad de Alcalá

Escuela Politécnica Superior

Máster Universitario en Ingeniería de Telecomunicación

Trabajo Fin de Máster

**Detección y predicción de errores
en smart grids mediante modelos
de inteligencia artificial**

**ESCUELA POLITÉCNICA
SUPERIOR**

Autor: Paula Bartolomé Mora

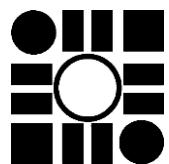
Tutor: Elisa Rojas Sánchez

Cotutor: David Carrascal Acebron

2024



Máster Universitario en Ingeniería de Telecomunicación



Universidad
de Alcalá

Madrid, 1 de julio de 2024

UNIVERSIDAD DE ALCALÁ

ESCUELA POLITÉCNICA SUPERIOR

Máster Universitario en Ingeniería de Telecomunicación

Trabajo Fin de Máster

**Detección y predicción de errores en smart grids mediante
modelos de inteligencia artificial**

Autor: Paula Bartolomé Mora

Tutor: Elisa Rojas Sánchez

Cotutor: David Carrascal Acebron

Tribunal:

Presidente:

Vocal 1º:

Vocal 2º:

AQUI DEDICATORIA

Agradecimientos

AQUI AGRADECIMIENTOS

Resumen

AQUI RESUMEN

Palabras clave:

Abstract

In this Master's Thesis (TFM) we present... AQUI ABSTRACT

Keywords:

AQUI CITA CELEBRE

AQUI AUTOR

Índice general

Resumen	v
Abstract	vii
1. Introducción	1
1.1. Presentación	1
1.2. Objetivos	2
1.3. Estructura del TFM	4
2. Estado del arte	7
2.1. Smart Grids	7
2.1.1. Flujo energético y comunicación bidireccional	9
2.1.2. Prosumidores y microgrids	10
2.1.2.1. Mercado energético	11
2.1.3. Estructura de una Smart Grid	14
2.1.3.1. Generación	14
2.1.3.2. Distribución	18
2.1.3.3. Consumo	22
2.1.4. Seguridad en Smart grids	22
2.1.5. Desafíos futuros de las smart grids	24
2.1.5.1. Retos técnicos	24
2.1.5.2. Retos económicos	24
2.2. IoT	24
2.2.1. IoE	25
2.3. DEN2NE	26
2.4. Big Data	26
2.4.1. Computación en nube	27
2.5. Inteligencia Artificial	29
2.5.1. Machine Learning (ML)	30
2.5.1.1. Random Forest (RF)	32
2.5.1.2. Support Vector Machines (SVM)	33

2.5.2. Deep Learning (DL)	37
2.5.2.1. Red Neuronal Artificial (ANN)	38
2.6. Herramientas software	38
2.6.1. BRITE	38
2.6.1.1. Definición de topologías	39
2.6.1.2. Modelos de topologías	40
2.6.1.3. Automatización de la ejecución	41
2.6.1.4. Graficación de topologías	42
3. Diseño y análisis de datos	43
3.1. Análisis de los datasets disponibles	43
3.1.1. <i>SustDataED</i>	47
3.1.2. Estructura del dataset <i>SustDataED</i>	47
3.1.2.1. Medidas de consumo de energía	49
3.1.2.2. Medidas de eventos de potencia	50
3.1.2.3. Medidas demográficas	51
3.1.2.4. Medidas de producción de energía	51
3.1.2.5. Medidas de eventos de usuario	52
3.1.2.6. Medidas de condiciones ambientales y climáticas	53
3.1.3. Conclusiones del análisis del dataset <i>SustDataED</i>	53
3.2. Simulación de datos de producción	54
3.2.1. Estudio y análisis de la ubicación (<i>Global Solar Atlas</i>)	55
3.2.1.1. Identificación de capas de datos	56
3.2.1.2. Análisis de resultados de radiación	58
3.2.1.3. Configuración y cuantificación del potencial energético de la ubicación	60
3.2.1.4. Análisis de resultados de potencia	60
3.2.2. Creación del dataset de producción (<i>PVWatts</i>)	63
3.2.2.1. Configuración de los parámetros de entrada	63
3.2.2.2. Configuración de las pérdidas del sistema real	65
3.2.2.3. Análisis de resultados de la simulación	67
3.3. Procesado de los datos	71
3.3.1. Procesado de datos de consumo	71
3.3.1.1. Análisis de la situación inicial y primeros pasos	71
3.3.1.2. Síntesis de la información	75
3.3.1.3. Automatización del proceso de síntesis de la información . .	76
3.3.1.4. Selección del despliegue	81
3.3.1.5. Selección del rango temporal y procesamiento adicional .	81

3.3.2. Procesado de datos de producción	84
3.3.2.1. Preprocesamiento de datos de <i>SustDataED</i>	84
3.3.2.2. Preprocesamiento de datos de <i>PVWatts</i>	88
3.3.2.3. Selección de datos de producción	92
3.3.3. Combinación de datos de consumo y de producción	93
3.4. Planteamiento de escenarios y generación de topologías en BRITE	95
3.4.1. Planteamiento de escenarios y configuración de BRITE	96
3.4.2. Resultados de la generación de topologías	97
3.5. Simulación de las topologías en DEN2NE	98
3.5.1. Adaptación del algoritmo DEN2NE a las pruebas	99
3.5.1.1. Cargas y simtest	99
3.5.2. Configuración de los parámetros de entrada	99
3.5.3. Creación del dataset final y conclusiones de las pruebas	101
4. Desarrollo y evaluación del modelo	105
4.1. Selección de modelos	105
4.1.0.1. Random Forest (RF)	105
4.2. Support Vector Machines (SVM)	105
4.2.0.1. Red Neuronal Artificial (ANN)	105
5. Conclusiones y trabajo futuro	107
Bibliografía	109
Lista de Acrónimos y Abreviaturas	117
A. Anexo I - Pliego de condiciones	119
B. Anexo II - Presupuesto	121
C. Anexo III - Manuales de usuario e Instalación	123
C.1. Herramienta BRITE	123
C.1.1. Virtualización del sistema operativo Linux	123
C.1.2. Compilación e instalación de BRITE	123
C.1.3. Ejecución de BRITE	124

Índice de figuras

1.1. Proceso de detección y predicción de errores	2
2.1. Red de distribución y flujo bidireccional de datos y energía en una <i>smart grid</i> [9]	8
2.2. Infraestructura de una interfaz AMI para el flujo bidireccional de energía y datos [7]	10
2.3. Estructura de la respuesta a la demanda en el contexto de una <i>smart grid</i> con prosumidores [12]	11
2.4. Modelo basado en las interacciones de los agregadores con los prosumidores y el mercado eléctrico [15]	12
2.5. Estrategia de DSM basada en interacciones individuales de cada consumidor con la compañía [18]	13
2.6. Estrategia de DSM para smart grids basada en interacciones entre los usuarios y la compañía [18]	14
2.7. Estructura de componentes de una SG [5]	15
2.8. Esquema de funcionamiento de una unidad CHP [19]	16
2.9. Gestión de operaciones en una unidad CHP [20]	17
2.10. Representación del proceso P2G [21]	18
2.11. Instalación de un SVC en Sylling (Noruega) [23]	19
2.12. Representación de un sistema de transmisión de energía eólica con líneas HVDC [27]	21
2.13. Infraestructura de componentes de un sistema IoT [34]	25
2.14. Infraestructura de <i>Big Data</i> enfocada al ámbito de las SGs [28]	28
2.15. Plataforma de análisis de <i>Big Data</i> en el entorno de SGs [39]	28
2.16. Categorías de ML [46]	31
2.17. Modelo RF [47]	32
2.18. Cuantificación del hiperplano óptimo entre dos clases en el SVM [49]	34
2.19. Representación de vectores clasificados erróneamente dentro de los márgenes establecidos en el SVM [51]	35
2.20. Configuración del parámetro de regularización C [53]	36
2.21. Aplicación del kernel RBF [54]	36

2.22. Diferencias estructurales entre el ML y el DL [55]	37
2.23. Arquitectura de una ANN [56]	38
2.24. Modelos soportados por BRITE [4]	40
2.25. Esquema de funcionamiento de BRITE y del <i>parser</i> [3]	41
3.1. Representación del período temporal que comprende el proceso de recolección de datos para cada hogar	48
3.2. Gráfica de valores de múltiples fuentes energéticas (<i>SustDataED</i>)	52
3.3. Mapa mundial del índice de radiación directa normal (DNI) mundial [73] . .	57
3.4. Mapa del índice de radiación horizontal global (GHI) mundial [73]	57
3.5. Mapa del potencial de producción energética fotovoltaica (PVOUT) mundial [73]	58
3.6. Mapa del índice de radiación directa normal (DNI) de Madeira [73]	59
3.7. Mapa del índice de radiación horizontal global (GHI) de Madeira [73] . . .	59
3.8. Mapa del potencial de producción energética fotovoltaica (PVOUT) de Madeira [73]	59
3.9. Representación de la trayectoria solar percibida en la localización de la ciudad de Funchal [73]	61
3.10. Comparación de valores totales mensuales de producción energética fotovoltaica (PVOUT) respecto a la radiación directa normal (DNI) [73]	61
3.11. Perfiles promedios de potencial de producción energética fotovoltaica (PVOUT) y de radiación directa normal (DNI) [73]	62
3.12. Representación de las diferentes opciones de array que permite configurar la herramienta <i>PVWatts</i> [78]	65
3.13. Gráfica para el cálculo de las pérdidas por sombreado en la herramienta <i>PVWatts</i> [78]	66
3.14. Comparación de valores totales mensuales de producción energética fotovoltaica (PVOUT) respecto a la radiación directa normal (DNI) a partir de los resultados de la simulación	68
3.15. Salida de <i>datasamples_onenode.ipynb</i> tras aplicar la operación de promedio	75
3.16. Lanzamiento de pruebas con <i>threads</i>	79
3.17. Lanzamiento de pruebas con procesos	79
3.18. Representación del período temporal que comprende el proceso de recolección de datos para los hogares del segundo despliegue	82
3.19. Comparación del consumo de las viviendas 5 y 17 en el rango seleccionado (<i>SustDataED</i>)	83
3.20. Comparación del consumo de las viviendas 13 y 16 en el rango seleccionado (<i>SustDataED</i>)	84

3.21. Gráfica de energía solar producida a nivel global (<i>SustDataED</i>)	85
3.22. Gráfica de temperatura en el rango seleccionado (<i>SustDataED</i>)	86
3.23. Gráfica de energía solar producida en el rango seleccionado (<i>SustDataED</i>) .	86
3.24. Correlación entre temperatura y energía solar producida en el mes de agosto (<i>SustDataED</i>)	87
3.25. Representación de los valores de correlación mediante un mapa de calor (<i>SustDataED</i>)	88
3.26. Gráfica de energía solar producida en el rango seleccionado (<i>PVWatts</i>) . .	89
3.27. Representación de los valores de correlación mediante un mapa de calor (<i>PVWatts</i>)	90
3.28. Correlación entre temperatura y energía solar producida en el mes de agosto (<i>PVWatts</i>)	91
3.29. Correlación entre radiación y energía solar producida en el mes de agosto (<i>PVWatts</i>)	91
3.30. Representación de los valores de correlación mediante gráficas (<i>PVWatts</i>) .	92
3.31. Comparación entre el consumo y la generación de potencia en la vivienda 1 en el rango seleccionado	94
3.32. Gráfica de la carga neta resultante en la vivienda 1 en el rango seleccionado	94
3.33. nomenclatura de los directorios y ficheros de resultados	99
3.34. Diagrama completo de diseño del dataset final	103
C.1. Características del sistema operativo	124

Índice de tablas

2.1. Tecnologías FACTS de 1 ^a y 2 ^a generación	20
3.1. Comparación entre datasets públicos en el ámbito NILM [59] [70] [71] [60] . .	46
3.2. Tabla de medidas de consumo energético [68]	49
3.3. Tabla de medidas de eventos de potencia [68]	51
3.4. Tabla de medidas de producción de energía [68]	51
3.5. Tabla de medidas de producción de energía [68]	52
3.6. Tabla de medidas de eventos de usuario [68]	53
3.7. Tabla de medidas de condiciones ambientales [68]	53
3.8. Tabla de valores extraídos para cada índice de radiación en la ciudad de Funchal [73]	58
3.9. Dataset con valores totales mensuales [78]	67
3.10. Dataset con muestras adquiridas por hora [78]	67
3.11. Tabla de comparación de los valores totales mensuales de producción energética fotovoltaica (PVOUT) y de radiación directa normal (DNI) de las dos herramientas (valores teóricos y simulados)	70
3.12. Resumen de los datos de consumo del dataset <i>SustDataED</i> [68]	72
3.13. Resumen de las características de los ficheros de los despliegues de <i>SustDataED</i> .	72
3.14. Estructura de campos de cada fichero <i>consum_x.csv</i>	80
3.15. Estructura de campos del fichero <i>mean_prod.csv</i>	85
3.16. Dataset resultante de la etapa de procesamiento	95
3.17. Dataset final obtenido por cada instante temporal probado en DEN2NE . .	102

Índice de Códigos

3.1.	Formato del timestamp	73
3.2.	Eliminación de valores NaN	73
3.3.	Fragmentación de ficheros iniciales	74
3.4.	Función de lectura de los ficheros	76
3.5.	Función de cálculo del promedio	77
3.6.	Función de automatización del cálculo del promedio	78
3.7.	Creación de procesos	80
3.8.	Aplicación del rango temporal a los ficheros	82
3.9.	Combinación de datos de clima y de producción	85
3.10.	Configuración de los parámetros de entrada en el script de automatización de BRITE	97
3.11.	Configuración de los parámetros de entrada en el script de automatización de DEN2NE	100
3.12.	Combinación de resultados y test	101
C.1.	Instalación de paquetes	124
C.2.	Ejecución de la interfaz gráfica de <i>Boston University Representative Internet Topology Generator</i> (BRITE)	124
C.3.	Ejecucion de BRITE por la línea de comandos	124

1. Introducción

En este primer capítulo, se presentarán a modo de introducción los aspectos más relevantes del Trabajo Fin de Máster (TFM) desarrollado, como son la transformación de las redes energéticas en nuevas redes inteligentes de energía (del inglés *Smart Grid* (SG)) y su consecuente necesidad de monitorización, además del creciente auge de la Inteligencia Artificial (IA) y de las técnicas de aprendizaje automático y profundo (del inglés *Machine Learning* (ML) y *Deep Learning* (DL)).

De la misma manera, se hará hincapié en los objetivos que se establecen para este TFM, describiendo así la secuencia de acciones que se seguirá para poder llevarlos a cabo. Dichos objetivos serán los pilares sobre los que se sustente el diseño y el desarrollo de modelos eficientes basado en ML y DL para la detección y predicción de errores en SGs. De forma adicional, se incluirá un último apartado en referencia a la estructura de capítulos que seguirá este TFM, así como una explicación breve sobre los temas que se abordarán en cada uno de ellos.

1.1. Presentación

En los últimos años, el concepto de red eléctrica convencional está siendo completamente transformado como resultado del creciente desarrollo de las SGs [1] [2]. La posibilidad de brindar a tiempo real una monitorización del proceso de distribución eléctrica y a su vez, integrar una participación activa del consumidor convierte a estas redes en uno de los pilares de la transición hacia la descarbonización.

En este contexto, se ha convertido en un objetivo primordial el diseño de nuevos protocolos que provean un encaminamiento y una distribución energética eficientes. Es por ello que, desde el equipo de investigación NetIS de la *Universidad de Alcalá* (UAH) se ha desarrollado el algoritmo *Distributed ENergy ENVironments and Networks* (DEN2NE) [3], con el fin de automatizar la gestión de los recursos en entornos del Internet de las Cosas (del inglés Internet of Things (IoT)), enfocándose especialmente en SGs.

Teniendo esto en cuenta, se puede expresar que DEN2NE pretende realizar una distribución óptima de los recursos energéticos de cada uno de los nodos que presenta una determinada topología de red para conseguir finalmente un balance a nivel global. Sin embargo, el algoritmo se encuentra actualmente con un desafío a afrontar, basado en la imperiosa necesidad de poder detectar y predecir de una forma precisa los posibles errores que se puedan producir en el proceso de distribución energética entre nodos. En caso de fallos en la red, DEN2NE debería tener la capacidad de responder de una forma rápida y específica, pues es de vital importancia tomar acciones a nivel de distribución para evitar que los errores se agraven y escalen al resto de la red.

1.2. Objetivos

Tomando en consideración el apartado anterior, se define como objetivo principal de este TFM el desarrollo de diversas técnicas de ML y DL para identificar de forma precisa los posibles errores que se pueden producir en una SG durante el proceso de distribución energética que, como se ha introducido, se aplicará mediante el algoritmo DEN2NE.

En otros términos, la identificación de patrones se apoyará en el análisis de grandes volúmenes de datos provenientes de implementaciones de SGs reales. Estos serán previamente procesados de una forma exhaustiva para reducir su tamaño y seleccionar la información verdaderamente necesaria para el posterior desarrollo de los modelos. En la Figura 1.1 se determina el diagrama de flujo que define la secuencia de acciones a realizar en este TFM.

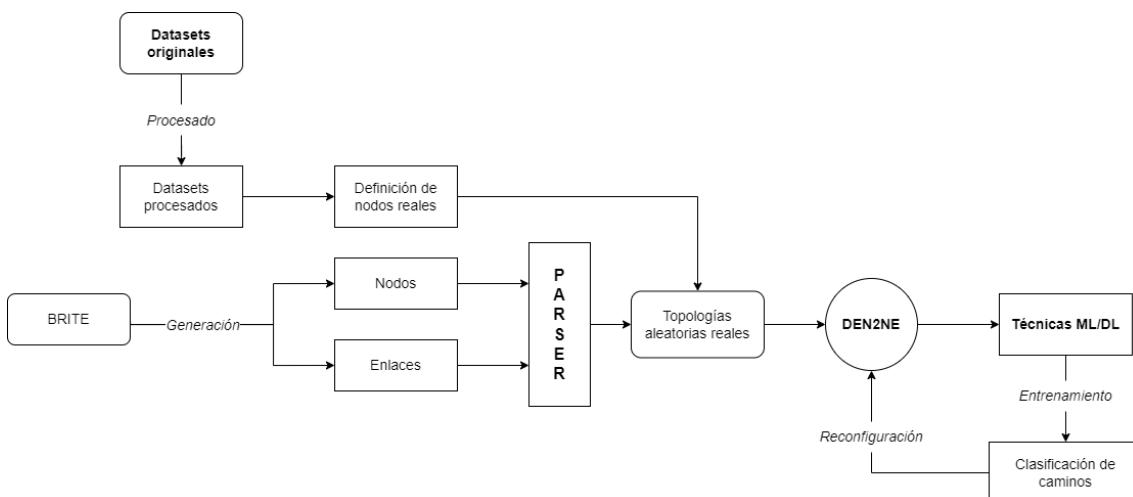


Figura 1.1: Proceso de detección y predicción de errores

Por tanto, el presente TFM permitirá determinar un modelo final de predicción de fallos para entornos de SGs. Entrando en detalle, se pueden definir los diferentes objetivos en los siguientes puntos:

- **Estudio del estado del arte y análisis de las diferentes fuentes de datos reales disponibles.** Se realizará un estudio en profundidad del contexto en el que se engloban las SGs y los protocolos de distribución de recursos, poniendo el enfoque en DEN2NE. Será necesaria una investigación sobre la disponibilidad de fuentes de datos reales y una evaluación de su viabilidad para este TFM. De forma adicional, se precisará del estudio y análisis de herramientas de simulación de datos.
- **Definición y procesado del volumen de datos para el posterior desarrollo.** El procesamiento de los datos adquiridos será fundamental para simplificar su comprensión. Además, se llevará a cabo la selección de la cantidad de información realmente útil para el desarrollo.
- **Planteamiento de escenarios y generación de diferentes topologías.** A partir del volumen final de datos que se elaborará, se plantearán una serie de escenarios mediante la generación de topologías de nodos con la herramienta BRITE [4].
- **Simulación de topologías y extracción del conjunto de datos final.** Las topologías generadas se importarán a un simulador propietario realizado en python. Por consiguiente, se entrará en el funcionamiento del algoritmo DEN2NE y se realizarán las modificaciones necesarias para que, mediante la ejecución del mismo, se pueda extraer el conjunto de datos final sobre el que se va a desarrollar.
- **Desarrollo y entrenamiento de diferentes modelos de ML y DL.** Se realizará un estudio sobre las posibles técnicas de ML y DL a emplear y se procederá a seleccionar las más apropiadas, según el contexto en el que se engloba este TFM. Por consiguiente, se llevará a cabo el desarrollo y el entrenamiento de los mismos tomando como base los datos procesados anteriormente.
- **Análisis y evaluación de los resultados obtenidos.** Se analizarán los resultados de detección y predicción de errores de los diferentes modelos desarrollados. Mediante el análisis en cuestión, se determinará de forma concluyente cuál aporta una mayor efectividad para poder diagnosticar con un alto porcentaje de precisión los errores que se producen en una SG.

1.3. Estructura del TFM

En esta sección se expone de forma general la estructura de capítulos que tendrá la memoria del presente TFM con una breve descripción del contenido que abarcarán cada uno de ellos.

Capítulo 1: Introducción. Se comenzará esta memoria con una presentación de los aspectos más significativos. Se expondrán las motivaciones que han originado la realización de este TFM y los objetivos que se pretenden alcanzar con el mismo.

Capítulo 2: Estado del arte. Se establecerá el marco teórico en el que se sitúa este TFM y se documentarán los conceptos principales para introducir en un contexto lo suficientemente consistente el diseño y desarrollo práctico posterior. Además, se expondrá de forma detallada el funcionamiento del algoritmo DEN2NE.

Capítulo 3: Diseño y análisis de datos. Se llevará a cabo un análisis sobre las posibilidades de diseño a través de una investigación exhaustiva sobre las fuentes de datos de implementaciones reales existentes, además de estudiar y ejecutar algunas herramientas de simulación para extraer información adicional. Después, se definirá todo el procesamiento que deberá llevarse a cabo sobre los datos para sintetizar los mismos y seleccionar únicamente la información útil. Las siguientes etapas vendrán definidas por el planteamiento de diferentes escenarios de red y la generación de topologías mediante la herramienta BRITE y el algoritmo den2ne, respectivamente. Finalmente, se obtendrá el conjunto de datos final sobre el que se entrenarán los modelos de ML y DL a desarrollar

Capítulo 4: Desarrollo y evaluación de los modelos. Se describirá en detalle el desarrollo de las técnicas de ML y DL que han sido seleccionadas según el contexto en el que se engloba este TFM. Los modelos obtenidos serán entrenados, analizados y por consiguiente, evaluados. Los resultados definirán finalmente el modelo más apropiado para diagnosticar con alta precisión los errores que se pueden producir en el entorno de una SG.

Capítulo 5: Conclusiones y trabajo futuro. Se finalizará la memoria con un capítulo enfocado a las conclusiones obtenidas tras la realización de este TFM. Además, se indicarán las posibles vías de trabajo a futuro.

Bibliografía. Se incluirán todas las referencias de artículos, libros, páginas web u otros materiales que han sido consultados y empleados para elaborar esta memoria. Se seguirá el estilo de citación del Institute of Electrical and Electronics Engineers

(IEEE), así como las recomendaciones oficiales de la normativa sobre TFMs de la UAH.

Anexos. Se añadirán los manuales de usuario y de instalación de herramientas. También, se expondrán las especificaciones del *hardware* sobre el que se ha desarrollado este TFM y una estimación de su presupuesto.

2. Estado del arte

En el presente capítulo se entrará en profundidad en los conceptos más relevantes relacionados con el TFM. Por ello, el estado del arte se dividirá en una serie de Secciones enfocadas, por un lado, en el contexto de las SGs y las redes IoT (ver Secciones 2.1 y 2.2) y, por otro lado, en la descripción teórica del concepto de *big data* y de las técnicas de ML y DL (ver Secciones 2.4 y 2.5.1) que se aplicarán en la etapa de desarrollo.

De la misma forma, se añadirá una última Sección (ver Sección 2.6) que detallará las herramientas software que se emplearán. En el caso de este TFM se presentará el funcionamiento de la plataforma BRITE, que será necesaria posteriormente para el diseño de escenarios de red y la generación de topologías.

Es por ello que se puede expresar que el propósito principal de este Capítulo se centra en establecer un marco teórico consistente y que, por tanto, permita conseguir una suficiente compresión del contexto, previamente a la exposición de las etapas de diseño y desarrollo del TFM en los Capítulos 3 y 4.

2.1. Smart Grids

En las últimas décadas, se ha observado una transformación integral del modelo asociado a la red eléctrica convencional. El aumento de la energía demandada por los usuarios finales y los requisitos cada vez mayores de la industria ha tenido como consecuencia que algunos países hayan intentado diseñar redes eléctricas agrupadas en un conjunto de grandes redes nacionales. De este modo, todas las fuentes energéticas disponibles pueden estar conectadas para ser gestionadas conjuntamente en función de la demanda recibida, además de conseguir una coordinación a alto nivel. [5]

Sin embargo, una red eléctrica no se puede definir como una entidad única e independiente, pues se trata de una agregación de redes, compañías energéticas y operadores que trabajan en distintos niveles de comunicación. Es por ello, que la idea de desarrollar una gran red nacional encuentra cierto equilibrio energético, pero no llega a los altos porcentajes de eficiencia que pueden proveer las redes inteligentes energéticas o de otra forma, las *smart grids* (SG).

La iniciativa sobre redes inteligentes del IEEE, califica a las *smart grids* [6] como "imperativas y revolucionarias que implican nuevas capacidades de comunicación y control, fuentes de energía, modelos de generación y adherencia a estructuras regulatorias transjurisdicciones". Por otro lado, en el año 2009, el Departamento de Energía de Estados Unidos [7] determinó en su reporte anual sobre *smart grids* los siguientes objetivos principales que se perseguían con el desarrollo de este tipo de redes:

- Permitir una participación activa de los clientes en el sistema.
- Integrar todas las opciones de generación y almacenamiento de energía.
- Ofertar nuevos productos y servicios.
- Proporcionar energía de calidad y satisfacer un gran rango de necesidades.
- Optimizar el uso de los recursos y aumentar la eficiencia.
- Dar una respuesta rápida ante emergencias y problemas producidos en la red.

Tomando en consideración estos objetivos, se puede definir una *smart grid* como una red inteligente con la capacidad de distribuir los suministros de energía de forma optimizada a los usuarios, basándose en la información que recoge de los mismos. Es por ello que supone una actualización digital de las redes de distribución y transmisión a larga distancia para incorporar sistemas de monitorización y control a tiempo real (ver Figura 2.2). [8]

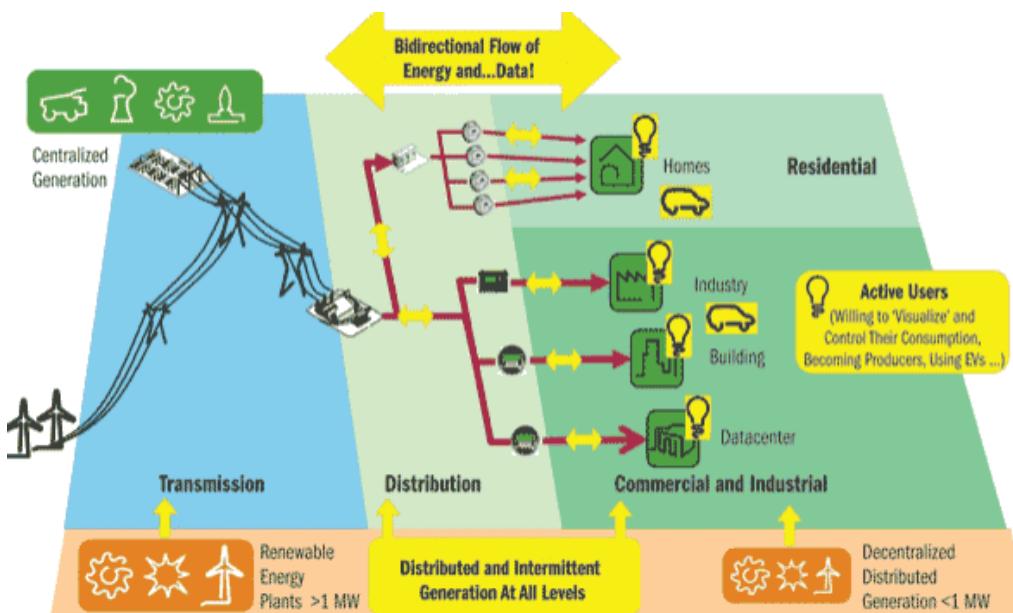


Figura 2.1: Red de distribución y flujo bidireccional de datos y energía en una *smart grid* [9]

Su base se asienta en el diseño de sistemas inteligentes coordinados capaces de obtener tanto la información respectiva a la demanda o requisitos energéticos de cada zona como la de la disponibilidad de recursos a partir de las diferentes fuentes de producción existentes. Todo ello conduce al desarrollo de un plan estratégico de distribución energética para poder conectar a todas las entidades participantes en la red entre sí. Además, en cuanto al factor medioambiental, las SGs son un concepto clave en la transición energética y en el proceso de descarbonización. La aplicación de una distribución energética inteligente y la posibilidad de integrar al sistema fuentes renovables permiten el desarrollo de ciudades sostenibles y una gran reducción de emisiones de CO₂. [1] [10]

2.1.1. Flujo energético y comunicación bidireccional

Cabe destacar que una de las principales características diferenciadoras de las SGs respecto a las redes energéticas convencionales es que se fundamentan en una comunicación bidireccional. Este factor determinante se puede apreciar en la Figura 2.1 y se traduce en una producción y una distribución dinámica y personalizada hacia cada usuario de la red.

Es decir, en una red tradicional al ser unidireccional, se provee energía desde el distribuidor hacia el consumidor sin llevar a cabo ningún análisis estadístico sobre el consumo que se está produciendo en las líneas finales en un determinado instante temporal. En cambio, en el contexto de las SGs, se pone el foco en las acciones de los usuarios y en la consecuente asignación de patrones de consumo eléctrico que permita predecir el comportamiento futuro de los mismos. Sin embargo, como se expondrá más adelante en la Sección 2.1.3.3, este proceso de clasificación de usuarios requerirá del análisis de grandes volúmenes de datos adquiridos a tiempo real, por lo que se aumentará la complejidad del sistema a costa de alcanzar la eficiencia. [11]

Bajo la premisa de la característica de red bidireccional, se puede expresar que los propios usuarios son el gran pilar sobre el que se cimienta el sistema. En comparación a la red eléctrica tradicional, toman un papel mucho más activo monitorizando continuamente su comportamiento eléctrico y recopilando información para trasladarla al resto de la red. Esto tiene como ventaja una gran reducción de los costes derivados de la distribución y transmisión en el sistema, ya que se evita proporcionar más cantidad de energía de la requerida por las líneas finales. [8]

Es por ello que se emplea una Infraestructura Avanzada de Medición (del inglés Advanced Metering Infrastructure (AMI)) con una interfaz constituida por varias capas o niveles como se puede apreciar en la Figura 2.2. De esta forma, se dividen los flujos de comunicación entre las diferentes entidades que componen la red para permitir una mejor

gestión de los mismos. [7]

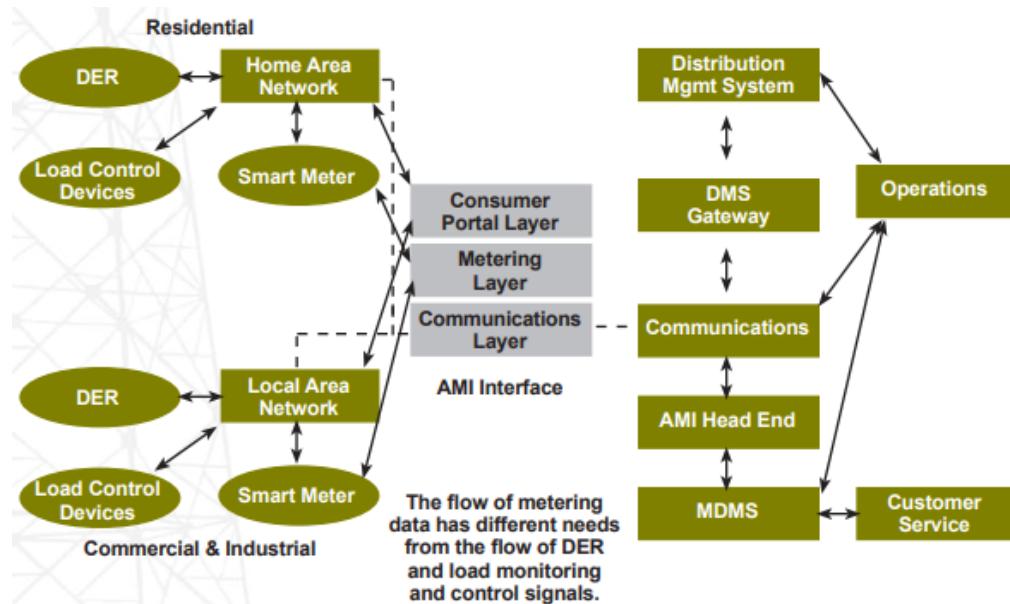


Figura 2.2: Infraestructura de una interfaz AMI para el flujo bidireccional de energía y datos [7]

2.1.2. Prosumidores y microgrids

Dentro del presente contexto, en referencia a los usuarios es preciso introducir el término de prosumidor [12]. Se puede determinar como prosumidora a toda entidad o usuario final que tiene la capacidad de producir de forma alternativa recursos energéticos, además de poder consumirlos. En la Figura 2.3 se puede visualizar cómo se estructura la SG en un conjunto de distintas comunidades o agregaciones de prosumidores con el fin de crear microrredes de distribución y almacenamiento energético (del inglés *microgrids*).

En este caso es imprescindible que los equipos y dispositivos dedicados a la generación de electricidad se encuentren dentro de la microrred o en una ubicación cercana a la misma. Así, se podrá abastecer a los usuarios del conjunto de forma eficiente, reduciendo los costes relacionados con la transmisión energética.

Este tipo de esquema puede ser aplicado en diferentes entornos, como pueden ser los residenciales, industriales o agrícolas, para conseguir descentralizar la gestión de los recursos. Sin embargo, debe existir cierta gestión externa y coordinada de todas estas microrredes o comunidades de usuarios. Esta es llevada a cabo por una entidad denominada como operador del sistema distribuido (del inglés *Distribution System Operator* (DSO)) [12] [13]. Algunas de sus funciones principales se basan en asegurar el abastecimiento de recursos en

el interior de las microrredes en función de la demanda existente y en supervisar el estado operativo la infraestructura de red para garantizar su estabilidad y seguridad.




Figura 2.3: Estructura de la respuesta a la demanda en el contexto de una *smart grid* con prosumidores [12]

Por otro lado, se encuentra también la figura del centro de servicios auxiliares [12], que se encarga de recibir la información sobre los recursos energéticos de los prosumidores y cuantificar en función de la oferta y demanda el beneficio económico que obtendrán los prosumidores. Estos normalmente son gestionados por los operadores del mercado eléctrico, pero puede variar según la región o el país.

2.1.2.1. Mercado energético

Las agregaciones de prosumidores posibilitan el autoconsumo y la compartición de los recursos generados por sí mismos con los demás participantes de la microrred, incluso con el resto de la SG. La mayoría de los prosumidores, sobre todo en entornos residenciales son de pequeño tamaño y tienen mayores complicaciones para participar en los mercados eléctricos por sí mismos.

Por ello, los agregadores [14] [12] se encargan de facilitar esta tarea para que una cantidad de prosumidores locales puedan actuar en conjunto como fijadores de precios de

compra/venta en el mercado eléctrico global. Es decir, cada agregador se encarga de representar a los prosumidores que lo componen y actúa como intermediarios entre los mismos y el conjunto de mercados energéticos. A cambio, cada prosumidor debe pagar un plan mensual a la compañía para cubrir los costes eléctricos y así, dejar la responsabilidad de las transacciones a los agregadores para que operen de forma flexible. En esta operativa también incide el DSO, el cual se encarga de que las transacciones de compra/venta sigan el cumplimiento de los estándares y regulaciones establecidos en el mercado energético.

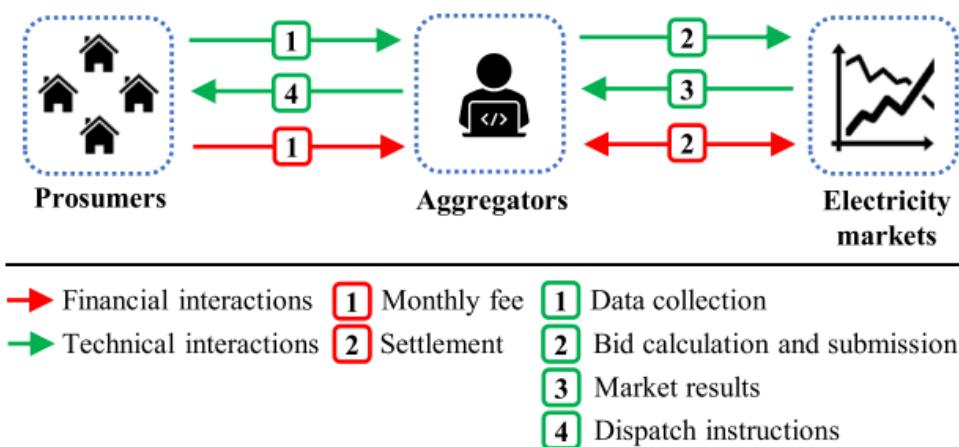


Figura 2.4: Modelo basado en las interacciones de los agregadores con los prosumidores y el mercado eléctrico [15]

A partir del funcionamiento expuesto y de la Figura 2.4, se pueden diferenciar los tipos de interacciones que se producen en este modelo [15]:

- Interacciones técnicas
 1. Recopilación y adquisición de datos sobre los recursos de los prosumidores para su posterior procesamiento en los agregadores.
 2. Cuantificación y presentación de ofertas desde los agregadores hacia los mercados mayoristas de electricidad.
 3. Comunicación de los resultados de diferentes mercados a los agregadores.
 4. Envío de instrucciones o recursos distribuidos en función de los resultados del mercado.
- Interacciones financieras
 1. Pago de tarifa mensual de cada prosumidor al agregador.

2. Liquidación de las transacciones trasladadas desde los prosumidores en el mercado eléctrico (cobro por demanda y pago por generación).

En cuanto al proceso de fijación de precios, generalmente, se adoptan tarifas minoristas dinámicas según el instante temporal, como pueden ser la fijación de precios por tiempo de uso (del inglés *Time-of-Use Pricing* (TOU)) o en tiempo real (del inglés *Real Time Pricing* (RTP)). Dentro de este contexto es preciso introducir los programas de gestión del lado de la demanda (del inglés *Demand Side Management* (DSM)).

Como término, un programa DSM es un programa basado en el control de las interacciones de consumo y de gestión de cargas residenciales desde el lado del cliente. Considerando este modelo de interacciones, se puede expresar que un DSM tiene como pilar fundamental la distribución de recursos energéticos de manera eficiente y acorde a la demanda y a la oferta. Permite reducir el coste de la adquisición energética y los costes asociados a la distribución como consecuencia de minimizar el número de interacciones necesarias entre el prosumidor y el resto de entidades del sistema. [16]

Por lo tanto, volviendo a los modos de dinamización de las tarifas, si por ejemplo se emplea RTP, se buscará lograr el equilibrio de la demanda en tiempo real, modificando las cargas de los consumidores en las horas pico [17]. Es decir, cada uno de los usuarios actúa individualmente en función de los precios dinámicos en el tiempo, comunicándose directamente con la compañía energética como se puede visualizar en la Figura 2.5.




Figura 2.5: Estrategia de DSM basada en interacciones individuales de cada consumidor con la compañía [18]

Con este proceso, el consumidor como puede saber en tiempo real la tarifa a la que está consumiendo energía, puede trasladar su propia carga desde las horas donde el precio es más alto (horas pico) a las de precio menor (horas valle). Esta gestión produce por tanto, menores picos de demanda y contribuyendo a la bajada de los precios. [16] [18]

No obstante, el diseño de un programa DSM ideal en el contexto de las SGs debería

permitir también las interacciones entre los mismos prosumidores dentro de una zona residencial o microgrid. Estas interacciones generalmente se automatizan a través de equipos dedicados a una comunicación digital bidireccional. Como se aprecia en la Figura 2.6, este proceso tiene como fin conducir a una coordinación de las acciones respectivas a las cargas de un área determinada. Por tanto, en este caso la monitorización de las cargas totales para todos los nodos participantes en un instante determinado aportará la información necesaria sobre la relación entre la potencia pico y promedio (del inglés *Peak-to-Average Ratio* (PAR)) y contribuirá a la fijación del precio unitario para ese mismo instante. [18]

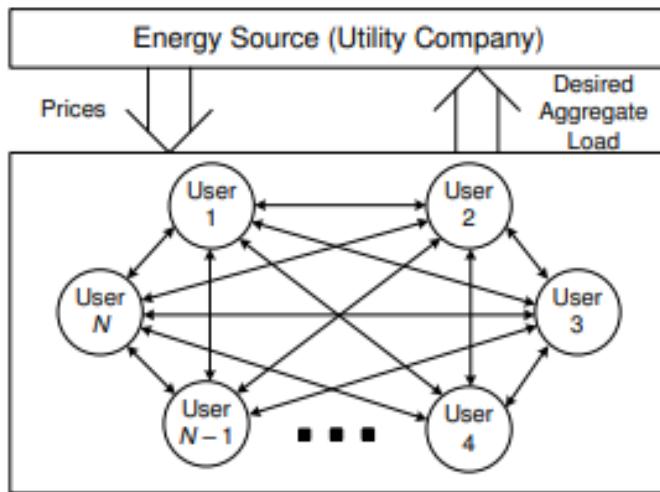


Figura 2.6: Estrategia de DSM para smart grids basada en interacciones entre los usuarios y la compañía [18]

2.1.3. Estructura de una Smart Grid

Una SG está constituida por múltiples elementos diferentes como se puede visualizar en la Figura 2.7. Cada uno de ellos está dedicado a uno de los procesos principales, que se pueden dividir en generación, distribución y consumo. [5]

2.1.3.1. Generación

Como ya se introducía en la Sección 2.1.2, dentro de una SG, el prosumidor se trata de la figura que potencia principalmente el uso de energías renovables, las cuales pueden ser obtenidas por ejemplo a partir de generadores térmicos fotovoltaicos (del inglés *Photovoltaic Thermal* (PVT)) o de turbinas eólicas. Para posibilitar posteriormente el uso de la energía generada, esta debe ser convertida y acondicionada mediante dispositivos

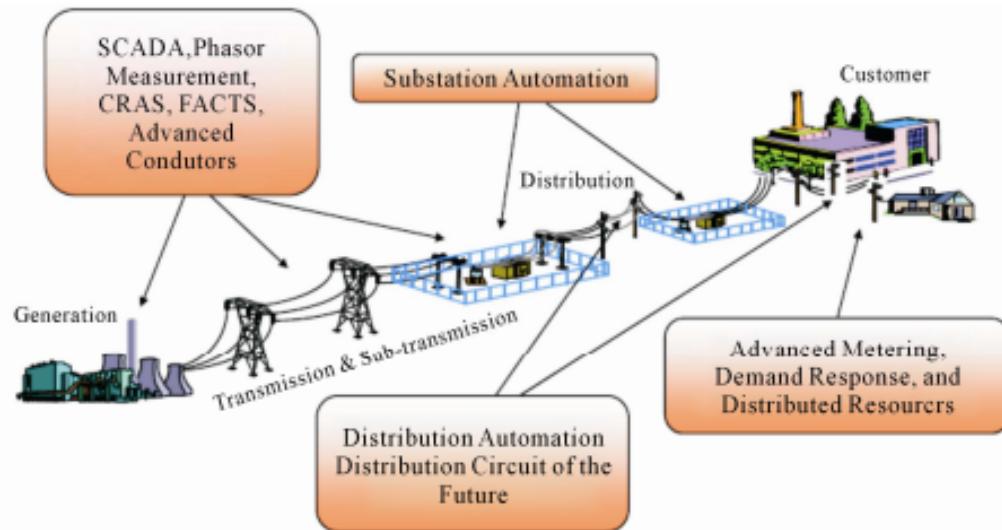


Figura 2.7: Estructura de componentes de una SG [5]

dedicados, como son unidades combinadas de calor (del inglés *Combined Heat and Power* (CHP)) o de conversión a gas (del inglés *Power-to-Gas* (P2G)). [12]

Las unidades CHP [19], como se puede apreciar en la Figura 2.8, llevan a cabo un aprovechamiento del calor residual que deriva del proceso de generación de electricidad. Se emplean como respaldo eléctrico, ya que se componen de sistemas de almacenamiento de energía térmica (del inglés *Thermal Energy Storages* (TES)) para poder separar la producción y el uso del calor y la energía. Luego, este calor almacenado se puede emplear en aplicaciones térmicas como la calefacción u otros procesos industriales. [20]

COMBINED HEAT & POWER

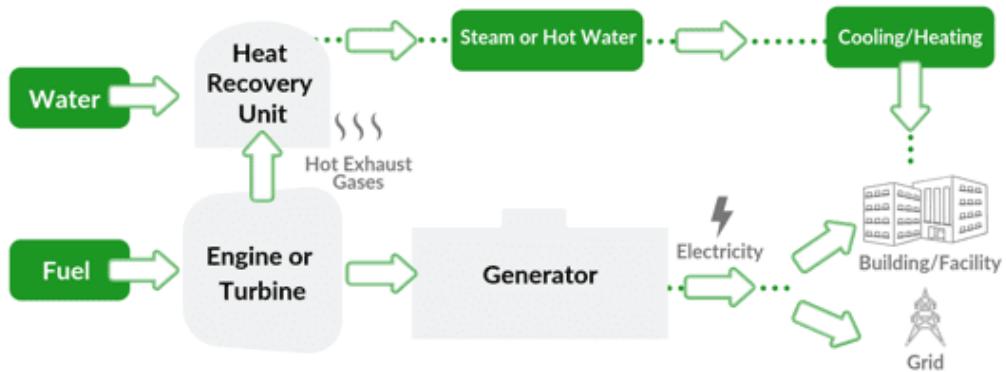


Figura 2.8: Esquema de funcionamiento de una unidad CHP [19]

Es por ello que las unidades CHP mejoran la eficiencia del sistema energético, contribuyendo a un uso mucho más eficaz de los recursos y a una reducción de las pérdidas que se producen en la transmisión. Además del TES, utilizado para almacenar el calor producido, una unidad CHP también se constituye de un motor acoplado a un generador eléctrico para llevar a cabo el proceso de generación de electricidad y calor. Como se puede apreciar en la Figura 2.9, todas las operaciones de la unidad y las interacciones que se producen entre módulos se coordinan desde el gestor de operaciones para que se produzca un correcto funcionamiento.




Figura 2.9: Gestión de operaciones en una unidad CHP [20]

Por otro lado, la unidad P2G, mencionada anteriormente, se encarga de la conversión de la electricidad en gases sintéticos, como son el hidrógeno o el metano. Es de gran importancia, ya que este tipo de gases son más fácil de transportar y almacenar que la electricidad, por lo que se simplifica la gestión energética. Como se puede apreciar en la Figura 2.10, el objetivo del P2G se basa en descomponer el agua mediante un proceso de electrólisis a partir de electricidad proveniente de fuentes renovables. Después, el hidrógeno que se produce se puede utilizar directamente o procesarlo de forma adicional en metano. [12]

Dentro del contexto de la generación de energía también es importante destacar algunos equipos, como son los sistemas de control y adquisición de datos (del inglés *Supervisory Control and Data Acquisition (SCADA)*) [22]. Estos pueden ser instalados en generadores, como son paneles solares fotovoltaicos o turbinas eólicas, consiguiendo una monitorización remota de los mismos. Mediante la información recopilada a tiempo real permiten conocer los niveles de generación y establecer una predicción de la disponibilidad energética que habrá en el sistema o en un área determinada del mismo.

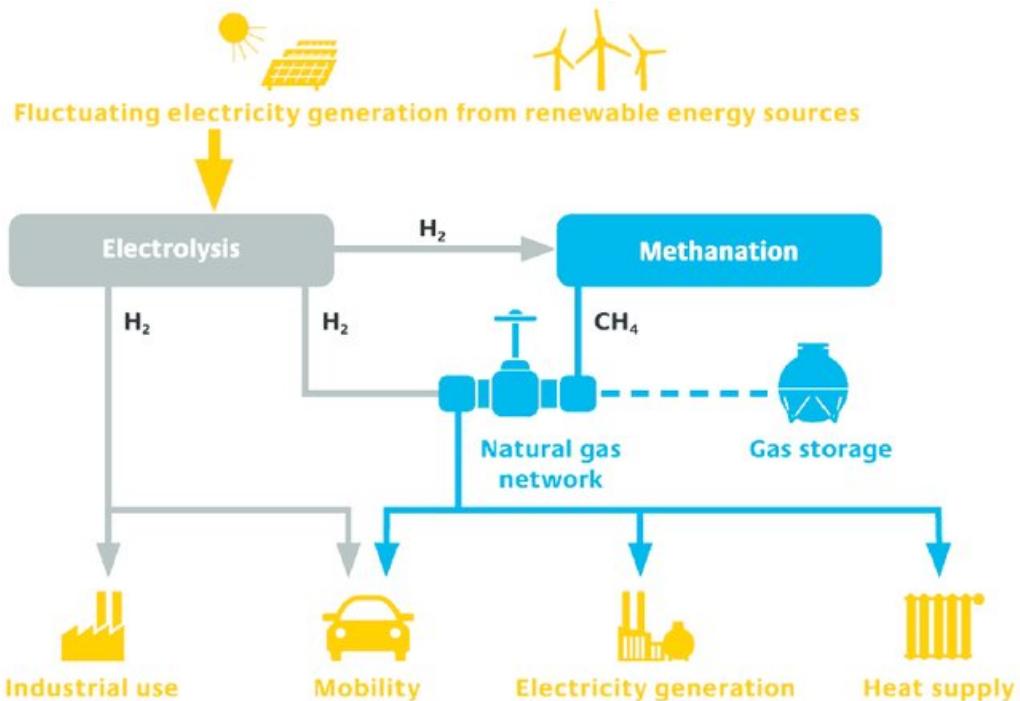


Figura 2.10: Representación del proceso P2G [21]

2.1.3.2. Distribución

Un dispositivo importante en el campo de la distribución energética es la Unidad de Medición de Fasores (del inglés *Phasor Measurement Unit* (PMU)). Se emplea para medir con una alta precisión los fasores de tensión y corriente en la red eléctrica, proporcionando información relevante sobre las magnitudes y fases de las ondas sinusoidales.

También, es empleado en los generadores y debe contar con una alta tasa de muestreo para capturar eventos transitorios o cambios rápidos en la red. En otros términos, debe tener la capacidad de identificar o detectar a tiempo real posibles anomalías que se puedan dar en la distribución y por ello, se trata de un componente imprescindible para comprobar y garantizar la estabilidad de la SG.

La confiabilidad y la seguridad de la red también reside en los Sistemas de Transmisión de Corriente Alterna Flexibles (del inglés *Flexible AC Transmission System* (FACTS)) [23] [24]. Estos vienen dados por la necesidad de superar las limitaciones técnicas introducidas por las redes eléctricas, como son las térmicas o las respectivas al voltaje. En otros términos, incrementan la potencia transmitida y aportan flexibilidad al permitir modificar de forma dinámica los parámetros eléctricos ante cambios en la configuración de la red.

Los FACTS incluyen todos los elementos electrónicos basados en tecnología de alta potencia y que son empleados dentro de una SG para la transferencia de energía de CA y el control de la potencia reactiva. También, realizan tareas de reducción de impedancia en las líneas de transmisión y de optimización del factor de potencia y pueden actuar tanto a nivel individual como de forma coordinada con otros controladores. Los FACTS se dividen en dos generaciones: la primera emplea interruptores controlados por tiristores y la segunda tiene como base convertidores estáticos de commutación. En la Tabla 2.1 se visualizan las tecnologías FACTS más relevantes. [25] [24]

Poniendo el enfoque en la garantía de estabilidad de una SG, uno de los sistemas más importantes de los expuestos en la Tabla 2.1 es el *Static Var Compensator* (SVC) [23]. Los compensadores estáticos son capaces de detectar grandes caídas de tensión resultantes a la producción de un cortocircuito o a la pérdida de líneas de transisión en un área de la red. Esto es importante, ya que una detección rápida de una avería permite restaurar en un corto período de tiempo la tensión del área afectada sin que el problema escale a otras partes de la red.

En otros términos, aísla este área del resto de la red eléctrica. Además, el SVC asegura que el proceso de restauración se produzca paulatinamente para que los efectos producidos por el cortocircuito sean prácticamente imperceptibles en los puntos de carga del área afectada. En la Figura 2.11 se puede apreciar un ejemplo de instalación de un SVC en el municipio noruego Sylling y se encuentra conectada a un sistema de 420 kV.



Figura 2.11: Instalación de un SVC en Sylling (Noruega) [23]

Generación	Tipo	Descripción
1º	<i>Thyristor-Controlled Series Capacitor</i> (TCSC)	Controla el flujo de potencia tanto reactiva como activa por la línea de transmisión mediante el ajuste de impedancia en serie y amortigua las oscilaciones.
	SVC	Absorbe o suministra potencia reactiva según las necesidades de una línea de transmisión a través de la variación de la susceptancia en paralelo. Ayuda a mantener el voltaje estable en la red y proveen un aumento de la capacidad de transferencia de energía.
2º	<i>Static Synchronous Compensator</i> (STATCOM)	Compensa la potencia reactiva al igual que el SVC, pero en este caso empleando electrónica de potencia para proporcionar una respuesta más rápida.
	<i>Unified Power Flow Controller</i> (UPFC)	Combina las funciones de un TCSC y un SVC, teniendo la capacidad de controlar en una línea de transmisión tanto la impedancia en serie como la susceptancia en paralelo.
	<i>Static Synchronous Series Compensator</i> (SSSC)	Modifica dinámicamente la impedancia y es capaz de controlar la fase y la amplitud de la tensión en la línea.
	<i>Interline Power Flow Controller</i> (IPFC)	Conecta varias líneas de transmisión en paralelo. No obstante, modula la impedancia y la fase de la tensión de cada línea de transmisión de forma independiente, lo que permite operar sobre el flujo de potencia de una forma controlada. Mejora la capacidad de transmisión y reduce las pérdidas energéticas.

Tabla 2.1: Tecnologías FACTS de 1^a y 2^a generación

Siguiendo en el ámbito de la distribución energética, es importante también exponer las tecnologías enfocadas a la transmisión de electricidad a larga distancia, como son las Corriente Continua de Alto Voltaje (del inglés *High Voltage Direct Current* (HVDC)) [26]. Como su nombre indica, utilizan corriente continua para ello, lo que minimiza las pérdidas en el proceso de transmisión respecto al caso de la Corriente Alterna de Alto Voltaje (del inglés *High Voltage Alternating Current* (HVAC)), además de permitir portar mucha más potencia. Esto es fundamental cuando se pretende integrar al sistema global fuentes de energía ubicadas en áreas remotas, sobre todo dentro del contexto de las SGs. Generalmente, las fuentes de energías renovables, como pueden ser la solar o la eólica, se encuentran alejadas de los puntos geográficos con mayor demanda y se requiere una respuesta rápida ante cambios de carga para mantener la estabilidad del sistema.

Es decir, cuando se transmiten grandes cantidades de potencia a largas distancias con líneas de HVAC, se generan ángulos eléctricos entre los voltajes y las corrientes en la línea muy grandes que pueden producir oscilaciones descontroladas y por tanto, desencadenar inestabilidades que llegarán a escalar a lo largo del sistema. Por ello, las tecnologías HVDC simplifican la interconexión entre microrredes y permiten una mayor integración de sistemas dedicados al almacenamiento energético para facilitar la gestión de los recursos disponibles. Como desventaja, se encuentra el alto coste que supone su implementación, ya que al final solamente se puede emplear en el caso de aplicaciones punto a punto.

En la Figura 2.12 se muestra como ejemplo una infraestructura de transmisión de energía eólica a larga distancia. Esta energía proviene de una fuente remota y se transporta a través del medio marino para llegar hasta los usuarios. Como se puede apreciar, es necesario implementar estaciones de conversión de alto voltaje de corriente alterna a continua y viceversa en los extremos de las líneas HVDC.

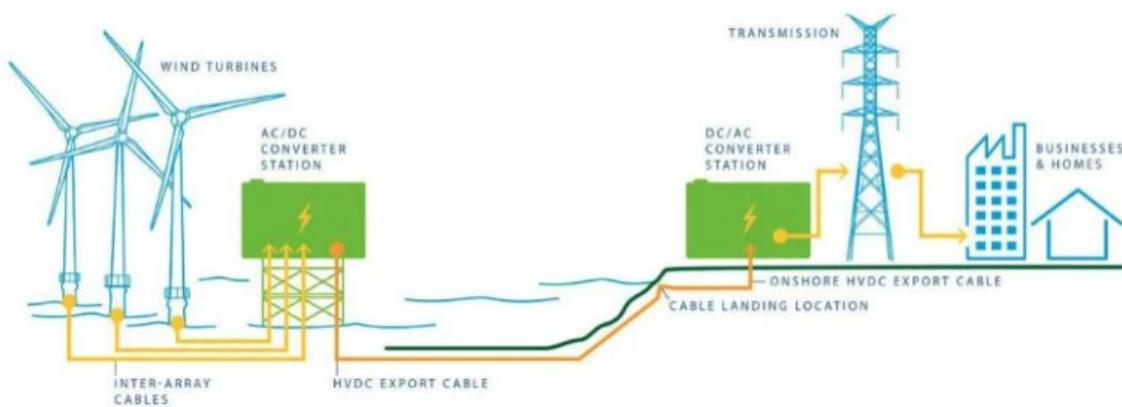


Figura 2.12: Representación de un sistema de transmisión de energía eólica con líneas HVDC [27]

2.1.3.3. Consumo

Entrando en detalle en las ubicaciones finales del sistema y por tanto, en el proceso de consumo, es imprescindible conocer la cantidad de energía demandada por los clientes que pertenecen a una SG. La instalación de sensores o medidores inteligentes (del inglés *smart meters*) en las viviendas posibilitan el registro constante de datos respectivos al consumo de energía, niveles de voltaje, corriente y factor de potencia. Estos son almacenados, analizados y procesados por las distribuidoras de energía para obtener a partir de los mismos la información necesaria sobre el comportamiento de los usuarios. [28]

Como se había introducido en el Apartado 2.1 el proceso de adquisición de datos por parte de los usuarios se trata de uno de los pilares más relevantes de cara a la optimización energética del sistema. Los objetivos principales que se pretenden con este proceso se engloban en la reducción del consumo, la optimización de la distribución y la maximización del beneficio. Respecto a este último, las compañías energéticas a partir de su base de clientes estudian las estrategias de categorización de los mismos para definir el sistema de fijación de precios dinámicos. [28]

No obstante, la gestión de los sensores finales en las SGs se caracteriza por su alta complejidad, debido a los grandes volúmenes de datos a manejar. Se requiere un procesamiento eficiente a tiempo real para analizar datos capturados de múltiples fuentes con el fin de evitar latencias o bloqueos en el sistema. Es por ello que se dificulta el empleo de herramientas convencionales de gestión de bases de datos y se requiere una solución más avanzada mediante la aplicación de tecnologías enfocadas al *Big Data*. Se profundizará más sobre ello en la Sección 2.4.

2.1.4. Seguridad en Smart grids

Como se ha introducido en la Sección referente a la figura del prosumidor (ver Sección 2.1.2), el DSO tiene la capacidad de operar ante problemas y fallos en la red tomando decisiones y dando una respuesta rápida. En determinados casos las incidencias se pueden dar por la configuración del propio sistema, si esta no se realiza de forma correcta y eficiente. No obstante, también es preciso contemplar la posibilidad de ataques externos que atenten contra el sistema de la SG.

Uno de los ataques más peligrosos en este ámbito es el de Inyección de Datos Falsos (del inglés *False Data Injection* (FDI)) [29] y, como su nombre determina, se basa en la inyección de paquetes maliciosos en la red con el fin de bloquear los servicios de la misma y conseguir la autorización para realizar operaciones restringidas. El proceso se puede realizar actuando directamente a través de los sensores finales (*smart meters*) o

secuestrando el canal de comunicación. Algunas técnicas empleadas por los atacantes son las siguientes [29]:

- Fallo del dispositivo: Se aplica un ataque de Denegación de Servicio (del inglés *Distributed Denial of Service* (DDoS)) a los sensores. Cabe destacar que generalmente los sensores que se encuentran en las ubicaciones finales tienen una capacidad limitada de conexión que derivaría en grandes latencias en la comunicación de datos con el resto de entidades de la red. En este momento el atacante se encarga de suplantar al host en cuestión para enviar los paquetes falsos en su nombre.
- *Cracking*: Se descifran las contraseñas para obtener acceso a los equipos mediante ingeniería social o fuerza bruta. De la misma forma que el anterior, la limitación de los recursos computacionales de los sensores provoca que no existan mecanismos de contraseñas lo suficientemente seguros. Además, la mayoría de ellos emplean como protocolos de comunicación Modbus/TCP o DNP 3.0/TCP, los cuales implementan una transmisión de texto en formato plano y sin cifrado. Por ello, un atacante puede tener la posibilidad de monitorear y capturar el tráfico si consigue acceso.
- Envenenamiento de tablas *Address Resolution Protocol* (ARP) o *ARP Spoofing* [30]: Consiste en enviar mensajes falsos ARP para monitorizar el tráfico y capturar o alterar los paquetes que se están transmitiendo por la red.

Teniendo esto en cuenta, es imprescindible definir los mecanismos de detección y mitigación a emplear para evitar que se produzcan ataques FDI [29]:

- Mecanismo de autenticación estrictos: Los datos que se suministran al DSO o a otras entidades de control de la SG deben de ser autenticados para comprobar su confiabilidad. Para ello, se emplean por ejemplo, marcas de tiempo para evitar ataques de repetición y protocolos de seguridad como *Transport Layer Security Protocol* (TLS) o *Secure Sockets Layer* (SSL), además de *Secure Hash Algorithm* (SHA) y *Hash Message Authentication Code* (HMAC).
- Gestión dinámica de claves: Se actualizan las claves con una determinada frecuencia para incrementar la seguridad de los estándares IEEE 802.11s y evitar ataques DDoS.
- Empleo del protocolo *Secure Neighbor Discovery* (SEND) [31]: Para evitar los ataques de *ARP Spoofing* se emplean pares de claves *Rivest, Shamir y Adleman* (RSA) para poder garantizar en el proceso de enrutamiento que los mensajes que tienen como origen un determinado host pertenecen al mismo.

2.1.5. Desafíos futuros de las smart grids

2.1.5.1. Retos técnicos

2.1.5.2. Retos económicos

2.2. IoT

El Internet de las Cosas (del inglés IoT) [32] [33] se define como la integración de múltiples sensores o dispositivos físicos interconectados entre sí que se comunican a través de una red inalámbrica y recopilan información en tiempo real.

La evolución del IoT tal y como se conoce en la actualidad tiene sus inicios en los años 90. Sin embargo, en ese entonces estas tecnologías se enfrentaban con la problemática del gran tamaño que presentaban los chips, por lo que se produjo un avance lento de las mismas. A medida que se permitió la reducción del volumen los dispositivos electrónicos y se mejoró la eficiencia y la capacidad de computación de los chips, se facilitó el progreso del IoT.

En los últimos años, la integración de la tecnología 5G o de quinta generación móvil, ha supuesto el incremento de la velocidad de transmisión, procesamiento y análisis de los datos en los sistemas IoT. La capacidad de administrar a gran escala multitud de dispositivos físicos y la próxima implementación del 6G, depara un futuro en el que las tecnologías IoT estarán presentes en numerosos ámbitos y sectores.

Una de las grandes ventajas que proporcionan los sistemas IoT es que no es necesaria la intervención humana para posibilitar la transmisión y recepción de datos entre los elementos de la red. También, cabe destacar la reducción del coste de computación, la automatización de las tareas y la monitorización en tiempo real. No obstante, en cuanto a posibles desventajas, pueden presentar ciertas vulnerabilidades en cuestiones de privacidad y seguridad. Por ello, en la construcción de un sistema IoT se deben centrar esfuerzos en blindar los distintos elementos que lo componen frente a posibles ataques que puedan extraer información delicada o sabotear el funcionamiento.

En cuanto a la estructura de un sistema IoT, se pueden diferenciar cuatro componentes que contribuyen al funcionamiento del mismo [32] [33]:

- Dispositivos inteligentes: Se trata de cualquier elemento físico al que se le pueda asignar una dirección IP y que tenga como mínimo capacidad de computación para recopilar datos del entorno o del usuario y transmitirlos a través de la red.
 - Conectividad: En este campo entran varias posibilidades de conexión: Wi-Fi, Blue-
-

tooth, redes de área amplia y baja potencia (del inglés *Low Power Wide Area Networks* (LPWAN)), etc.

- Aplicación: Se compone de un conjunto de servicios de nube que se encargan de integrar y procesar todos los datos recopilados por los dispositivos del sistema IoT. Además, en algunos ámbitos, emplea técnicas de ML para analizar la información que recibe y optimizar la toma de decisiones en el sistema.
- Interfaz gráfica: Desde la misma, el usuario puede gestionar y controlar el conjunto de elementos de la red. La interfaz está conectada directamente a la nube y puede tratarse de una aplicación móvil o web.

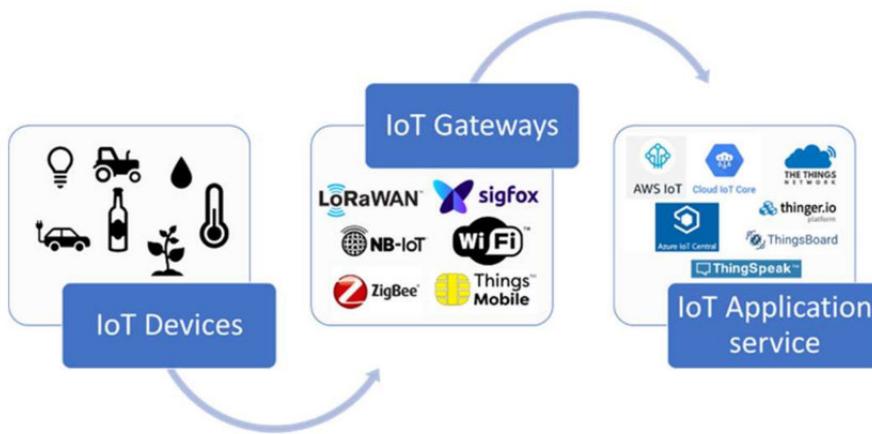


Figura 2.13: Infraestructura de componentes de un sistema IoT [34]

2.2.1. IoE

Considerando el contexto energético en el que se engloba este TFM y entrando con más detalle en el marco de las tecnologías IoT, es preciso destacar dentro de las mismas la subcategoría denominada como el Internet de la Energía (del inglés Internet of Energy (IoE)) [35]. Como concepto, el IoE comprende todo el paradigma de operación de los elementos que constituyen una red energética. Es decir, lleva a cabo la integración de todos los dispositivos, sensores o equipos informáticos en una misma estructura, la cual está basada en internet para poder monitorizar y controlar remotamente cada punto de la red.

Se puede expresar que, con la implementación de tecnologías basadas en IoE, se buscan objetivos muy similares a las SGs. No obstante, el IoE va más allá y supone un control

y una gestión de la red a mayor escala. En otros términos, no solo se constituye por los elementos de la propia infraestructura eléctrica, sino que también permite una gestión energética a nivel interna de los hogares, mediante la inclusión de electrodomésticos y otros dispositivos electrónicos.

2.3. DEN2NE

funcionamiento del algoritmo

[3] [36]

2.4. Big Data

El *Big Data* [28] se puede definir como el manejo y el análisis de un conjunto extremadamente grande de datos, los cuales provienen de fuentes diferentes y no correlacionadas. Debido a su complejidad y volumen, no pueden ser procesados con software o herramientas tradicionales de gestión de bases de datos y se requieren soluciones tecnológicas más avanzadas. El concepto de *Big Data* se basa en tres componentes principales, denominadas como las 5 Vs [37] [38]:

- Variedad: Hace referencia a la heterogeneidad de la información. Existen distintos tipos de datos a procesar de diferentes fuentes, formas y resoluciones. Se puede simplificar su gestión si estos son estructurados (en forma de tablas de bases de datos) o dificultar, si estos no tienen una estructura definida (en formato de texto o imagen). También, pueden ser semiestructurados (en formato JSON o XML).
- Velocidad: Es un parámetro crítico, ya que algunos entornos requieren de una toma de decisiones a tiempo real y los datos deben de ser generados, procesados y analizados rápidamente.
- Volumen: Es imprescindible tener la capacidad de gestionar una gran cantidad de datos (en el orden de los TB) que además, es creciente en el tiempo. El almacenamiento y la minería de datos deben de ser eficientes para manejárlas de forma correcta
- Veracidad: Mide la calidad y confiabilidad de la información que se adquiere. Se comprueba su autenticidad e integridad para asegurar que proviene de una fuente legítima, por lo que se deben aplicar mecanismos de seguridad como la encriptación o herramientas de detección y mitigación de ataques a la red (ver Sección 2.1.4). También, se verifica que la información no contenga errores y que sea lo más precisa posible.

- Valor: La masividad de datos introduce mucho ruido y confusión en la información y debe de seleccionarse solamente aquella de utilidad aplicando minería de datos y procesamiento adicional.

Durante los últimos años el *Big Data* se ha adoptado en multitud de sectores y campos como en las telecomunicaciones, las finanzas, el comercio, la medicina, el transporte o la investigación científica. Como se ha expuesto en los apartados anteriores (ver Sección 2.1 y en particular, 2.1.3.3) y poniendo enfoque en los objetivos de este TFM (ver Sección 1.2), el *Big Data* tiene un gran potencial en el ámbito de las SGs.

En este contexto, la efectividad del empleo de la información reside en la búsqueda de la correlación entre los datos adquiridos de la red eléctrica y el resto de características que pueden influir en los mismos, como son el comportamiento de los usuarios finales, las condiciones de estabilidad, la disponibilidad de recursos, el estado de las cargas o las condiciones climáticas en un determinado instante temporal. La coordinación de las mediciones que se realizan en la red junto con la información que se dispone del entorno es crucial para la monitorización, el control y la operativa llevada a cabo dentro de la SG. [28]

En otros términos, un análisis efectivo del *Big Data* conducirá a una buena toma de decisiones en el sistema y en consecuencia, a su optimización. Este análisis se constituye del empleo de herramientas dedicadas al procesamiento distribuido, el almacenamiento en la nube, la minería de datos y a técnicas y algoritmos de aprendizaje automático (ML).

2.4.1. Computación en nube

En la Figura 2.14 se representa la infraestructura de procesos dedicados al *Big Data* en un ámbito de SGs. Como se puede visualizar, se compone de tres capas operativas: la superior está enfocada al almacenamiento y computación de datos, la intermedia, a la gestión, compartición e integración de datos de diferentes aplicaciones o fuentes y la inferior, a todos los procesos y técnicas que se encargan del procesamiento, minería, clusterización y clasificación final. [28]

Para implementar esta infraestructura es preciso hacer uso de un entorno de computación en nube. Dentro de este contexto, las grandes tecnológicas como Google, Amazon y Microsoft han puesto sus esfuerzos en los últimos años en desarrollar y optimizar sus propios entornos de nube con el fin de integrar toda la gestión y análisis del *Big Data* en una plataforma. A modo de aportar una mayor comprensión de su funcionamiento, se representa en la Figura 2.15 un esquema de los servicios de nube disponibles.




Figura 2.14: Infraestructura de *Big Data* enfocada al ámbito de las SGs [28]




Figura 2.15: Plataforma de análisis de *Big Data* en el entorno de SGs [39]

La computación en la nube se basa en el concepto de virtualización, el cual se puede definir como la tecnología que permite la creación de diferentes entornos virtuales aislados a partir de los recursos hardware disponibles y con independencia de este. Los proveedores de servicios emplean la virtualización para crear múltiples Máquinas Virtuales (VMs) y ofrecer recursos, como pueden ser el almacenamiento, la potencia de procesamiento o las aplicaciones de la nube, como diferentes servicios virtualizados. Esto aporta las siguientes ventajas a la computación en nube [39] [40]:

- Escalabilidad: Se pueden aumentar o reducir recursos de la nube según las necesidades en cada instante temporal. Los usuarios consiguen un autoprovisionamiento de

los recursos, ya que pueden desplegar instancias virtuales cuando lo deseen de forma manual o automática.

- Flexibilidad: Se ofrecen muchas posibilidades de configuración de los servicios de la nube.
- Interoperabilidad: Se emplean Interfaces de Programación de Aplicaciones (del inglés *Application Programming Interface (API)*) para integrar plataformas y aplicaciones heterogéneas. El objetivo es soportar la comunicación entre las mismas y que se produzca una interpretación de los datos de forma correcta. Por ello, también se estandarizan los protocolos para que sean comunes.
- Seguridad: Las plataformas de servicios de nube ofrecen un gran nivel de seguridad e implementan medidas como la encriptación de los datos y restricción de acceso o de permisos. Además, el aislamiento de los recursos y de las aplicaciones en diferentes VMs permite configurar e implementar diferentes políticas de seguridad según las necesidades.
- Ahorro de costes: Se implementa un modelo de pago por uso en función de los recursos que se han consumido y se evita la inversión inicial necesaria para la instalación de una infraestructura física, además de su mantenimiento en el tiempo (CAPEX y OPEX).
- Disponibilidad: Se garantiza el acceso a los servicios y la confiabilidad de los mismos. Para ello, implementa técnicas de redundancia y aporta una buena tolerancia a fallos.

2.5. Inteligencia Artificial

La inteligencia artificial (IA) se constituye como la disciplina de diseño y creación de sistemas de software o hardware de imitación de la inteligencia humana para la realización de tareas. Generalmente, estos sistemas obtienen la capacidad de aprendizaje, razonamiento, planificación y toma de decisiones a partir del entrenamiento basado en grandes cantidades de información. En otros términos, adquieren e interpretan datos del entorno o de un contexto específico y, teniendo en cuenta un objetivo determinado, procesan la información contenida para decidir la siguiente acción a realizar. Adicionalmente, son capaces de adaptar su comportamiento ante el análisis o detección de cambios en el entorno. [41] [42]

La IA se determina como una de las tecnologías más revolucionarias y transformadoras de la actualidad y del futuro cercano por su potencial de aplicación en numerosos ámbitos.

No obstante, el origen del término se remonta al año 1956, cuando el científico John McCarthy introdujo la idea de crear máquinas inteligentes tomando como base las teorías de computación de los matemáticos Norbert Wiener y John von Neumann en los años 40. [41]

En la última década, el impulso de la IA y los grandes avances que se han producido en este campo vienen dados principalmente, por el aumento de las capacidades de los equipos informáticos y el acceso a grandes cantidades de recursos computacionales en las herramientas especializadas e infraestructuras de nube. En otros términos, se posibilita un almacenamiento masivo de datos y, en consecuencia, mejoras significativas en el desarrollo de algoritmos y técnicas, que cada vez se vuelven más complejas y precisas.

Entrando en estas técnicas, se establecen dos divisiones dentro del campo de la IA en función de la naturaleza del aprendizaje: el automático (*Machine Learning (ML)*) y el profundo (*Deep Learning (DL)*). En las siguientes Secciones (ver Secciones 2.5.1 y 2.5.2) se expondrán las características que presentan cada una de estas ramas, además de entrar en profundidad en el funcionamiento de los modelos que se emplearán en el desarrollo de este TFM.

2.5.1. Machine Learning (ML)

La rama de aprendizaje automático (*Machine Learning (ML)*) se enfoca en el desarrollo de modelos que sean capaces de aprender y tomar decisiones en base a la introducción de datos. Durante el proceso se realizan observaciones a la información existente y, en función de la técnica a emplear, se aplican algoritmos estadísticos para identificar patrones en los datos. Por lo tanto, mediante un entrenamiento progresivo en el tiempo, un modelo de ML puede llegar a realizar predicciones sobre datos futuros sin la intervención humana y con una alta precisión. Como se representa en la Figura 2.16, las técnicas de ML pueden pertenecer a tres categorías diferentes en función del enfoque de la información y de los objetivos que se pretenden conseguir con su aplicación: [43] [44] [45]

- Aprendizaje no supervisado: Se parte de datos sin etiquetar para el entrenamiento de los modelos. Es decir, se parte del conocimiento de unos datos de entrada, pero no de la salida, por lo que el objetivo de los modelos no supervisados se basa en explorar posibles patrones en los datos mediante clustering.
- Aprendizaje supervisado: Se manejan conjuntos de datos con un conocimiento de las posibles salidas, las cuales se proporcionan en forma de etiquetas o de valores numéricos. Las técnicas de aprendizaje supervisado buscan una función óptima que consiga, dadas unas determinadas variables o características de entrada, predecir la

salida con cierta precisión y son aplicables a dos tipos de problemas: de regresión, si a partir de las variables de entrada se desea predecir un valor numérico continuo a la salida, o de clasificación, si se predefinen diferentes clases y se asignan las variables de entrada a una de ellas.

- Aprendizaje por refuerzo: Las técnicas englobadas en este tipo aprenden por prueba y error, por lo que su entrenamiento a lo largo del tiempo y la experiencia permiten optimizar los resultados sin la necesidad de disponer de un gran volumen de datos.



Figura 2.16: Categorías de ML [46]

Una vez expuestas las diferentes categorías donde se engloban las técnicas de ML, es preciso indicar que se va a centrar el estudio en el aprendizaje supervisado y, en particular, en la resolución de problemas de clasificación binaria. El motivo principal viene dado porque el objetivo que se persigue con la realización de este TFM se basa en el desarrollo de modelos que permitan detectar y predecir posibles errores que se pueden producir en una SG durante el proceso de distribución energética.

Como se detallará más adelante en la Sección 3.5.1, se creará un conjunto de datos etiquetados en función de la existencia de error o no para entrenar los modelos. Teniendo en cuenta esto, a continuación, se incluyen dos Secciones (ver Secciones 2.5.1.2 y 2.5.1.1) para

presentar el funcionamiento de las dos técnicas de ML que se desarrollarán posteriormente.

2.5.1.1. Random Forest (RF)

El modelo de Bosques Aleatorios (del inglés *Random Forest* (RF)) está fundamentado en la aplicación de un conjunto de árboles de decisión. Cada uno de estos árboles se definen como estimadores y crecen mediante un proceso de entrenamiento sobre un subconjunto de datos extraído de forma aleatoria del conjunto completo. A la salida del esquema de estimadores se obtiene una predicción final basada en la votación mayoritaria de los árboles. No obstante, es un método que se puede emplear también en problemas de regresión y, en este caso, se proporcionaría un valor numérico promedio, calculado a partir de todas las salidas. En la Figura 2.17 se representa de forma gráfica el diagrama de flujo que expone el funcionamiento del modelo. [47]




Figura 2.17: Modelo RF [47]

El proceso de construcción de los árboles de decisión se constituye por operaciones de división que van formando nodos y ramificaciones de forma iterativa. El objetivo es lograr la mayor ganancia de información posible a través de la valoración de la importancia que presentan cada una de las características del conjunto de datos. Es decir, en cada nodo del árbol se cuantifica la ganancia de información que presenta cada característica

y, después, se selecciona la que tenga el mayor valor para dividir los datos existentes en dos subconjuntos homogéneos de menor tamaño. Este proceso se va repitiendo en todos los nodos hasta llegar al final del árbol. [48]

En cuanto al cálculo de la ganancia de información, es preciso introducir el concepto de impureza. Este se define como el procedimiento de evaluación de la calidad de las divisiones que se producen en los nodos. En otros términos, se puede expresar que indica el nivel de ruido que hay en los datos de los subconjuntos creados. Principalmente, se pueden emplear dos métodos de medición de la impureza: [48]

- Entropía: Mide la incertidumbre que proporciona un conjunto de datos, teniendo un mayor valor cuanto mayor sea la incertidumbre calculada.
- Índice Gini

2.5.1.2. Support Vector Machines (SVM)

El modelo de Máquinas de Vector Soporte (del inglés *Support Vector Machine* (SVM)) es una técnica que se emplea tanto en problemas de regresión como de clasificación. Se basa en el concepto del *Maximal Margin Classifier* o *Hard Margin Classifier*, puesto que tiene el fin principal de encontrar el hiperplano óptimo que consiga una máxima separación entre dos clases diferentes dentro de un espacio de características. Esta separación se define como margen y se mide como la distancia perpendicular que existe desde el hiperplano hacia los vectores de soporte, que son las muestras más cercanas a la frontera de separación de clases. En la Figura 2.18 se representa el cálculo del mejor hiperplano entre dos clases de datos. [49] [50]

Por ello, se puede expresar que los vectores de soporte son los puntos más críticos del plano para asignar una de las clases predefinidas a los nuevos vectores de datos a la entrada. Este proceso de clasificación viene dado por la siguiente expresión: [51]

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq M$$

Donde:

y_i es la etiqueta de la clase.

x_i es el vector de características.

w es el vector de pesos o coeficientes del hiperplano.

b es el sesgo ajustado en el modelo.




Figura 2.18: Cuantificación del hiperplano óptimo entre dos clases en el SVM [49]

M es el ancho definido para el margen.

No obstante, en la práctica es complicado determinar un hiperplano si no se trata de un problema ideal y basado en datos linearmente separables. Generalmente, en los casos reales si se intenta forzar un máximo margen, se pueden llegar a producir problemas de sobreentrenamiento, ya que nuevos datos pueden suponer grandes variaciones en el hiperplano. En la Figura 2.19 se representa la opción alternativa que se lleva a cabo en la mayoría de los casos, basada en obtener un margen máximo, permitiendo cierto grado de error (*Soft Margin Classifier*). [52] [50]

Esto tiene como consecuencia que existan una serie de vectores clasificados de forma errónea en el plano. En este proceso se introduce el concepto de variables de holgura (*slack variables*) a partir de la siguiente expresión:

$$\xi_i = \max(0, 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b))$$

Estas variables determinan si un vector está correctamente clasificado o si se encuentra en una zona errónea del margen o del hiperplano, respectivamente. En el caso de posición incorrecta, el valor de la variable define la distancia al margen o el error cometido:

$$\begin{aligned}\xi_i &= 0 && \text{si } 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \leq 0 \\ 0 < \xi_i &< 1 && \text{si } 0 < 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \leq 1 \\ \xi_i &> 1 && \text{si } 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b) > 1\end{aligned}$$




Figura 2.19: Representación de vectores clasificados erróneamente dentro de los márgenes establecidos en el SVM [51]

El sumatorio de todas las variables de holgura que existen en el plano vienen incluidas en el objetivo de la función de pérdida del modelo para que el error de clasificación sea mínimo, a la vez que el margen es máximo. Como es preciso encontrar un cierto equilibrio entre ambos, el SVM se determina como una técnica de optimización convexa que se fundamenta en el hiperparámetro C . En la Figura 2.20 se representa de forma gráfica cómo su valor establece el control de forma inversamente proporcional de la cantidad de muestras clasificadas erróneamente, por lo que se define como el parámetro de regularización del modelo. Es decir, cuanto más alto sea su valor, menores violaciones del margen y del hiperplano serán permitidas y más se enfocará el modelo en un *Maximal Margin Classifier*. [50]

Para enfrentar problemas con datos no linearmente separables, además de permitir cierto grado de error, como se ha expuesto anteriormente, es imprescindible incrementar las dimensiones del espacio original de características. En este caso se introduce el concepto de kernel como función para obtener un nuevo espacio dimensional diferente al original donde exista una mayor probabilidad de que los datos sean linearmente separables. La aplicación de los diferentes tipos de kernels se caracterizan por las siguientes expresiones: [50] [53]




Figura 2.20: Configuración del parámetro de regularización C [53]

Kernel lineal:	$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
Kernel polinómico:	$K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i \cdot \mathbf{x}_j + r)^d$
Kernel radial o gaussiano:	$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \ \mathbf{x}_i - \mathbf{x}_j\ ^2)$
Kernel sigmoid:	$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\gamma \mathbf{x}_i \cdot \mathbf{x}_j + r)$

De forma adicional, en la Figura 2.21 se representa cómo se produce la transformación dimensional de las características para el caso del kernel gaussiano o *Radial Basis Function* (RBF).




Figura 2.21: Aplicación del kernel RBF [54]

2.5.2. Deep Learning (DL)

El campo del aprendizaje profundo (*Deep Learning (DL)*) se enfoca principalmente en la creación de redes neuronales que imiten el comportamiento y la estructura lógica que tiene el cerebro humano para buscar patrones en los datos. A diferencia de las técnicas de ML, el DL se vuelve más eficiente en el análisis de grandes volúmenes de datos, puesto que el ML presenta ciertas limitaciones en este aspecto. [46]

De la misma forma, el DL presenta un mejor funcionamiento en la identificación de patrones cuando se manejan características complejas, aportando resultados con una mayor precisión que el ML. Es por ello que las técnicas de DL cobran una gran importancia en entornos donde los datos no son estructurados, como se produce en el caso de las imágenes, texto y audio. En este caso se pueden introducir en aplicaciones de reconocimiento de voz, procesado de lenguaje natural (*Natural Language Processing (NLP)*) o visión artificial para la detección de objetos y clasificación de imágenes. [44]

Por otro lado, a nivel estructural las diferencias entre las técnicas de ML y las de DL radican principalmente en el tratamiento de las características o variables de los datos. En el caso de emplear ML, si se manejan conjuntos con un gran número de características, sería necesario introducir un paso previo de diseño y selección de las más relevantes. Esto, como se puede apreciar en la Figura 2.23, no ocurre en el desarrollo de un modelo de DL, ya que el tratamiento se produce internamente dentro de la red reурonal. [55]




Figura 2.22: Diferencias estructurales entre el ML y el DL [55]

Una vez definida la rama de aprendizaje profundo, además de presentar las diferencias que presenta respecto a la de aprendizaje automático, se introduce una Sección dedicada a la exposición del modelo de DL que se desarrollará como motivo del objetivo de este TFM (ver Sección 2.5.2.1).

2.5.2.1. Red Neuronal Artificial (ANN)

Las redes neuronales artificiales (*Artificial Neural Network (ANN)*)




Figura 2.23: Arquitectura de una ANN [56]

[2]

2.6. Herramientas software

2.6.1. BRITE

BRITE [4] se presenta como una plataforma dedicada a la generación de topologías de red. Fue desarrollada en la Universidad de Boston y se caracteriza por su gran flexibilidad, ya que enfoca su arquitectura en el concepto de modelo topológico. Es decir, soporta varios modelos diferentes y cada uno de ellos viene determinado por los parámetros de entrada que se definen. Es por ello que BRITE sigue la siguiente secuencia de acciones para diseñar las topologías:

1. Definición del posicionamiento de los nodos:

2. Nivel de Interconexión de los nodos y configuración de enlaces:
3. Asignación de atributos y características de la red y de los dispositivos: Se determina el delay y el ancho de banda de los enlaces.
4. Especificación del formato de salida: Se indica un formato .brite para todas las topologías generadas.

En la Sección 3.4 se definirán las acciones realizadas con esta herramienta en el caso de este TFM. Por otro lado, con el motivo de facilitar el empleo de BRITE, se incluirá una Sección dedicada al proceso de instalación, configuración y ejecución en el Anexo correspondiente a los manuales de usuario (ver Sección C.1). Se podrá acceder a más información desde el repositorio¹ del equipo de investigación NetIS de la UAH.

2.6.1.1. Definición de topologías

La herramienta BRITE basa el proceso de creación de topologías en la definición de los siguientes parámetros de entrada en un fichero con formato .conf:

- *Name*: Modelo de la topología.
- *N*: Número de nodos de la topología.
- *HS* y *LS*: Dimensiones del plano. Respectivamente, hacen referencia a la longitud total del plano cuadrado y al tamaño de los cuadros interiores.
- *Node Placement*: Posicionamiento de los nodos. Se puede producir de forma totalmente aleatoria o creando zonas a lo largo del plano con mayor concentración de nodos.
- *Growth Type*: Método de introducción de los nodos en la topología. Se puede realizar este proceso de forma incremental (uno a uno) o de forma aleatoria (todos a la vez).
- *m*: Número de enlaces por nodo o número de nodos vecinos a los que se conectará un nuevo nodo al unirse a la red. BRITE puede crear enlaces unidireccionales o bidireccionales y, respectivamente, la topología generada tendría un grado *m* o *2m*.
- *Alpha, Beta*: Parámetros específicos para topologías basadas en el modelo Waxman.
- *BWDist, BWMin, BWMax*: Ancho de banda de los enlaces.

¹<https://github.com/NETSERV-UAH/BRITE>

2.6.1.2. Modelos de topologías

Como se ha introducido, con BRITE se posibilita el uso de múltiples modelos para crear topologías. En la Figura 2.24 se representan todos los que soporta la herramienta. No obstante, este TFM se va a enfocar en la generación de topologías a nivel de router, como son los modelos Router Waxman y Router Barabasi-Albert.




Figura 2.24: Modelos soportados por BRITE [4]

En el caso del Router Waxman, como su nombre indica, emplea un modelo de probabilidad Waxman para establecer la Interconexión de los nodos en la topología [57]:

$$P_{\text{Waxman}}(u, v) = \alpha \cdot e^{-\frac{d}{\beta \cdot L}} \quad (2.1)$$

Donde:

$P(u, v)$ es la probabilidad en función de la distancia euclíadiana entre un nodo u y un nodo v de la red.

α es un parámetro específico del modelo que hace referencia a la densidad de enlaces y toma generalmente un valor igual a 0.2.

β es un parámetro específico del modelo que hace referencia al ratio enlaces largos/enlaces cortos en la topología y toma generalmente un valor igual a 0.15.

L es la máxima distancia entre dos nodos cualesquiera.

Por otro lado, el modelo Router Barabasi-Albert está basado en la generación de topologías con un incremento exponencial del número de nodos a lo largo del tiempo. Además,

se permite una conexión preferencial, suponiendo que cuanto mayor grado de conectividad abarque un nodo, mayor será la probabilidad de que este añada nuevos enlaces.

Por lo tanto, el plano de la topología comienza con un número de nodos inicial N_0 y se van añadiendo los demás uno a uno. Cada uno de estos nuevos nodos se conectarán a N nodos ya añadidos a la topología con una probabilidad [57]:

$$P_{\text{Barabási-Albert}}(k_i) = \frac{k_i}{\sum_j k_j} \quad (2.2)$$

Donde:

$P(k)$ es la probabilidad de conexión del nodo i con grado k .

$\sum_j k_j$ es el sumatorio de los grados de todos los nodos de la topología.

2.6.1.3. Automatización de la ejecución

A modo de facilitar la ejecución de la herramienta BRITE se aporta en el repositorio el fichero de python *generador_brite.py*, dedicado a la automatización del proceso de creación de un fichero de configuración. Este recibirá los parámetros de entrada que caracterizarán a la topología a generar (ver Sección 2.6.1.1) y escribirá el nuevo fichero.

También, se añade el fichero de python *parser.py*, que se encargará de definir la función de transformación del archivo de salida proporcionado por BRITE (en formato .brite) en dos nuevos ficheros: *Nodos.txt* y *Enlaces.txt*. Respectivamente, estos almacenarán las posiciones x e y de los nodos en el plano y la información sobre las distancias y los identificadores de los nodos que se interconectan con cada enlace. Este funcionamiento se muestra de forma gráfica en la Figura 2.25.




Figura 2.25: Esquema de funcionamiento de BRITE y del *parser* [3]

Teniendo en cuenta los ficheros anteriores, se proporciona un script *autogenerador.sh* donde se incluyen todas sus funcionalidades y se automatiza todo el proceso de ejecución de la herramienta. Este script sigue la siguiente secuencia de pasos:

1. Define los valores de cada uno de los parámetros de entrada.
2. Ejecuta el fichero de python *generador_brite.py* aplicando los parámetros definidos para el modelo Waxman y Barabasi.
3. Genera 10 topologías diferentes para cada archivo de configuración a partir de 10 ficheros de semillas (*seed_files*) dados en el repositorio. Esto posibilita la generación de 10 topologías totalmente diferentes para cada escenario de red definido (a partir de unos mismos parámetros de entrada).
4. Se aplica un bucle en función del número de semilla:
 - a) Crea el directorio para cada escenario y se ejecuta la herramienta BRITE sobre cada uno.
 - b) Se ejecuta *parser.py* para obtener a la salida los ficheros *Nodos.txt* y *Enlaces.txt* de cada uno de los escenarios.

2.6.1.4. Graficación de topologías

3. Diseño y análisis de datos

Este Capítulo abordará la fase del TFM que se centra en el análisis, diseño y procesado de las fuentes de datos para lograr el objetivo principal de generar un dataset final que suponga la base del entrenamiento y el desarrollo de los modelos de ML que se plantearán en el Capítulo 4. Se abrirá el Capítulo con una Sección enfocada al estudio de la disponibilidad de fuentes de datos de implementaciones reales de SGs. Por ello, será imprescindible llevar a cabo una investigación exhaustiva y un posterior análisis de su utilidad en referencia a las necesidades que presenta este TFM (ver Sección 3.1).

Por consiguiente, se añadirá una Sección en referencia al estudio de la generación energética (ver Sección 3.2). Esta vendrá justificada por la necesidad de realizar un análisis sobre algunas herramientas de simulación existentes que proporcionan datos de potencia. Este proceso posibilitará obtener información adicional sobre los recursos solares y las condiciones climáticas de una ubicación determinada. Una vez expuestas y seleccionadas las fuentes de datos que sevirán como base para el desarrollo de este TFM, se añadirá una Sección dedicada a la definición detallada de las acciones que serán necesarias para llevar a cabo un procesamiento exhaustivo de toda la información recopilada (ver Sección 3.3).

Después, siguiendo las especificaciones expuestas anteriormente en la Sección 2.6.1, se plantearán una serie de escenarios mediante la generación de múltiples topologías con la herramienta BRITE (ver Sección 3.4). Los resultados que se obtengan a partir de ella se constituirán como la base sobre la que se realizarán las simulaciones en el algoritmo DEN2NE. En esta Sección (ver Sección 3.5.1) será preciso detallar las modificaciones y ajustes a implementar en el algoritmo. Esto permitirá extraer a la salida del mismo el conjunto de datos final sobre el que se entrenarán los modelos de ML.

3.1. Análisis de los datasets disponibles

En ámbitos como el Procesado de Lenguaje Natural (del inglés NLP) o el reconocimiento facial, la disponibilidad de numerosas fuentes de datos ha sido imprescindible para acelerar el desarrollo de técnicas de minería de datos y de aprendizaje automático (ML).

A diferencia de estos campos, el contexto energético experimenta un menor grado de

disponibilidad de datasets. La protección de la privacidad de los usuarios en el proceso de medición y análisis de su comportamiento energético supone que exista un menor número de datasets públicos enfocados a implementaciones reales. No obstante, la búsqueda de la optimización de la distribución energética y de la reducción del consumo de los usuarios, aparte de otras motivaciones ambientales, ha instado en los últimos años a múltiples ingenieros y científicos a lo largo del mundo a crear datasets públicos enfocados a la investigación (ver Tabla 3.1).

En este contexto han cobrado gran importancia las técnicas de Monitorización de Cargas no Intrusiva (del inglés *Non-Intrusive Load Monitoring* (NILM)). Como se ha introducido en la Sección 2.2.1, cada vez se produce una mayor integración de las tecnologías de IoT en el ámbito de las SGs para obtener una mayor monitorización del comportamiento energético en los hogares. Es por ello que el fin principal de las técnicas de NILM reside en establecer una desagregación energética para poder estimar de una forma precisa el consumo individual de cada uno de los dispositivos y electrodomésticos que hay en una vivienda. Para ello, se instalan medidores en cada circuito y después, se analizan, tanto a nivel interno como a nivel externo de la vivienda, los cambios de los parámetros eléctricos en cada instante temporal. [58] [59]

Teniendo esto en cuenta, se puede expresar que las técnicas de NILM se caracterizan por su bajo coste y por su facilidad y flexibilidad de despliegue. No obstante, el proceso de medición y recolección de datos puede llegar a requerir mucho tiempo y esfuerzo. Por ello, en el contexto de la investigación es importante que los datos tengan una disponibilidad pública para progresar en el desarrollo de técnicas de minería de datos y de aprendizaje automático en el ámbito energético.

En la Tabla 3.1 se exponen los múltiples datasets residenciales que han sido estudiados en esta fase de diseño, junto con información relativa a la implementación real sobre la que se ha basado cada uno de ellos, como es la ubicación de la misma, el número de viviendas total, el lapso temporal que comprende el despliegue, la frecuencia de las muestras tomadas y los parámetros eléctricos medidos. En virtud de las motivaciones y objetivos del presente TFM, es importante tener en cuenta ciertos requisitos para evaluar los conjuntos de datos disponibles y seleccionar el más apropiado:

- **Cantidad:** En primera instancia, es imprescindible revisar la cantidad de datos que aporta cada conjunto. En otros términos, para llevar a cabo un análisis estadístico del comportamiento energético de una ubicación se requiere partir de un conjunto de datos que agrupe las mediciones de un gran número de edificios residenciales. Adicionalmente, este análisis debe comprender extensos períodos temporales de me-

dición para visualizar de forma correcta el comportamiento de los usuarios y predecir patrones de consumo a lo largo del tiempo.

- Calidad: Se debe evaluar la calidad de los datos recogidos, la cual responde en parte con la resolución de las medidas que se toman. Como se puede observar en la Tabla 3.1, algunos datasets como *REDD* y *BLUED* se centran en monitorizar los edificios residenciales a una frecuencia de muestreo alta. En el contexto de las tecnologías de NILM, esto aporta una vista más representativa del comportamiento energético a nivel interno en una vivienda y permite una desagregación energética más precisa. Por lo tanto, cuanto mayor sea la frecuencia de adquisición de medidas, mayor será la resolucion de los datos.
- Ubicación: En términos de la ubicación de la implementación real sobre la que se han adquirido las mediciones, es de importancia conocer a la hora de analizar los datos las diferencias de voltaje que se manejan en cada país. Por ejemplo, en el caso de datasets como *BLUED* o *Smart**, los cuales provienen de ciudades de Estados Unidos, trabajarán a tensiones menores de 120V, mientras que otros como *ECO* o *GREEND*, cuyos datos se han adquirido en países europeos, lo harán con tensiones de hasta 230V. [59] [60]
- Parametrización: Por lo general, un dataset dedicado a las tecnologías de NILM estará constituido por una colección de muestras de voltaje (V), corriente (I) y potencia activa (P), reactiva (Q) y aparente (S). Cada una de estas muestras vendrá asociada a una marca de tiempo y a un identificador que haga referencia a la vivienda o medidores a los que corresponde. Adicionalmente, algunos de los datasets que se exponen en la Tabla 3.1, como son *HUE* o *SustDataED*, también incluyen información relativa a parámetros ambientales. Esto, sobre todo en el contexto de las SGs, proporciona información fundamental sobre el impacto de las condiciones climáticas en el comportamiento de los usuarios.
- Generación fotovoltaica: Considerando el contexto de SGs en el que se engloba este TFM, es de vital importancia seleccionar un conjunto de datos que aporte información relativa a la generación de energía a través de fuentes renovables, como ocurre en el caso de *Smart** o *SustDataED*. En relación con esto, se expondrá en la Sección 3.2 el estudio de una plataforma específica dedicada a la adquisición de datos de generación energética.

Nombre	Localización	Nº de residencias	Período de medición (días)	Resolución de medida	Parámetros
<i>AMPds2</i> [61]	Vancouver (Canadá)	1	730	1min	I, V, P, S, F, pf
<i>BLUED</i> [62]	Pittsburg (Estados Unidos)	1	8	12KHz	I, V, eventos de switch
<i>ECO</i> [63]	Thun (Suiza)	6	244	1Hz	P
<i>GREEND</i> [59]	Italia y Austria	9	310	1Hz	P
<i>HUE</i> [64]	British Columbia, Canada	28	60	1Hz	P
<i>iAWE</i> [65]	Nueva Delhi (India)	1	73	1Hz	V, I, P, S
<i>REDD</i> [66]	Boston (Estados Unidos)	6	119	15KHz	I, V, P
<i>Smart*</i> [67]	Massachussets (Estados Unidos)	3	90	1min	P, S, V, I
<i>SustDataED</i> [68]	Madeira (Portugal)	50	1144	1min	I, V, P, Q, S
<i>UK-DALE</i> [69]	Reino Unido	5	499	16KHz	P, estado de switch

Tabla 3.1: Comparación entre datasets públicos en el ámbito NILM [59] [70] [71] [60]

Como se ha introducido en el Capítulo 1, el objetivo principal que se pretende con este TFM es desarrollar técnicas de ML para identificar y predecir de forma precisa los errores que se pueden producir en una SG durante el proceso de distribución energética. A partir de ello, se expresa la necesidad de seleccionar un conjunto de datos en el que se pueda analizar el comportamiento de múltiples usuarios, tanto de consumo como de producción, durante un extenso período de tiempo.

De igual manera, es importante que las muestras tengan una buena resolución y que proporcione información en cada instante sobre las condiciones climáticas de la ubicación donde se encuentran las viviendas. Bajo las premisas anteriores, se ha finalizado el proceso de estudio y análisis de los diferentes conjuntos de datos llegando a la conclusión de que el dataset más adecuado a emplear en este TFM es *SustDataED*.

3.1.1. ***SustDataED***

El dataset *SustDataED* [68] es creado a partir del proyecto de investigación *Sustainable Interactions with Social Networks, context Awareness and Innovative Services* (SINAIS), dedicado al diseño, implementación y despliegue de sistemas NILM de bajo coste. Surge con el objetivo de proporcionar una retroalimentación ecológica a los usuarios para fomentar un comportamiento energético sostenible y un mayor uso de las fuentes de energía renovables.

El dataset *SustDataED* engloba cinco años de datos de consumo y producción energética de 50 hogares de la ciudad de Funchal (Madeira, Portugal) con una resolución o frecuencia de adquisición de nuevas muestras por minuto. Debido a esto, se caracteriza por comprender una gran cantidad de información eléctrica que tendrá que ser posteriormente procesada de forma exhaustiva (ver Sección 3.3).

Pese a la necesidad de procesamiento que conlleva, el uso de *SustDataED* en el presente TFM brinda ciertas ventajas. Entre otras, aporta un gran perspectiva del comportamiento eléctrico a largo plazo de múltiples hogares con diferentes características y ofrece un enfoque medioambiental, ya que mediante la adquisición de los datos relativos a las condiciones climáticas posibilita el análisis de la correlación de las mismas con el consumo de los usuarios y la producción de energía.

3.1.2. **Estructura del dataset *SustDataED***

El proceso de adquisición y recolección de los datos de los 50 hogares que constituyen el dataset se divide en cuatro despliegues diferentes (ver Figura 3.1):

- Los despliegues 1 y 2 se pueden tratar en conjunto, ya que abarcan las mismas viviendas, suponiendo un total de 23. El despliegue 1 se inicia en julio de 2010 y

finaliza en el mes de noviembre de ese mismo año cuando se reinstala una versión revisada del sistema de realimentación. En este momento, comienza el despliegue 2, que durará hasta abril del 2012.

- El despliegue 3 se implementa en un total de 17 hogares desde el mes de agosto de 2012 hasta enero de 2013. Se introducen novedades en el sistema de adquisición de datos para reducir el número de sensores a instalar, optimizando la arquitectura de monitorización.
- El despliegue 4 es el último que se realiza y consta de la agrupación de medidas de 10 hogares, comenzando la recolección de datos de los mismos en el mes de julio de 2013 y finalizando en marzo de 2014.

En la Figura 3.1 se representan gráficamente los períodos temporales que abarcan los despliegos expuestos anteriormente mediante el empleo de la librería de *Python*, *matplotlib*. Además, como se puede apreciar, cada uno de los 50 hogares participantes supone un identificador único (*id*).

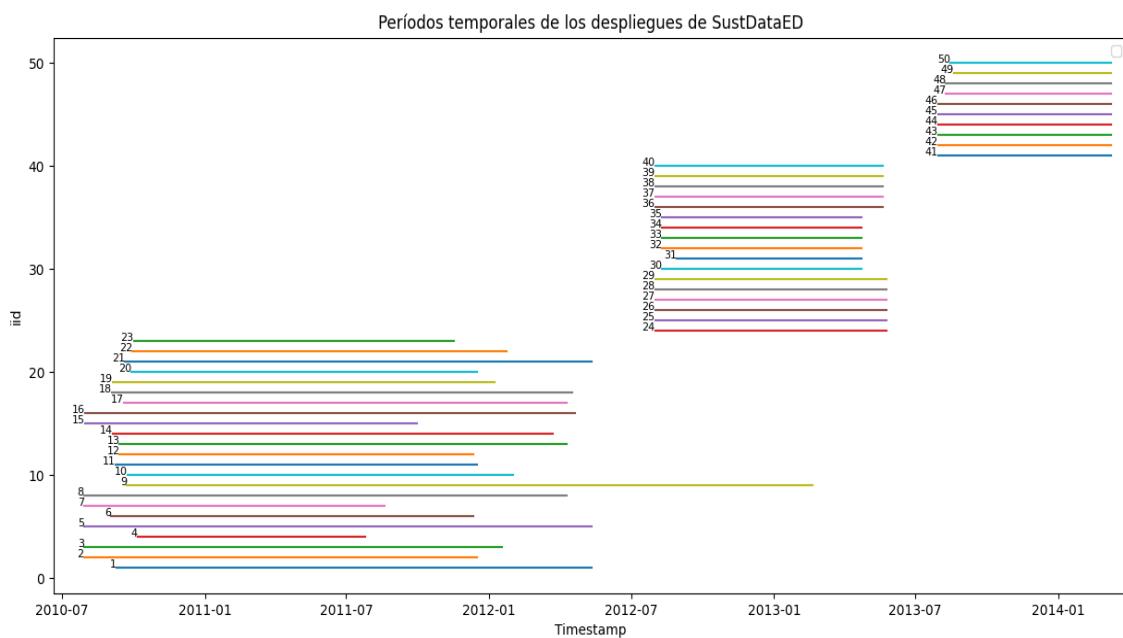


Figura 3.1: Representación del período temporal que comprende el proceso de recolección de datos para cada hogar

A continuación, se detallará a modo organizativo, cómo el dataset *SustDataED* clasifica en varias tablas los datos en función del tipo de información al que se hace referencia.

3.1.2.1. Medidas de consumo de energía

En la Tabla 3.2 se listan los campos que han sido definidos para la recolección de medidas de consumo de cada uno de los hogares. El dataset asocia los parámetros eléctricos a dos identificadores: uno para describir la vivienda de la que se están recogiendo los datos, y otro, para el despliegue al que pertenece.

Por otro lado, se almacena para cada medida una marca de tiempo con la fecha, hora, minuto y segundo en la que se ha recogido la información y se incluye el parámetro *miss_flag* para indicar si para un determinado instante temporal se han adquirido datos de forma incorrecta, suponiendo filas vacías en el dataset.

Campo	Descripción	Unidades
<i>home_id</i>	Identificador de vivienda monitorizada	-
<i>timestamp</i>	Instante temporal de medida	datetime
<i>deploy</i>	Identificador del despliegue	-
<i>Imin</i>	Corriente mínima	A
<i>Imax</i>	Corriente máxima	A
<i>Iavg</i>	Corriente media	A
<i>Vmin</i>	Tensión mínima	V
<i>Vmax</i>	Tensión máxima	V
<i>Vavg</i>	Tensión media	V
<i>Pmin</i>	Potencia activa mínima	W
<i>Pmax</i>	Potencia activa máxima	W
<i>Pavg</i>	Potencia activa media	W
<i>Qmin</i>	Potencia reactiva mínima	VAR
<i>Qmax</i>	Potencia reactiva máxima	VAR
<i>Qavg</i>	Potencia reactiva media	VAR
<i>Smin</i>	Potencia aparente mínima	VA
<i>Smax</i>	Potencia aparente máxima	VA
<i>Savg</i>	Potencia aparente media	VA
<i>PFmin</i>	Factor de potencia mínimo	-
<i>PFmax</i>	Factor de potencia máximo	-
<i>PFavg</i>	Factor de potencia medio	-
<i>miss_flag</i>	Flag de valores vacíos	-

Tabla 3.2: Tabla de medidas de consumo energético [68]

Los parámetros de tensión (V) y corriente (I) se muestrean continuamente a una frecuencia de 8KHz y las medidas de potencia activa (P), reactiva (Q) y aparente (S) se cuantifican a un ratio de 50 muestras por segundo a partir de las siguientes expresiones [68]:

$$S = I_{\text{RMS}} \cdot V_{\text{RMS}}$$

$$P = S \cdot \cos(\phi)$$

$$Q = S \cdot \sin(\phi)$$

Donde:

I_{RMS} es la corriente eficaz (RMS).

V_{RMS} es el voltaje eficaz (RMS).

ϕ es el ángulo de fase entre la corriente y el voltaje instantáneos.

No obstante, como se había introducido en el Apartado 3.1.1 y se había definido en la Tabla 3.1, todas estas medidas, una vez son recogidas, se almacenan en el dataset a una resolución de una muestra por minuto. Se introduce también en la Tabla 3.2 el valor de factor de potencia (PF) para medir la eficiencia del uso de energía en un sistema eléctrico. Se cuantifica a partir de la razón entre la potencia activa (P) y la potencia aparente (S), siendo ideal un valor de 1.

3.1.2.2. Medidas de eventos de potencia

La información sobre los eventos de potencia se extrae de las medidas en crudo de potencia activa que, como se ha expresado en el apartado anterior, se producen a una frecuencia de muestreo de 50Hz. La Tabla 3.3 se dedica al proceso de detección de dichos eventos o, en otros términos, de identificación de cambios en la carga total de una vivienda. Como se ha introducido en la Sección 3.1, estos datos serían de gran utilidad en el caso de requerirse el empleo de técnicas de NILM.

El proceso de recolección de las muestras tiene como base un método estadístico que calcula la probabilidad de que se produzca un cambio del valor de potencia media entre dos instantes. Para ello, el algoritmo trabaja con dos ventanas temporales: una de detección, que cuantifica la probabilidad del cambio en una muestra determinada y otra de búsqueda de los valores mínimos y máximos de potencia, que define las posiciones de los eventos en la señal de potencia agregada. En referencia a esto, viene definido un cambio mínimo de potencia real de 30 W.

Campo	Descripción	Unidades
<i>home_id</i>	Identificador de vivienda monitorizada	-
<i>timestamp</i>	Instante temporal de medida	datetime
<i>deploy</i>	Identificador del despliegue	-
<i>delta_P</i>	Cambio real de potencia activa	W
<i>delta_Q</i>	Cambio real de potencia reactiva	VA
<i>trace_P</i>	Traza real de potencia activa del evento	W
<i>trace_Q</i>	Traza real de potencia reactiva del evento	VAR

Tabla 3.3: Tabla de medidas de eventos de potencia [68]

3.1.2.3. Medidas demográficas

Para el análisis del comportamiento eléctrico de cada uno de los hogares monitorizados se puede visualizar en la Tabla 3.4 cómo se almacena la información respectiva a sus inquilinos y a los períodos temporales de adquisición de datos de cada vivienda.

Campo	Descripción	Unidades
<i>home_id</i>	Identificador de vivienda monitorizada	-
<i>building_id</i>	Identificador de edificio	-
<i>begin_monitoring</i>	Fecha de inicio de medición	datetime
<i>end_monitoring</i>	Fecha de fin de medición	datetime
<i>begin_feedback</i>	Fecha de inicio de realimentación en el despliegue	datetime
<i>end_feedback</i>	Fecha de fin de realimentación en el despliegue	datetime
<i>type</i>	Tipo de vivienda	-
<i>bedrooms</i>	Número de habitaciones	-
<i>adults</i>	Número de adultos inquilinos	-
<i>children</i>	Número de niños inquilinos	-
<i>contracted_power</i>	Potencia contratada	kWh

Tabla 3.4: Tabla de medidas de producción de energía [68]

De forma adicional, el dataset *SustDataED* incluye otra tabla con datos complementarios sobre las personas participantes en los despliegues, como son el género, edad, educación y ocupación.

3.1.2.4. Medidas de producción de energía

El dataset *SustDataED* recoge a nivel global los datos respectivos a la producción de electricidad en intervalos de 15 minutos. La energía generada se desagrega según su fuente de procedencia, dando protagonismo a las fuentes renovables. En la Tabla 3.5 se indican los campos que han sido definidos para cuantificar las medidas. Adicionalmente, en la

Figura 3.2 se representan gráficamente los valores recogidos en el dataset a lo largo del tiempo para cada una de las fuentes de energía dadas. En este caso se emplea la librería de *Python matplotlib*.

Campo	Descripción	Unidades
<i>timestamp</i>	Instante temporal de medida	datetime
<i>total</i>	Producción total	MWh
<i>thermal</i>	Electricidad producida por fuentes térmicas	MWh
<i>hydro</i>	Electricidad producida por fuentes hidroeléctricas	MWh
<i>eolic</i>	Electricidad producida por fuentes eólicas	MWh
<i>biomass</i>	Electricidad producida por fuentes orgánicas	MWh
<i>solar</i>	Electricidad producida por fuentes fotovoltaicas	MWh

Tabla 3.5: Tabla de medidas de producción de energía [68]

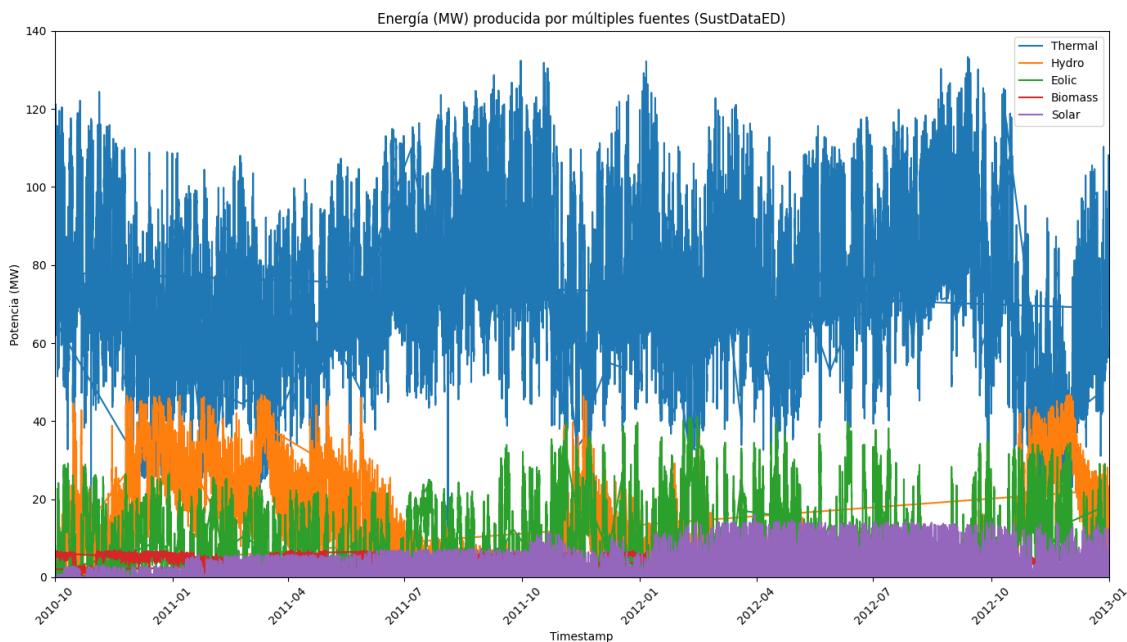


Figura 3.2: Gráfica de valores de múltiples fuentes energéticas (*SustDataED*)

3.1.2.5. Medidas de eventos de usuario

Una de las ventajas que proporciona la monitorización del comportamiento eléctrico de un hogar es la realimentación de la información que se produce hacia los mismos usuarios. El dataset recoge en forma de eventos las interacciones que se llevan a cabo con este

sistema de realimentación a través de los campos determinados en la Tabla 3.6.

Campo	Descripción	Unidades
<i>home_id</i>	Identificador de vivienda monitorizada	-
<i>timestamp</i>	Instante temporal de medida	datetime
<i>deploy</i>	Identificador del despliegue	-
<i>type</i>	Tipo de interacción	-
<i>view_id</i>	Identificador de pantalla de visualización	-
<i>view_name</i>	Nombre de pantalla de visualización	-

Tabla 3.6: Tabla de medidas de eventos de usuario [68]

3.1.2.6. Medidas de condiciones ambientales y climáticas

Como se ha introducido al comienzo de la Sección 3.1.1, el dataset aporta un enfoque medioambiental a los procesos de consumo y producción energética al incluir la recolección de los datos relativos a las condiciones climáticas que se dan en cada instante. En la Tabla 3.7 se muestran los parámetros que se tienen en cuenta en las mediciones. Se incluye un campo dedicado a los eventos climáticos, que aporta información adicional cuando se produce un suceso metereológico determinado.

Campo	Descripción	Unidades
<i>timestamp</i>	Instante temporal de medida	datetime
<i>temperature</i>	Temperatura exterior	°C
<i>humidity</i>	Humedad relativa	%
<i>pressure</i>	Presión relativa	hPa
<i>wind_dir</i>	Dirección del viento	-
<i>wind_speed</i>	Velocidad del viento	kmh
<i>precipitation</i>	Niveles de precipitación	mm
<i>events</i>	Eventos relevantes	-
<i>conditions</i>	Condiciones del cielo	-

Tabla 3.7: Tabla de medidas de condiciones ambientales [68]

3.1.3. Conclusiones del análisis del dataset *SustDataED*

Una vez realizado el estudio y el análisis en profundidad de los datos proporcionados por el dataset *SustDataED*, se definen una serie de conclusiones a tener en cuenta antes de iniciar la fase de preprocesamiento de los datos. Por ello, considerando las motivaciones de la realización de este TFM, se puede expresar que la utilidad que proporciona el

dataset *SustDataED* viene dada principalmente por el uso de las medidas de consumo, de producción y de las condiciones ambientales (ver Tablas 3.2, 3.5 y 3.7).

El procesamiento que será requerido para estos datos se detallará en la Sección 3.3. No obstante, es importante incidir en las características de los datos de producción eléctrica dados por *SustDataED*. Como se ha expuesto anteriormente en la Sección 3.1.2.4, el dataset proporciona esta información en términos globales y después, desagrega los valores energéticos según su fuente de procedencia. Por lo tanto, en la Sección 3.3.2 de este documento se detallará cómo será imprescindible determinar si estos datos son precisos y evaluar su utilidad específicamente en un entorno de SGs como motivo de los objetivos de este TFM.

Por otro lado, en cuanto a los eventos de potencia (ver Tabla 3.3), como este TFM no se basa en el diseño de técnicas NILM, ni se pretende establecer una desagregación de potencia a nivel interno de una vivienda, se expone este tipo de datos únicamente a modo de estudio. De la misma forma, sucede en el caso de los eventos de usuario (ver Tabla 3.6), los cuales no proporcionan información de utilidad que sea necesaria de procesar en la siguiente fase.

3.2. Simulación de datos de producción

Como se ha expuesto en el Apartado anterior de conclusiones del dataset (ver Sección 3.1.3), en la siguiente etapa de este TFM, dedicada al preprocesamiento de los datos (ver Sección 3.3), se requerirá evaluar la precisión y la utilidad de los datos de producción proporcionados por *SustDataED*. Para ello, la presente Sección viene definida por la necesidad de obtener una fuente de datos de producción energética adicional, que permita contrastar la información adquirida del dataset anteriormente con la misma.

Atendiendo a este fin, se procederá a emplear varias herramientas de análisis y simulación de datos de producción energética, detallándose a su vez, sus características de funcionamiento y la configuración necesaria. Cabe destacar que el proceso de simulación de los datos que se va a llevar a cabo implica recrear un dataset que sea riguroso con la realidad.

Por lo tanto, en primera instancia, se deberá llevar a cabo un estudio y un análisis específico de las características geográficas y climáticas a largo plazo de la localización que se tomará como base. Por consiguiente, se cuantificarán los datos mediante una herramienta de simulación en función del estudio anterior. Finalmente, se analizarán los resultados y se evaluará su precisión, con el fin de procesarlos y combinarlos con los datos adquiridos

de *SustDataED* (ver Sección 3.3.2). Es decir, será en esta fase de preprocesamiento donde se tome la decisión final de selección de la fuente de datos de producción más adecuada para el desarrollo de este TFM.

3.2.1. Estudio y análisis de la ubicación (*Global Solar Atlas*)

En cuanto a la ubicación, en este caso será preciso basarse concretamente en Funchal, capital de la isla de Madeira (Portugal), ya que el análisis a realizar tiene que ser acorde a los datos recogidos en el dataset *SustDataED*.

Según los parámetros de clasificación climática de Köppen [72], la ciudad de Funchal se caracteriza por tener un clima mediterráneo. Al localizarse en una zona subtropical, presenta oscilaciones diarias mínimas, lo que se traduce en escasos cambios de temperatura entre las diferentes estaciones del año. Por ello, los inviernos son suaves y con precipitaciones moderadas, mientras que los veranos tienden a ser ligeramente más cálidos y secos.

Tomando en consideración lo anterior, para conocer el potencial de los recursos solares que presenta la ubicación se va a proceder al empleo del modelo solar *Solargis*, proporcionado por la plataforma online *Global Solar Atlas*¹. Esta plataforma es financiada por el *Energy Sector Management Assistance Program* (ESMAP) y administrada por la organización de El Banco Mundial con el objetivo de mapear los recursos de energía renovable a nivel global, permitiendo el acceso a una gran cantidad mapas y de datos promediados a largo plazo y en tiempo real de cualquier punto de la Tierra. [73] [74]

La información sobre los recursos solares y la cuantificación de la energía se suministran a través de esta plataforma siguiendo el estándar GIS ráster o cuadriculado con formatos GeoTIFF o AAIGRID. Para las diferentes capas de datos que se pueden determinar en función de los parámetros de radiación o del potencial fotovoltaico, se sigue una referencia espacial geográfica en base al código EPSG 4326 [75]. Este código es asignado por la organización *European Petroleum Survey Group* (EPSG) para identificar la proyección geográfica empleada, la cual en este caso hace referencia al sistema de coordenadas convencional (latitud-longitud) que se utiliza para la representación cartográfica de la Tierra. Por otro lado, los metadatos correspondientes a las características de cada capa se proveen en formato PDF o XML, siguiendo la estructura de datos geográficos definida por ISO 19115:2003/19139. [73] [76]

¹<https://globalsolaratlas.info/map>

3.2.1.1. Identificación de capas de datos

Considerando las motivaciones que se persiguen con el empleo de la plataforma *Global Solar Atlas*, es preciso realizar un paso previo al análisis, basado en la identificación de los tipos de capas de datos que se pueden configurar: [76]

- *Direct Normal Irradiation* (DNI) (kWh/m²): El índice de radiación directa normal se define como la cantidad de radiación solar que llega perpendicularmente a la superficie de la placa fotovoltaica, sin tener en cuenta los posibles efectos atmosféricos de dispersión o absorción.
- *Diffuse Irradiance Fraction* (DIF) (kWh/m²): El índice de radiación difusa hace referencia a la porción de radiación dispersada por las nubes y los gases atmosféricos, lo que produce que provenga de todas las direcciones.
- *Global Horizontal Irradiation* (GHI) (kWh/m²): El índice de radiación horizontal global viene dado por el sumatorio de la radiación solar directa (DNI) y la radiación solar difusa dispersada en consecuencia a los efectos de la atmósfera (DIF).
- *Global Irradiation at Optimum Tilt* (GTI) (kWh/m²): El índice de radiación global inclinada se refiere al total de radiación que incide en una superficie inclinada, que generalmente se encuentra ajustada un ángulo óptimo para maximizar la captación en términos anuales.
- *Photovoltaic Power Potential* (PVOUT) (kWh/kWp): El parámetro que mide el potencial energético de los sistemas fotovoltaicos de una ubicación determinada se cuantifica a partir de un sistema de referencia construido por módulos de silicio cristalino, de 1kWp (kilovatio pico) y que se encuentra inclinado un ángulo óptimo.

Es necesario indicar que todos los parámetros anteriores se proporcionan para cada ubicación como valores promedios anuales de los totales diarios. Adicionalmente, otras capas a tener en cuenta para el análisis de los datos podrían ser la temperatura del aire, que determina en gran medida el ambiente de operación de las placas fotovoltaicas, o la elevación del terreno, que puede convertirse en un factor limitante para la instalación de plantas solares.

En las Figuras 3.3 y 3.4, se visualizan en formato GeoTIFF los resultados de aplicar las capas de los índices de radiación DNI y GHI al mapa mundial a través de la plataforma *Global Solar Atlas*. Por otro lado, en la Figura 3.5 se representa el potencial fotovoltaico dado por el parámetro PVOUT. Como es de esperar, se puede verificar que existe una gran correlación entre los niveles de radiación recibidos con respecto a la cantidad de energía que se puede generar con una planta solar en una ubicación determinada.

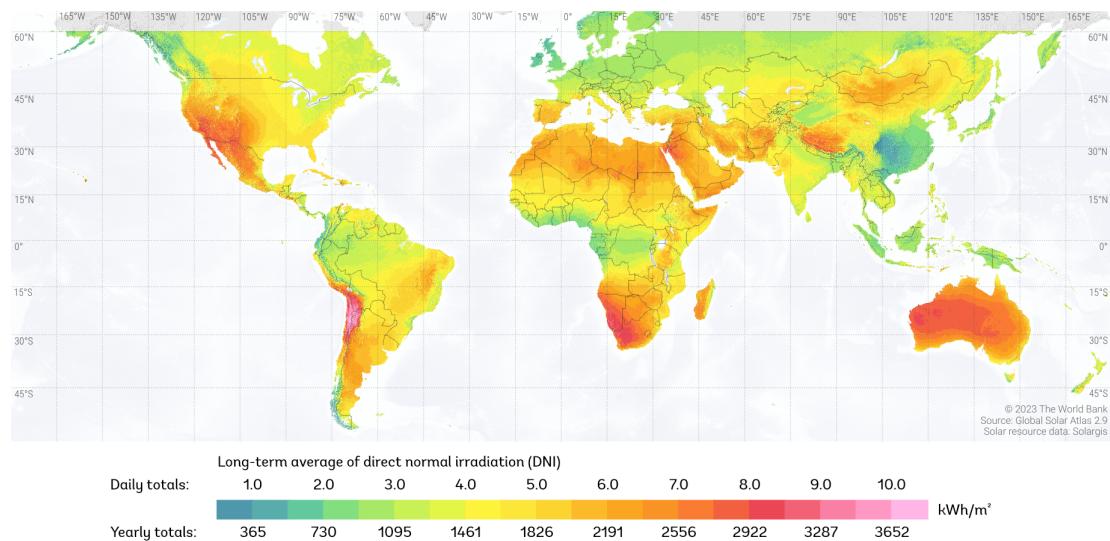


Figura 3.3: Mapa mundial del índice de radiación directa normal (DNI) mundial [73]




Figura 3.4: Mapa del índice de radiación horizontal global (GHI) mundial [73]

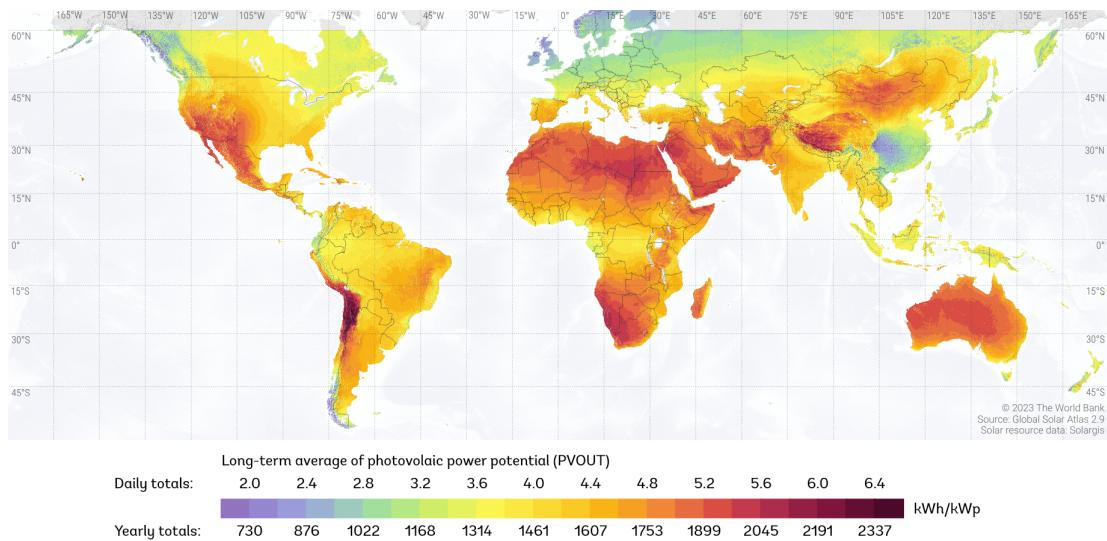


Figura 3.5: Mapa del potencial de producción energética fotovoltaica (PVOUT) mundial [73]

3.2.1.2. Análisis de resultados de radiación

De la misma forma, lo anterior se hace patente para el caso de la isla de Madeira como se puede visualizar en las Figuras 3.6, 3.7 y 3.8. Desde la plataforma *Global Solar Atlas* también, se extraen y se recogen en la Tabla 3.8 los valores de los índices de radiación configurados específicamente para la localización de la ciudad de Funchal.

Parámetro	kWh/m ² /día	kWh/m ² /año
DNI	3,698	1349,9
DIF	2,038	743,8
GHI	4,345	1586,1
GTI	4,730	1726,3

Tabla 3.8: Tabla de valores extraídos para cada índice de radiación en la ciudad de Funchal [73]

Por tanto, se puede comprobar a través de estos valores y de la leyenda proporcionada en las figuras anteriores, que Funchal se percibe como una ciudad con un potencial de recursos solares medio alto. Esto es coherente con su localización subtropical y con la elevación del terreno. Es decir, al encontrarse en una zona de costa ronda en valores cercanos a los 100 metros (concretamente 137 metros en la ubicación seleccionada) y se reduce ligeramente el nivel de energía solar capturable respecto a otras zonas de la isla más montañosas.



Figura 3.6: Mapa del índice de radiación directa normal (DNI) de Madeira [73]



Figura 3.7: Mapa del índice de radiación horizontal global (GHI) de Madeira [73]



Figura 3.8: Mapa del potencial de producción energética fotovoltaica (PVOUT) de Madeira [73]

3.2.1.3. Configuración y cuantificación del potencial energético de la ubicación

Para calcular de forma aproximada la cantidad de energía que supondría la instalación de un sistema fotovoltaico en la ciudad de Funchal, es preciso configurar primero los siguientes parámetros a través de la plataforma:

- Tipo y tamaño de sistema fotovoltaico: Se permite seleccionar entre un sistema enfocado a una vivienda, a un edificio comercial o a una planta solar de grandes dimensiones. En este caso, como se toma como base el estudio de producción energética en un entorno residencial, se configura el primero. Es preciso indicar que en la plataforma la configuración de un sistema fotovoltaico para un entorno residencial no considera la opción de almacenamiento de electricidad.
- Capacidad de instalación: Se toma una capacidad máxima de generación de 4kWp (kilovatios pico) para el sistema. En otros términos, este valor determina la cantidad de energía que producirían los paneles en condiciones óptimas.
- Azimut [77]: Se determina como el ángulo de orientación horizontal y, en función de su valor, define la proyección de los paneles solares en dirección norte, sur, este u oeste. Se indica un valor de 180º para establecer una orientación hacia el sur.
- Inclinación: La plataforma establece como ángulo óptimo para la localización de Funchal un ángulo de 26º, por lo que se configura la instalación de los paneles solares sobre rieles sujetos a un tejado con esta misma inclinación.

3.2.1.4. Análisis de resultados de potencia

Una vez configurados los parámetros expuestos, se obtienen como resultados la trayectoria solar diaria y los perfiles de radiación y generación fotovoltaica diarios y mensuales para la ubicación de Funchal. En la Figura 3.9 se representa la trayectoria solar diaria, en la que se puede visualizar la comparación de la elevación que percibe el sol en función del instante del año, siendo máxima durante el solsticio de junio, y mínima, durante el de diciembre. En el caso del equinoccio, se sigue una curva con valores promedios, al existir una igualdad entre las horas de día y las de noche.

Por otro lado, en la Figura 3.10 se modelan gráficamente los valores totales mensuales, tanto de producción energética, como de radiación directa normal DNI para visualizar la correlación existente entre los mismos en los distintos meses del año. El valor promedio máximo energético se alcanza en el mes de julio, con un valor de 565kWh, ocurriendo de la misma forma para el valor máximo de radiación, cuyo alcance es de 163,7kWh/m² para este mes.




Figura 3.9: Representación de la trayectoria solar percibida en la localización de la ciudad de Funchal [73]

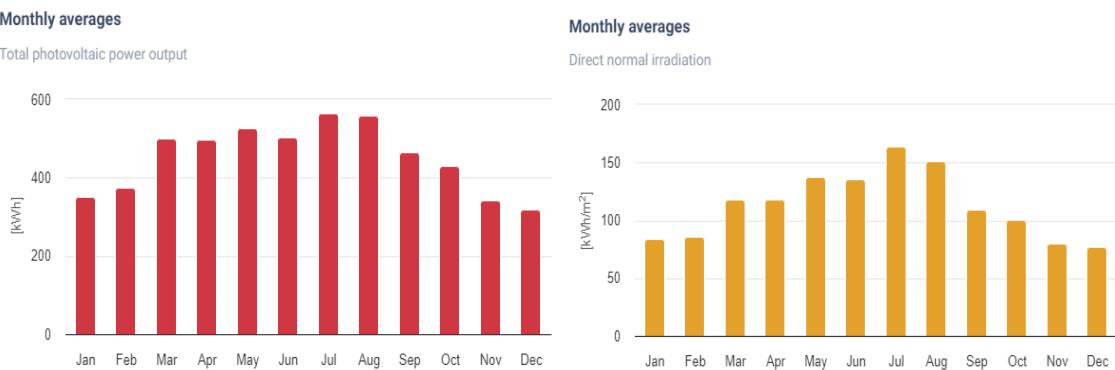


Figura 3.10: Comparación de valores totales mensuales de producción energética fotovoltaica (PVOOUT) respecto a la radiación directa normal (DNI) [73]

De la misma forma, se representan en la Figura 3.11 los perfiles diarios propromedios de radiación y generación fotovoltaica en función del mes del año, en los cuales se encuentran valores máximos en las horas centrales de los meses de julio y agosto.

Average hourly profiles

Total photovoltaic power output [kWh]

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
0 - 1												
1 - 2												
2 - 3												
3 - 4												
4 - 5												
5 - 6				0.002	0.030	0.043	0.022	0.002				
6 - 7			0.021	0.196	0.342	0.338	0.290	0.227	0.132	0.026	0.002	
7 - 8	0.036	0.164	0.512	0.831	0.965	0.942	0.917	0.871	0.816	0.649	0.352	0.118
8 - 9	0.755	0.911	1.201	1.414	1.486	1.479	1.538	1.525	1.437	1.263	0.995	0.758
9 - 10	1.307	1.469	1.710	1.826	1.812	1.760	1.911	1.965	1.831	1.703	1.455	1.247
10 - 11	1.636	1.824	2.093	2.066	2.007	1.960	2.153	2.209	2.059	2.025	1.706	1.525
11 - 12	1.773	1.982	2.259	2.132	2.078	2.012	2.256	2.306	2.074	1.989	1.734	1.602
12 - 13	1.695	1.926	2.176	2.085	2.040	1.938	2.211	2.235	1.948	1.851	1.616	1.554
13 - 14	1.511	1.731	2.013	1.919	1.947	1.901	2.107	2.098	1.755	1.638	1.445	1.379
14 - 15	1.306	1.527	1.767	1.692	1.703	1.687	1.866	1.847	1.521	1.366	1.181	1.153
15 - 16	0.929	1.139	1.365	1.308	1.324	1.330	1.478	1.432	1.132	0.929	0.765	0.742
16 - 17	0.349	0.614	0.820	0.816	0.845	0.873	0.964	0.912	0.652	0.387	0.208	0.200
17 - 18		0.069	0.217	0.296	0.356	0.406	0.443	0.367	0.152	0.012		
18 - 19				0.014	0.049	0.081	0.085	0.026				
19 - 20												
20 - 21												
21 - 22												
22 - 23												
23 - 24												
Sum	11	13	16	17	17	17	18	18	16	14	11	10

Average hourly profiles

Direct normal irradiation [Wh/m²]

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec
0 - 1												
1 - 2												
2 - 3												
3 - 4												
4 - 5												
5 - 6				48	63	48						
6 - 7		136	325	352	340	242	75					
7 - 8	65	231	382	430	451	476	446	385	292	157	50	
8 - 9	293	325	385	423	443	458	521	505	438	379	315	272
9 - 10	364	383	418	415	418	411	493	502	421	403	358	337
10 - 11	374	392	437	400	399	399	484	487	405	424	353	342
11 - 12	363	382	441	384	396	383	482	476	377	373	326	320
12 - 13	333	357	410	368	386	367	471	455	344	338	298	296
13 - 14	294	328	389	347	381	378	467	438	320	312	279	277
14 - 15	284	311	366	334	361	362	442	419	304	296	261	266
15 - 16	258	274	331	304	324	328	398	370	263	249	230	228
16 - 17	135	203	275	253	269	281	331	307	219	158	97	92
17 - 18	32	121	167	201	225	248	216	92	8			
18 - 19			18	47	62	80	29					
19 - 20												
20 - 21												
21 - 22												
22 - 23												
23 - 24												
Sum	2,699	3,053	3,802	3,931	4,428	4,519	5,281	4,892	3,642	3,231	2,674	2,480

Figura 3.11: Perfiles promedios de potencial de producción energética fotovoltaica (PVOUT) y de radiación directa normal (DNI) [73]

Por lo tanto, tomando en consideración los parámetros configurados y los resultados obtenidos, se puede cuantificar finalmente, que la instalación de un sistema fotovoltaico en un edificio residencial de Funchal proporcionaría en un año una generación de energía promedia igual a 5433kWh y un valor acumulado de DNI equivalente a 1719,4 kWh/m².

3.2.2. Creación del dataset de producción (*PVWatts*)

Una vez que se han concretado a modo de análisis las características geográficas, climáticas y energéticas de la localización seleccionada en la ciudad de Funchal, se procederá a realizar el paso dedicado a la obtención de los datos de producción fotovoltaica por medio de la simulación. Para ello, se hará uso de la herramienta online *PVWatts*², proporcionada por el *National Renewable Energy Laboratory* (NREL), que se trata del laboratorio nacional del Departamento de Energía de Estados Unidos. [78]

De la misma forma que se ha operado con la plataforma *Global Solar Atlas* (ver Sección 3.2.1), en el caso de *PVWatts*, también se requiere indicar a la entrada las características relativas a la ubicación seleccionada y a la configuración del sistema de paneles fotovoltaicos que se desea.

En cuanto a la primera, la herramienta *PVWatts*, a diferencia de *Global Solar Atlas*, provee un mapa mundial que se rige por celdas, en función de la localización de las bases de datos del NREL. En el caso de este TFM se cuenta con la fortuna de que se dispone de una de estas bases en la misma ciudad de Funchal, concretamente en las coordenadas 32.65°N, 16.92°W. En este contexto es preciso comentar que esta característica se tuvo en cuenta para definir la localización exacta de instalación del sistema fotovoltaico en la plataforma *Global Solar Atlas* (ver Sección 3.2.1). Por lo tanto, no se requieren ajustes adicionales en estos términos.

3.2.2.1. Configuración de los parámetros de entrada

Con el objetivo de conseguir a la salida de la simulación unos datos que sean coherentes y acordes al análisis realizado anteriormente en la Sección 3.2.1.4, es imprescindible replicar y ajustar de la forma más precisa posible los valores de los parámetros de entrada de la herramienta:

²<https://pvwatts.nrel.gov/pvwatts.php>

- Tamaño del sistema fotovoltaico y capacidad de instalación: Por defecto, *PVWatts* determina una capacidad de 4kWp, por lo que coincide directamente con la definida en *Global Solar Atlas*. Además, se especifica la relación existente entre este valor y el tamaño del sistema de la siguiente manera:

$$\frac{4 \text{ kW}}{1 \text{ kW/m}^2 \times 0.16} = 25 \text{ m}^2$$

Donde se representa que, para obtener una eficiencia del 16% del sistema (eficiencia por defecto), se requiere un área de 25 m² para los módulos solares. Es decir, este valor no representa el área total del sistema fotovoltaico, ya que para ello habría que añadir el cálculo del espacio que se necesita establecer entre cada uno de los paneles DC o el tamaño de los inversores AC que se instalarían.

- Índice de cobertura del suelo: Se define como la relación entre el área de superficie del módulo y el área del suelo (tejado en el caso de una vivienda) ocupado en total. El valor predeterminado es de 0.4, lo que supone que, teniendo un área efectiva de 25 m², se necesitará un área total de 62,5 m².
- Ratio DC/AC: Haciendo referencia al tamaño de los inversores AC, es preciso exponer que estos limitan la salida de la energía del conjunto para que haya un correcto funcionamiento. La herramienta cuantifica por defecto para la localización, una relación 1.2 entre el tamaño de array de paneles y los inversores de corriente alterna. Por lo tanto, en este caso, estos contarán con una capacidad teórica de 3.33kW. Si se pretendiera realizar una instalación a gran escala se necesitarían ratios de hasta 1.5.
- Azimut: De la misma forma que en la configuración en la plataforma *Global Solar Atlas*, se define un azimut de 180°, orientando los paneles hacia el sur.
- Inclinación: *Global Solar Atlas*, en el caso de localizar el sistema fotovoltaico en la ciudad de Funchal, establecía como ángulo óptimo de inclinación, un valor de 26°.
- Tipo de módulos: Se selecciona el tipo estándar, basado en silicio cristalino y con una cobertura de vidrio con revestimiento antireflectante. Aproximadamente, cuenta con una eficiencia nominal del 19%.
- Tipo de array: Se especifica de forma simplificada un tipo de array fijo, que no siga el movimiento del sol mediante ejes de rotación, sino que mantenga sus valores de inclinación y de azimut configurados. En la Figura 3.12, se describe el funcionamiento de cada tipo de array.

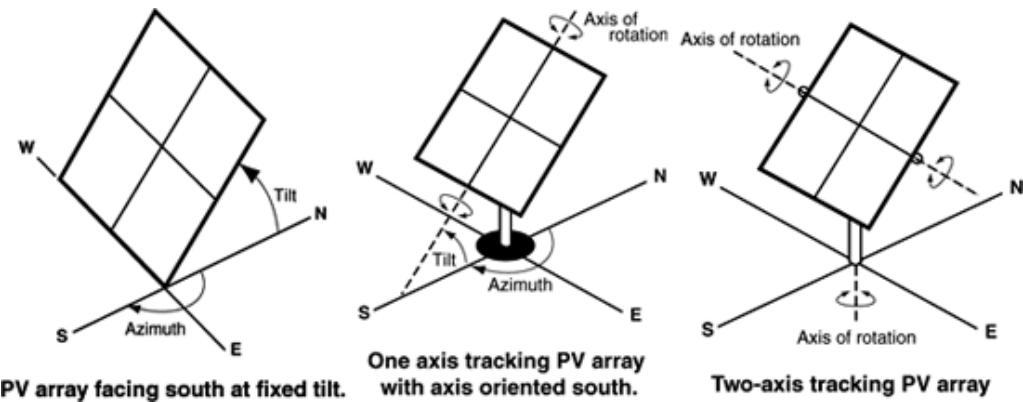


Figura 3.12: Representación de las diferentes opciones de array que permite configurar la herramienta *PVWatts* [78]

3.2.2.2. Configuración de las pérdidas del sistema real

Una de las ventajas de uso que permite la herramienta *PVWatts* es la posibilidad de estimar las pérdidas totales que tendría el sistema en la realidad. Esto es importante para que los resultados de la simulación que se va a realizar sean lo más parecidos a los que se obtendrían mediante la medición del sistema real. Para ello, se deben configurar cada una de las pérdidas parciales de la siguiente manera:

- Suciedad: Debido a la escasez de precipitaciones y a la presencia de calima que se experimenta en la isla, se determina un valor de un 2%.
- Sombreado: Se reduce la radiación solar que incide en los paneles si se producen sombras por objetos cercanos o por la propia de los módulos si se colocan en fila. Es decir, estos crean sombras sobre los de la fila adyacente. El cálculo se realiza a partir de la gráfica expuesta en la Figura 3.13. Por lo tanto, como se ha definido un tipo de array fijo con una inclinación de 26° y un valor de índice de cobertura del suelo de 0.4, se determina aproximadamente un valor de pérdidas por sombra igual a un 3%.
- Nieve: Teniendo en cuenta las características climáticas de la ciudad de Funchal debido a su localización en una zona subtropical, se determinan pérdidas del 0%.
- Discordancia: Son pérdidas eléctricas debido a las diferencias que se producen por imperfecciones en la fabricación de los módulos. Esto tiene como consecuencia que cada uno de ellos presente características I-V que varíen ligeramente entre sí. La herramienta proporciona un valor predeterminado del 2%.

- Cableado y conexiones: Pérdidas resistivas en el cableado y en las conexiones entre módulos, inversores y otros elementos del sistema con un valor por defecto del 2% y del 0.5%, respectivamente.
- Degradación inducida por la luz: Se trata del efecto de reducción de potencia que se produce durante los primeros meses de funcionamiento del sistema fotovoltaico. El valor predeterminado es 1,5%.
- Precisión del fabricante: Son pérdidas, generalmente bajas, que vienen definidas por la precisión del fabricante en el proceso de estudio de eficiencia de los paneles. Se determina un 1%.
- Disponibilidad: Se añaden las pérdidas que se producen a partir de los mantenimientos que se requieren a lo largo del tiempo y que causan paradas en el funcionamiento del sistema. Se provee un valor por defecto del 3%.

Finalmente, las pérdidas totales del sistema se pueden cuantificar a partir de la siguiente expresión:

$$Losses = (1 - 0.02) \times (1 - 0.03) \times (1 - 0.02) \times (1 - 0.02) \times (1 - 0.005) \times (1 - 0.015) \times (1 - 0.01) \times (1 - 0.03)$$

$$100\% \times (1 - Losses) = 14,08\%$$




Figura 3.13: Gráfica para el cálculo de las pérdidas por sombreado en la herramienta PVWatts [78]

3.2.2.3. Análisis de resultados de la simulación

Una vez se ha concluido con la configuración necesaria, se procede a ejecutar la simulación en la herramienta y a adquirir a la salida los resultados de la misma. Se obtienen dos datasets que replican un año completo de mediciones: uno con los valores totales mensuales (ver Tabla 3.9) y otro, con un conjunto de muestras que proporcionan información de cada hora (ver Tabla 3.10).

Como se puede visualizar, en ambas tablas se proporcionan los valores de potencia DC y AC, que corresponden a la salida del módulo solar (*DC Array Output*) y de los inversores (*AC System Output*), respectivamente. En el caso de la Tabla (ver Tabla 3.10), se incluye de forma adicional toda la información climática y ambiental de cada instante.

Campo	Descripción	Unidades
<i>Month</i>	Mes de la muestra	-
<i>Daily POA Irradiance</i>	Índice de radiación en el plano del array	kWh/m ² /day
<i>DC Array Output</i>	Potencia de salida DC del array	kWh
<i>AC System Output</i>	Potencia de salida AC del sistema	kWh

Tabla 3.9: Dataset con valores totales mensuales [78]

Campo	Descripción	Unidades
<i>Month</i>	Mes de la muestra	-
<i>Day</i>	Día de la muestra	-
<i>Hour</i>	Hora de la muestra	-
<i>Diffuse Irradiance</i>	Índice de radiación difusa (DIF)	W/m ²
<i>Plane of Array Irradiance</i>	Índice de radiación en el plano del array (POA)	W/m ²
<i>Ambient Temperature</i>	Temperatura ambiente	C
<i>Wind Speed</i>	Velocidad del viento	m/s
<i>Albedo</i>	Índice de reflectividad de la superficie	-
<i>Cell Temperature</i>	Temperatura de las células solares	C
<i>DC Array Output</i>	Potencia de salida DC del array	W
<i>AC System Output</i>	Potencia de salida AC del sistema	W

Tabla 3.10: Dataset con muestras adquiridas por hora [78]

Teniendo en cuenta las tablas anteriores, en este paso será imprescindible comprobar que los datos finales obtenidos presentan coherencia respecto al estudio previo y que encajan además, con el análisis de los resultados de la plataforma *Global Solar Atlas*, realizado en la Sección 3.2.1.4.

Por ello, en primera instancia, se va a proceder a poner el foco en los valores de radiación directa normal DNI. La herramienta *PVWatts*, como se puede ver en la Tabla 3.9, no proporciona directamente información mensual sobre este parámetro, sino sobre el índice de radiación en el plano del array (del inglés *Plane of Array Irradiance* (POA)), que se calcula a partir de la expresión [79]:

$$POA = DNI \cdot \cos(\theta)$$

Donde:

θ es el ángulo de inclinación configurado, que en este caso sería de 26°.

Por lo tanto, se pueden calcular los valores de DNI a partir de los de POA dados por el dataset. Mediante la librería *matplotlib* de *Python* se representa la Figura 3.14 para visualizar los valores totales mensuales, tanto de producción energética, como de radiación directa normal DNI. El valor máximo energético se alcanza en el mes de julio, con un valor de 517,8kWh, ocurriendo de la misma forma para el valor promedio máximo de radiación, cuyo alcance es de 181,1kWh/m² para este mes. Por tanto, volviendo a la Sección 3.2.1.4 y, específicamente a la 3.10, se puede determinar que los valores obtenidos en la simulación son muy precisos respecto al estudio previo.

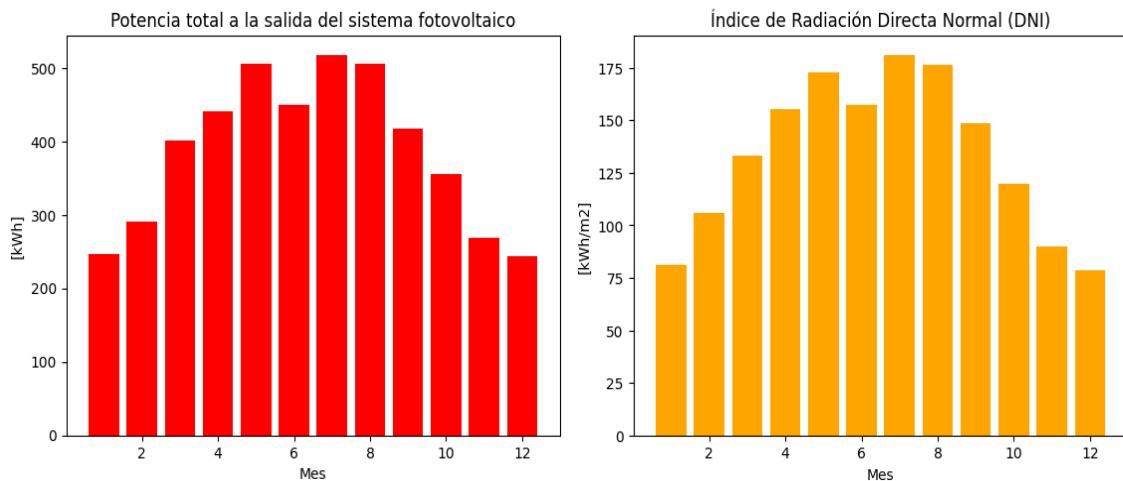


Figura 3.14: Comparación de valores totales mensuales de producción energética fotovoltaica (PVOUT) respecto a la radiación directa normal (DNI) a partir de los resultados de la simulación

Aparte de las gráficas realizadas, se expone la Tabla 3.11 para llevar a cabo de una forma correcta la comparación entre los valores estudiados en *Global Solar Atlas* y los resultantes de la simulación en *PVWatts*. Como se puede ver, existe un menor error entre los valores respectivos a la radiación que entre los valores de potencia producida. Las diferencias percibidas provienen principalmente por las pérdidas configuradas, ya que al final los resultados de la simulación son mucho más cercanos al caso real que los percibidos teóricamente.

Por lo tanto, a través del sumatorio de todos los valores mensuales de producción energética, se puede cuantificar finalmente, que un sistema fotovoltaico real localizado en la ciudad de Funchal, proveería aproximadamente un total de 4417kWh al año. Este valor representa un 81,3% del obtenido teóricamente (5433kWh) en la Sección 3.2.1.4 y viene justificado en gran parte por las pérdidas introducidas. Por otro lado, en el caso del DNI, con la herramienta *PVWatts* se obtiene un total anual equivalente a 1598,8 kWh/m², suponiendo un 92,9% del valor teórico (1719.4 kWh/m²).

Es preciso tener en cuenta las diferencias que presentan las herramientas *Global Solar Atlas* y *PVWatts* en sus algoritmos de cálculo, ya que cada una de ellas asignará pesos diferentes a los parámetros de entrada, incidiendo en los resultados. No obstante, a partir de los valores anteriores y de la Tabla 3.11, se puede determinar de forma concluyente que la simulación realizada es coherente con el estudio previo, cumpliendo así el objetivo principal de esta Sección.

Mes	Producción energética fotovoltaica (PVOUT) [kWh] Global Solar Atlas	PVWatts	Índice de Radiación Directa Normal (DNI) [kWhm ⁻²] Global Solar Atlas	PVWatts
Enero	350,2	247,1	83,7	81,1
Febrero	374,0	291,4	85,5	105,7
Marzo	500,8	401,9	117,9	132,8
Abril	497,9	441,3	117,9	155,0
Mayo	526,5	505,9	137,3	172,7
Junio	502,5	449,6	135,6	157,4
Julio	565,5	517,8	163,7	181,1
Agosto	558,6	505,5	151,6	176,1
Septiembre	465,3	417,4	109,3	148,7
Octubre	429,0	356,3	100,2	119,5
Noviembre	343,7	268,8	80,2	90,1
Diciembre	318,6	243,4	76,9	78,6

Tabla 3.11: Tabla de comparación de los valores totales mensuales de producción energética fotovoltaica (PVOUT) y de radiación directa normal (DNI) de las dos herramientas (valores teóricos y simulados)

3.3. Procesado de los datos

En las Secciones anteriores, se ha detallado el proceso de búsqueda y recolección de datos energéticos en entornos residenciales a partir de las fuentes públicas disponibles. Este proceso ha venido acompañado por un estudio y análisis en profundidad para exponer de forma justificada las razones de la selección de los conjuntos de datos que servirán como base de este TFM.

También, se ha llevado a cabo una investigación enfocada en dos herramientas de extracción de información geográfica, climática y energética. El fin de este proceso ha sido incorporar una nueva fuente de datos con parámetros relacionados con la producción de electricidad, la cual se ha construido a partir de la simulación de un caso real.

Entonces, se puede expresar que la ejecución de los procesos anteriores proporcionará múltiples ficheros de datos que soporten extensas cantidades de información. En consecuencia, estos ficheros se caracterizarán por su gran tamaño y su dificultad de manejo y empleo. Por ello, se introduce esta Sección con el fin principal de realizar un procesamiento exhaustivo y reducir los conjuntos de datos únicamente a las muestras que aporten información de utilidad para llevar a cabo el desarrollo posterior. Teniendo en cuenta el objetivo definido, se va a estructurar esta Sección en diferentes fases, en función de cada uno de los pasos que se deberán realizar para procesar los datos.

Antes de comenzar a describir este procesamiento, es imprescindible destacar que este vendrá determinado principalmente por la creación y diseño de código programado en *Python* en diferentes *notebooks* de *Jupyter*, ya que es el entorno más adecuado en el ámbito de la ciencia de datos y de la aplicación de técnicas de ML. Su empleo aportará la ventaja de poder depurar y comprobar paso a paso que se ejecutan de forma correcta cada una de las acciones que componen el procesamiento. Cabe destacar el uso de algunas librerías que serán imprescindibles para el manejo de los datos, como son *pandas*, *csv* o *numpy*, entre otras. Adicionalmente, para la representación de las diferentes gráficas de la Sección se hará uso de los módulos *matplotlib* y *seaborn*.

3.3.1. Procesado de datos de consumo

3.3.1.1. Análisis de la situación inicial y primeros pasos

El dataset seleccionado para este TFM, *SustDataED*, se detallaba en la Sección 3.1.1 como un conjunto de datos que abría multitud de posibilidades de implementación. Se puede expresar que esto venía justificado por el hecho de abarcar un extenso lapso temporal de medidas correspondientes a un gran número de viviendas. Además, estas medidas se

caracterizaban por ser adquiridas a una frecuencia de muestreo de un minuto, lo que apor-taba una buena resolución para analizar el comportamiento eléctrico de todos los usuarios implicados. Como también se exponía en la Sección 3.1.1, especialmente en la Figura 3.1, el dataset *SustDataED* se estructuraba en cuatro despliegues diferentes, cada uno con diferentes rangos temporales de medición y con un conjunto de viviendas determinado.

Poniendo el enfoque en las medidas de consumo, esto supone que se termine coleccio-nando en conjunto hasta un total de 24.512.181 muestras, correspondientes a 1144 días de medición. A modo de síntesis, se aporta la Tabla 3.12 con la información respectiva a cada despliegue. [68]

Por lo tanto, en este paso, enfocado al análisis de la situación inicial del conjunto, es preciso tener el conocimiento de los ficheros de datos de consumo de los que se va a partir. Por este motivo, se añade de forma adicional la Tabla 3.13, la cual expone la información relativa a cada despliegue y a los tamaños de cada uno de los ficheros proporcionados en el dataset.

Despliegue	Muestras	Días	Fecha de inicio	Fecha de fin
1	3.474.557	123	10/07/2010	10/11/2010
2	12.481.536	504	25/11/2010	20/04/2012
3	5.671.576	298	01/08/2012	25/05/2013
4	2.884.512	219	31/07/2013	10/03/2014
	24.512.181	1144		

Tabla 3.12: Resumen de los datos de consumo del dataset *SustDataED* [68]

Despliegue	Fichero de muestras	Tamaño (MB)
1	power_samples_d1_1	86.38
	power_samples_d1_2	69.99
2	power_samples_d2_1	289.81
	power_samples_d2_2	265.13
	power_samples_d2_3	283.27
	power_samples_d2_4	311.89
3	power_samples_d3_1	259.92
	power_samples_d3_2	233.69
	power_samples_d3_3	272.23
4	power_samples_d4_1	250.12
	power_samples_d4_2	252.84

Tabla 3.13: Resumen de las características de los ficheros de los despliegues de *SustDataED*

Como se puede comprobar, a priori la mayoría no precisan de un volumen manejable, por lo que la primera acción a realizar será dividir los mismos en nuevos ficheros que supongan un tamaño menor del dado. Esto sobre todo será importante a la hora de trabajar con el repositorio de GitHub, puesto que existe el factor limitante de que el tamaño máximo permitido por archivo es de 100MB.

No obstante, antes de dividir los ficheros, se debe volver a la Tabla que hace referencia a las medidas de consumo energético (ver Tabla 3.2) para observar que estos ficheros contienen una columna dedicada a la marca de tiempo (*timestamp*) del instante en el que se adquirió la medida.

A modo de simplificar esta información temporal, se crea un nuevo *notebook* de *Jupyter*, denominado como *preprocessing_nodes.ipynb*, que va a importar la librería *time* para añadir tres nuevas columnas al dataset que separen los datos de la fecha (columna *datetime*), el instante exacto de la muestra (hora, minuto y segundo) (columna *hour*) y la hora como un valor entero (columna *H*). En el caso de esta última columna, su utilidad vendrá descrita por los requerimientos de la siguiente Sección (ver Sección 3.3.1.3).

Código 3.1: Formato del timestamp

```

1 df['tmstp'] = pd.to_datetime(df['tmstp']) # Conversión de la columna del \textit{dataframe} a formato ↪
    ↪ datetime
2 df['datetime'] = df['tmstp'].dt.strftime('%Y-%m-%d') # Formateo de la fecha (año, mes, día)
3 df['hour'] = df['tmstp'].dt.strftime('%H:%M:%S') # Formateo del instante (hora, minuto, segundo)
4 df['H'] = df['tmstp'].dt.strftime('%H').astype(int) # Formateo de la hora como entero

```

De forma adicional, en este *notebook* se comprueba también, si existen filas con valores *NaN* que puedan perjudicar al análisis de los datos. Como ventaja, el dataset *SustDataED* aporta la columna *miss_flag* (ver Tabla 3.2) para determinar si para cierto instante temporal se ha producido la adquisición de forma incorrecta o con valores vacíos. Por tanto, la acción a desarrollar será comprobar en todo el *dataframe* cuándo este valor se encuentra activo y, en ese caso, eliminar la fila respectiva.

Código 3.2: Eliminación de valores NaN

```

1 df.isnull().any() # Comprobación previa de existencia de valores NaN en el \textit{dataframe}
2 df = df[df['miss_flag'] != 1] # Aplicación de filtro al \textit{dataframe}
3 df = df.dropna(thresh=len(df.columns) - 15 + 1) # Eliminación de columnas con todos los elementos ↪
    ↪ vacíos
4 df.isnull().any() # Comprobación posterior de existencia de valores NaN en el \textit{dataframe}

```

A modo de resumen, se puede determinar entonces, que se seguirá la siguiente secuencia de pasos en esta primera fase: crear las nuevas columnas temporales, eliminar las filas que estén completamente vacías y dividir los ficheros iniciales para ajustar su tamaño a un máximo de 100MB. Es obligatorio seguir este orden, puesto que no sería eficiente extraer los fragmentos del conjunto de datos y, después, añadir información nueva. En otros términos, de esta forma se estaría superando el tamaño máximo ajustado en los nuevos ficheros de salida.

Volviendo al proceso de división de los ficheros, se crea otro *notebook* de *Jupyter*, denominado como *split.ipynb*. En primer lugar, se importa al mismo la librería de *Python csv*, enfocada al tratamiento de archivos con formato .csv. Después, se escribe una función que, a partir de un fichero de entrada, itere a través de sus filas de datos hasta llegar al volumen máximo determinado para obtener a la salida el nuevo archivo en la ruta indicada. Es importante indicar en la función que, para cada nueva fragmentación de los datos, se incluya el encabezado con los nombres de cada uno de los campos, puesto que suponen ficheros diferentes y, de otro modo, no vendrían definidas correctamente sus columnas.

Código 3.3: Fragmentación de ficheros iniciales

```

1 with open(input_file, 'r') as csv: # Apertura del fichero de entrada
2     reader = csv.reader(csv) # Definición del reader
3     header = next(reader)
4
5     for row in reader: # Iteración de las filas del fichero
6         if current_row % split_size == 0: # Condición de máximo de filas
7             if output_file: # Cierre del fichero de salida
8                 output_file.close()
9             split = f'dataset/split_{current_split}.csv'
10            output_name = input_name + split
11            output_file = open(output_name, 'w', newline='') # Apertura del fichero de salida
12            writer = csv.writer(output_file) # Definición del writer
13            writer.writerow(header) # Escritura del encabezado
14            current_split += 1
15            writer.writerow(row) # Escritura de fila
16            current_row += 1
17
18 if output_file: # Cierre del fichero de salida
19     output_file.close()
```

Por tanto, tras realizar este procedimiento, se logra obtener un total de 28 nuevos ficheros en formato .csv de un tamaño reducido, permitiéndose así, una mejor gestión de los datos que contienen los mismos.

3.3.1.2. Síntesis de la información

La presente Sección se dedicará principalmente a la reducción de la información dada por *SustDataED*. Como se ha comentado anteriormente, el hecho de que las muestras se hayan adquirido a una frecuencia de un minuto, proporciona un gran volumen de datos que debería sintetizarse. En el caso de este TFM, con el fin de reducir el número de filas del dataset, se ha valorado como opción más apropiada realizar una cuantificación del promedio de las mediciones para cada hora. En otros términos, a partir de las muestras iniciales obtenidas cada minuto, se generaría un nuevo conjunto de medidas promediadas cada hora, resultando en una reducción de los datos en un factor 60.

En primera instancia, para simplificar la programación, se crea un primer *notebook* básico que realice el procedimiento de reducción de datos para uno de los ficheros fragmentados que se han obtenido a partir de *split.ipynb*. Este nuevo *notebook* se denomina como *datasamples_onenode.ipynb* y aplica el promedio únicamente a las medidas de un nodo contenidas en una hora y fecha determinadas. Estos valores son determinados como parámetros de entrada y, en el caso de la hora, es preciso hacer uso de la columna *H*, definida en la Sección anterior (ver Sección 3.3.1.1) para determinar la hora a la que pertenece la medida como un valor entero.

Por tanto, una vez definidos los valores de los parámetros de entrada, se aplica un filtro al *dataframe* a partir de los mismos y se comprueba que se ha realizado el procedimiento de forma correcta mediante la observación del número de filas que se extraen, que debería ser 60. Para llevar a cabo el cálculo del promedio, es preciso especificar las columnas sobre las que se va a aplicar la operación, que son las que contienen todos los valores que hacen referencia a los parámetros eléctricos. Por tanto, a partir de las 60 filas filtradas y, tomando en consideración las columnas comentadas, se puede calcular ya el valor promedio de cada uno de los parámetros eléctricos.

El resultado de este proceso supone una única fila con todos los valores promediados de una hora. En la Figura 3.15 se muestra como ejemplo la salida que se obtiene tras aplicar el promedio a las medidas adquiridas en la vivienda con identificador 25 en el instante temporal correspondiente al 8 de abril de 2013 con hora 15:00.

	lmin	lmax	lavg	Vmin	Vmax	Vavg	Pmin	Pmax	Pavg	Qmin	Qmax	Qavg	Pfmin	Pfmax	Pfavg	iid	H	datetime
0	0.567326	1.173665	0.591531	239.589517	240.550417	240.065317	104.408123	247.561008	110.18881	-23.030628	14.021733	9.078678	0.773812	0.814176	0.791915	25	15	2013-04-08

Figura 3.15: Salida de *datasamples_onenode.ipynb* tras aplicar la operación de promedio

3.3.1.3. Automatización del proceso de síntesis de la información

Como se viene exponiendo en la Sección anterior (ver Sección 3.3.1.3), el proceso de cálculo del promedio de valores viene determinado por los parámetros de entrada que se definen y se produce una ejecución únicamente para las 60 muestras que se han adquirido a partir de un identificador de vivienda y en una hora y fecha específicas.

Esta característica supone que, si se desea aplicar el promedio a los valores de las medidas de cada hora para todo el rango temporal que abarca cada uno de los nodos, se debe automatizar el proceso. Por ello, se crea un nuevo archivo de *Python*, denominado como *datasamples_process.py*, que incluirá todas las funciones necesarias para llevar a cabo el procedimiento de automatización. Es importante comentar que en esta Sección se pone el foco en los datos de consumo. Sin embargo, las funciones que se van a exponer a continuación, serán configuradas para ser empleadas también, en el caso de los datos relativos a la producción y al clima de *SustDataED*.

En primer lugar, *datasamples_process.py* describe una función de lectura que extrae como argumento el *path* donde se ubican los ficheros .csv a leer y, después, aplica un bucle para concatenar todos ellos en un mismo *dataframe*. Por consiguiente, se comprueba qué tipo de datos contienen los ficheros (ficheros de consumo o de producción) y se almacenan las columnas de los parámetros eléctricos con los que se va a operar en una variable X. En el caso de los ficheros de consumo, se selecciona la columna *Pavg*, que hace referencia a los valores de potencia activa media adquirida en cada instante. Esto es porque se trata de la información que se requiere conocer para poder establecer más adelante las cargas en el algoritmo DEN2NE. Este proceso en cuestión será detallado en la Sección 3.5.1.

En el paso de lectura se extraen también los identificadores de las viviendas que vienen contenidos en cada fichero. Finalmente, se devuelve el *dataframe* completo, la variable X y dos listas: una con los identificadores extraídos en el paso anterior y otra con todas las fechas únicas (columna *datetime*) que contiene el *dataframe*.

Código 3.4: Función de lectura de los ficheros

```

1 def read_files(files):
2     path = gl.glob(files) # Definición del path
3     dfs = []
4
5     for file in path:
6         dfs.append(pd.read_csv(file, low_memory=False)) # Lectura de cada fichero
7         print("Leyendo " + file)
8
9     df = pd.concat(dfs, ignore_index=True) # Operación de concatenación
10

```

```

11 # Comprobación de tipo de ficheros para almacenar los parámetros eléctricos y los identificadores
12 if files.startswith(files_cons): # Ficheros de consumo
13     X = df.iloc[:, 11:12]
14     iid_array = df["iid"].unique()
15 elif files == files_prod: # Ficheros de producción
16     X = df.iloc[:, 16:17]
17     iid_array = 0
18
19 X_features = X.columns.to_list()
20 X_features.append("iid")
21 X_features.append("datetime")
22 X_features.append("h")
23 datetime_array = df["datetime"].unique() # Extracción de las fechas
24 return df, X_features, iid_array, datetime_array

```

La siguiente función que se define es la relativa al cálculo del promedio de los valores. En ella, al igual que en la anterior, es preciso comprobar si los ficheros con los que se va a operar contienen datos de consumo o de producción. Se aplica una condición para ello a partir de la existencia de información sobre el identificador de la vivienda, ya que, como se comentaba en la Sección 3.1.2.4, los datos de producción de *SustDataED* se proporcionan en términos globales a todos los hogares. Esto quiere decir que no proveen información de identificador, por lo que es posible conocer el tipo de ficheros que se está tratando a partir del valor de esta columna.

Por tanto, tomando lo anterior en consideración, se aplica el filtro al *dataframe* de la misma forma que se realizaba en la Sección y se informa, a modo de depuración, sobre el progreso del proceso. El siguiente paso es calcular la media de los valores para cada hora y volcar los resultados, junto con el identificador de la vivienda y el dato de la fecha, en un nuevo *dataframe*.

Código 3.5: Función de cálculo del promedio

```

1 def extract_mean(df, IID_SAMPLE, HOUR_SAMPLE, DATETIME_SAMPLE, X_features, ↵
    ↵ result_dict, progress):
2     # Comprobación de tipo de ficheros para aplicar el filtro
3     if IID_SAMPLE == 0: # Ficheros de producción
4         filter = df[(df["h"] == HOUR_SAMPLE) & (df["datetime"] == DATETIME_SAMPLE)]
5         desc = f"Procesando producción {DATETIME_SAMPLE} {HOUR_SAMPLE}"
6     else: # Ficheros de consumo
7         filter = df[(df["iid"] == IID_SAMPLE) & (df["h"] == HOUR_SAMPLE)
8             & (df["datetime"] == DATETIME_SAMPLE)]
9         desc = f"Procesando consumo de IID {IID_SAMPLE} {DATETIME_SAMPLE} {HOUR_SAMPLE}"
10
11 df2 = pd.DataFrame() # Creación del nuevo \textit{dataframe} para almacenar los resultados
12
13 for feature in X_features:
14     if feature == "iid":

```

```

15     df2[feature] = IID_SAMPLE
16 elif feature == "datetime":
17     df2[feature] = DATETIME_SAMPLE
18 else:
19     df2[feature] = [filter[feature].mean()] # Cálculo del promedio
20
21 result_dict[IID_SAMPLE] = df2 # Diccionario final con todos los \textit{dataframes} creados
22 progress.value += 1

```

Finalmente, se escribe la función que se va a encargar de automatizar el proceso de cálculo de todos los valores promedios mediante compresión de listas. Se produce la llamada a la función *extract_mean()* con un doble bucle que introduce iteraciones en función de todas las fechas contenidas en la lista de fechas y de todas las horas que hay en un día.

Código 3.6: Función de automatización del cálculo del promedio

```

1 def process_data(iid, df_power_samples, datetime_array_ps, X_ps, result_dict, progress):
2     extraction = [
3         extract_mean(df_power_samples, iid, hour, datetime, X_ps, result_dict, progress)
4         for datetime in datetime_array_ps
5         for hour in range(24)]

```

Por lo tanto, una vez definidas las funciones anteriores, ya se permite realizar una ejecución automatizada del proceso de síntesis de los datos. En este caso, para realizar las pruebas de funcionamiento, se crea el script *run_tests.sh* y se lanza en un equipo que cuenta con un total de 32 cores. Este script posibilita la descompresión de los ficheros de datos, la instalación de las librerías de *Python* necesarias (especificadas en un archivo *requirements.txt*) y la ejecución de *datasamples_process.py*.

Se plantea en primera instancia, establecer una ejecución multihilo. Cuando se lleva a cabo el lanzamiento, se observa que, como es de esperar, se están utilizando varios cores. Sin embargo, como se puede visualizar en la Figura 3.16, el uso de *threads* no provoca en ningún momento que alguno de los cores disponibles se aproxime al 100% de su operabilidad.

Esto se debe a que los hilos no son procesos y están principalmente enfocados a la concurrencia. Es decir, el planificador del kernel establece en qué core se va a ejecutar cada una de las tareas y se producen cambios de contexto, que tienen como consecuencia, la introducción de latencias y una pérdida de eficiencia en la ejecución de las pruebas. Teniendo esto en cuenta, se toma la decisión de operar con procesos independientes. En este caso, no se van a producir desalojos, dado que la tarea sí es un proceso. Además, se establece uno para cada identificador, suponiendo que cada uno de ellos se ejecute completamente en un core. En la Figura 3.17, se muestran los cambios comentados. [80]

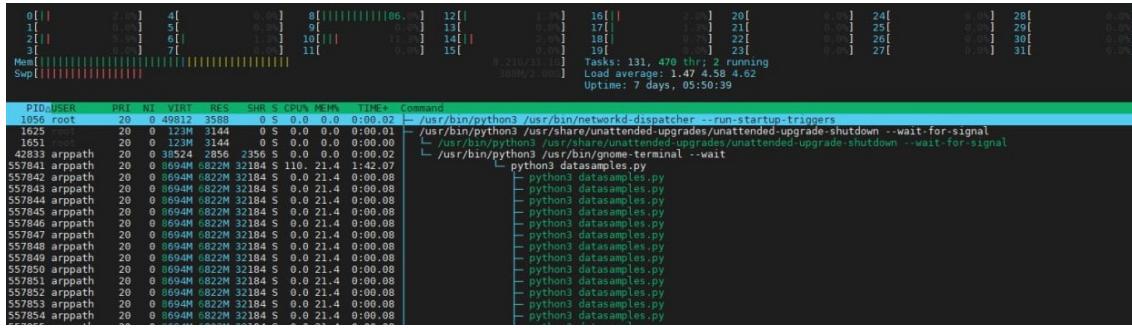
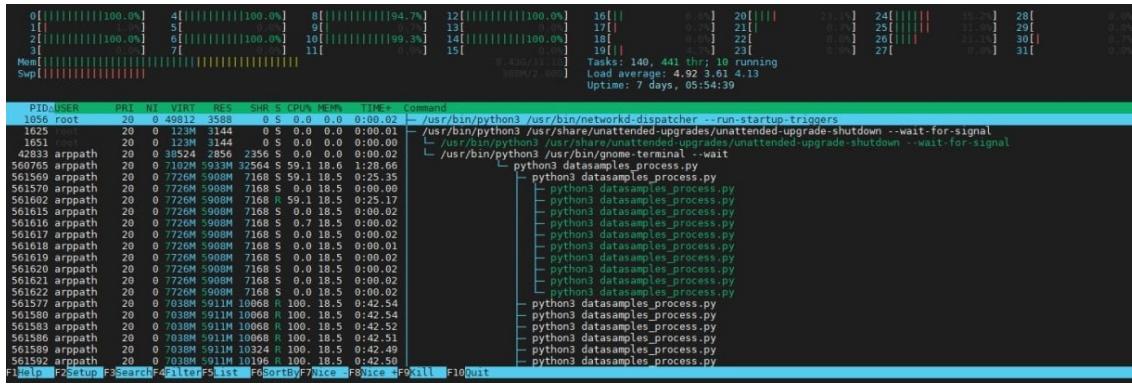
Figura 3.16: Lanzamiento de pruebas con *threads*

Figura 3.17: Lanzamiento de pruebas con procesos

Por lo tanto, volviendo al código, en el archivo se debe importar la librería *multiprocessing* y definir el administrador (*manager*) para crear un diccionario que será compartido por los procesos para almacenar los resultados de la ejecución. Después, se crean los procesos, llamando a la función *process_data*, expuesta anteriormente. Para la misma, se deben añadir los parámetros de entrada necesarios como argumentos e iterar para todos los identificadores de viviendas. En este momento, ya se pueden iniciar los procesos y definir el progreso de la ejecución a través de la terminal.

Para obtener a la salida los nuevos ficheros, se debe esperar a que todos los procesos finalicen. Se consigue un fichero de datos de consumo energético por vivienda definida en *SustDataED*, suponiendo en total 50. A modo organizativo, se sigue la nomenclatura *consum_x.csv*, donde x hace referencia al identificador de la vivienda a la que pertenecen las medidas promediadas. En la Tabla 3.14 se muestran los campos que contienen estos ficheros.

Código 3.7: Creación de procesos

```

1 if __name__ == "__main__":
2     df_power_samples, X_ps, iid_array_ps, datetime_array_ps = read_files(files_cons) # Lectura de ↪
        ↪ ficheros
3
4     manager = Manager() # Creación del administrador
5     result_dict = manager.dict() # Definición del diccionario compartido de resultados
6     progress = manager.Value('i', 0) # Creación de valor para indicar el progreso
7
8     processes = [ # Creación de los procesos
9         Process(target=process_data, args=(iid, df_power_samples, datetime_array_ps, X_ps, result_dict, ↪
            ↪ progress))
10        for iid in iid_prueba
11    ]
12
13    for process in processes:
14        process.start() # Inicio de los procesos
15
16    total_tasks = len(datetime_array_ps) * len(iid_prueba) * 24 # Cálculo del número de tareas
17
18    # Creación de barra de progreso
19    with tqdm(total=total_tasks, desc="Progreso total del script") as pbar:
20        while progress.value < total_tasks:
21            pbar.update(progress.value - pbar.n)
22
23    for process in processes:
24        process.join() # Espera a la finalización de todos los procesos
25
26    for iid, result in result_dict.items(): # Almacenamiento de los resultados en los nuevos ficheros
27        result.to_csv(f"results/consum_{iid}.csv", index=False)

```

En este caso, la información de consumo, la cual venía dada a una frecuencia de muestreo de un minuto, se ha transformado a valores promediados por hora. Por tanto, se puede expresar de forma concluyente, que se logra el objetivo de reducir el tamaño de los ficheros y de sintetizar el volumen de datos a manejar, ya que a partir de ahora se va a trabajar con datos por hora.

Campo	Descripción	Unidades
<i>iid</i>	Identificador de vivienda	-
<i>datetime</i>	Fecha del valor promedio	datetime
<i>H</i>	Hora del valor promedio	-
<i>Pavg</i>	Potencia activa media	W

Tabla 3.14: Estructura de campos de cada fichero *consum_x.csv*

3.3.1.4. Selección del despliegue

Teniendo en cuenta los resultados obtenidos en la Sección anterior, el siguiente paso consiste en seleccionar las viviendas sobre las que se va a basar el desarrollo y entrenamiento de modelos de ML. En la Sección 3.1.2, se describían los distintos despliegues que componían el proceso de la adquisición y creación del dataset *SustDataED* y se representaban los rangos temporales que comprendían cada uno de ellos en la Figura 3.1.

Poniendo en consideración esta información, es imprescindible seleccionar un conjunto de viviendas cuyas medidas estén abarcadas en un mismo lapso de tiempo para poder realizar un análisis de forma precisa y entrenar correctamente los modelos de ML. En otros términos, la selección de múltiples viviendas se debe reducir a escoger el despliegue más adecuado de los cuatro en los que se estructura *SustDataED*. El objetivo es buscar un balance entre manejar un buen número de hogares y un rango temporal lo suficientemente largo. Volviendo a la Figura 3.1, se puede visualizar que los despliegues que cumplen mejor estas condiciones son el primero y el segundo.

No obstante, en este proceso de análisis y selección del conjunto de viviendas, se deben añadir también, los datos de producción energética que provee *SustDataED*. En la Figura 3.2, se muestra cómo estos datos vienen comprendidos entre el mes de octubre de 2010 y enero de 2013. Esto supone que se debe descartar el primer despliegue de viviendas, ya que este abarca un rango temporal que va desde julio de 2010 a noviembre del mismo año.

Por lo tanto, teniendo estas condiciones y características en cuenta, se justifica que el despliegue más adecuado a emplear es el segundo, el cual comprende un total de 23 viviendas (desde el identificador 1 al 23). En la Figura 3.18, se representan, mediante el empleo de la librería de *Python*, *matplotlib*, los rangos temporales que abarcan las medidas adquiridas para cada una de las viviendas participantes en el segundo despliegue.

3.3.1.5. Selección del rango temporal y procesamiento adicional

Como se puede ver en la Figura 3.18, aunque las 23 viviendas pertenecen al mismo despliegue y abarcan un lapso temporal parecido, se pueden visualizar ciertas diferencias entre las mismas. Esto supone que realmente cada fichero de datos de consumo tenga un número de muestras diferente, lo que perjudicaría al análisis y entrenamiento posterior. Una vez seleccionado el despliegue, se deben acotar los ficheros de datos de consumo a un mismo rango temporal en el se pueda trabajar de forma eficiente.

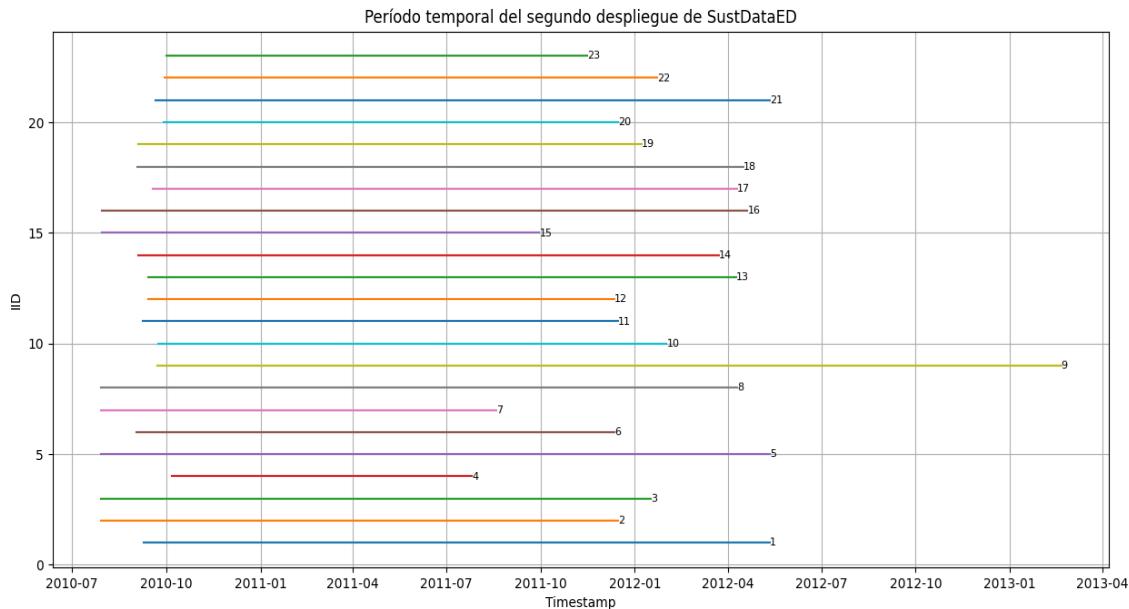


Figura 3.18: Representación del período temporal que comprende el proceso de recolección de datos para los hogares del segundo despliegue

Como se ha indicado anteriormente en esta misma Sección, los datos de producción energética se comienzan a medir desde el mes de octubre de 2010, por lo que es necesario como mínimo establecer el inicio del rango temporal en estas fechas. Por otro lado, entrando en el contenido de los ficheros, la fecha mínima en la que se visualiza que las 23 viviendas adquieren y almacenan medidas es el 28 de noviembre de 2010, lo que lleva a tomar la decisión de establecer la misma como inicio del rango temporal a considerar. En cuanto a la fecha final, a partir de la información dada en la Figura 3.18, se considera que la opción más eficiente es abarcar un año completo de muestras, siendo la fecha final el 28 de noviembre de 2011.

No obstante, en Secciones siguientes, se expondrá cómo el hecho de seleccionar un año de medidas será importante para calcular las cargas finales que se fijarán en el algoritmo DEN2NE (ver Secciones 3.3.3 y 3.5.1), puesto que en el caso de los datos de producción obtenidos de la herramienta *PVWatts* se comprenden valores de potencia de un año completo (ver Sección 3.3.2.2).

Código 3.8: Aplicación del rango temporal a los ficheros

```
1 rango = df[(df['datetime'] >= '2010-11-28') & (df['datetime'] < '2011-11-28')]
```

La aplicación del filtro del rango temporal a los datos se realiza en el *notebook* *consum_range.ipynb*. De forma adicional, se define el procesamiento que requieren los ficheros de consumo de aquellas viviendas que no incluyen valores en algunos instantes temporales dentro del rango indicado. En este paso, el objetivo es contar con ficheros que contengan un mismo número de medidas para simplificar su manejo. Por ello, para que los datos finales tengan la mayor precisión posible, se deben añadir las muestras que faltan en función del tipo de vivienda a la que se hace referencia.

Es decir, como se expuso en la Sección 3.1.2.3, el dataset *SustDataED* provee la Tabla 3.4 con toda la información respectiva a cada uno de los hogares monitorizados y a las características sociales de los propios inquilinos. Esta información determina principalmente, el comportamiento eléctrico que toma cada uno de los hogares y se debe tener en cuenta para añadir las muestras necesarias a los ficheros de aquellas viviendas que tienen el rango temporal incompleto.

A modo de ejemplo se muestra la Figura 3.19, donde para la vivienda con identificador 5, se podrían aproximar las muestras a las dadas por la vivienda con identificador 17. Esto se debe a que la información demográfica de las mismas es similar, ya que están habitadas por una familia de 4 integrantes, de los cuales son 2 adultos y 2 niños. Por lo tanto, se puede apreciar que se obtiene un comportamiento eléctrico parecido.

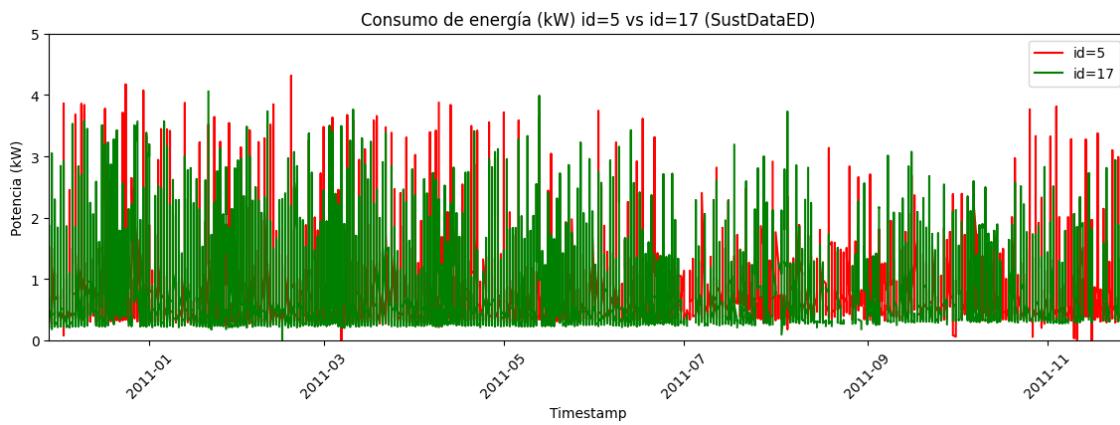


Figura 3.19: Comparación del consumo de las viviendas 5 y 17 en el rango seleccionado (*SustDataED*)

Ocurre de la misma forma en la Figura 3.20. No obstante, en este caso se representa el consumo de potencia de las viviendas con identificador 13 y 16, que se caracterizan por estar habitadas por dos inquilinos adultos, por lo que es coherente que se obtenga un menor consumo medio respecto al caso anterior.

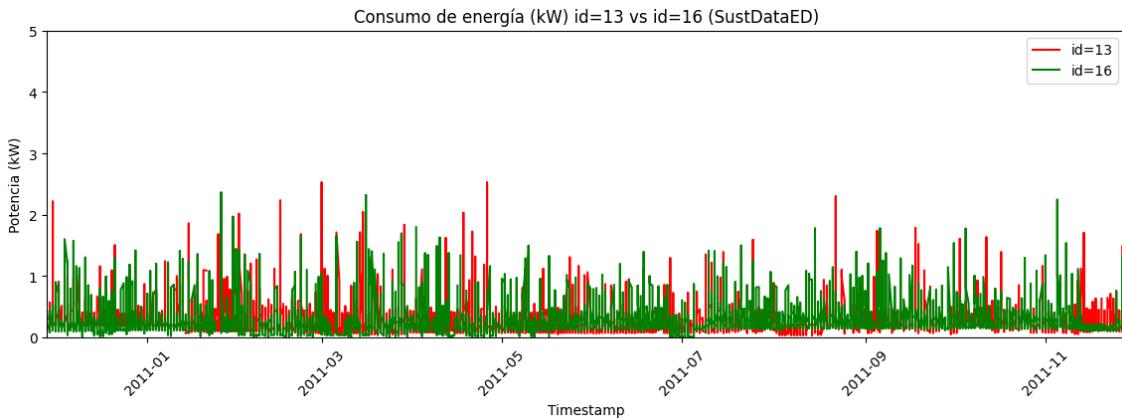


Figura 3.20: Comparación del consumo de las viviendas 13 y 16 en el rango seleccionado (*SustDataED*)

3.3.2. Procesado de datos de producción

Después de exponer el procesamiento necesario para los datos de consumo, se va a profundizar en la producción energética. Como ya se había detallado en las Secciones 3.1.3 y 3.2, referentes, respectivamente, a las conclusiones obtenidas del dataset *SustDataED* y a la introducción a las herramientas de simulación de datos de producción energética, se escribe la presente Sección con el objetivo de tomar la decisión de seleccionar la fuente de datos de producción más adecuada para el desarrollo de este TFM.

Por tanto, se debe comparar las características que presentan, tanto los datos que proporciona *SustDataED*, como los extraídos a través de la simulación en la herramienta *PVWatts*. Para ello, hay que determinar unos pasos iniciales de procesamiento en cada uno de ellos que permitan finalmente, establecer una comparación de forma correcta. En otras palabras, no sería preciso comparar ambas fuentes directamente si estas no están comprendidas en unos mismos rangos temporales o si no contienen los mismos parámetros.

3.3.2.1. Preprocesamiento de datos de *SustDataED*

En cuanto al dataset *SustDataED*, por un lado, se realiza la combinación de los parámetros energéticos y los climáticos. Este paso viene dado por la necesidad de realizar un análisis de la correlación que existe entre la producción solar y las características ambientales que se miden en cada instante. Por ello, se crea un nuevo *notebook*, denominado como *preprocessing_production.ipynb*, en el cual hay que tener en cuenta los campos expuestos en las Tablas 3.5 y 3.7. La operación de combinación de los datos energéticos y climáticos se determina a partir de la marca de tiempo (*timestamp*) y resulta en un nuevo *dataframe* de *Pandas*, que será almacenado en un nuevo fichero en formato .csv.

Por otro lado, es necesario sintetizar los datos de producción de la misma forma que Código 3.9: Combinación de datos de clima y de producción se ha realizado anteriormente para los ficheros de consumo. Como se había detallado en la Sección 3.3.1.3, se emplea el *notebook datasamples_process.ipynb* para automatizar este proceso y obtener la media de los valores de potencia. Como este TFM se engloba en un contexto de SGs, se enfoca la operación en la columna de medidas globales de producción fotovoltaica. Tras la ejecución del *notebook*, se obtiene un fichero con los campos definidos en la Tabla 3.15. Adicionalmente, se emplea la librería de *Python*, *matplotlib*, para representar gráficamente en la Figura 3.21 los valores de potencia recogidos en el fichero en órdenes de kW para simplificar el análisis.

Campo	Descripción	Unidades
<i>datetime</i>	Fecha del valor promedio	datetime
<i>H</i>	Hora del valor promedio	-
<i>solar</i>	Electricidad producida por fuentes fotovoltaicas	MWh

Tabla 3.15: Estructura de campos del fichero *mean_prod.csv*




Figura 3.21: Gráfica de energía solar producida a nivel global (*SustDataED*)

De la misma forma, teniendo en cuenta el rango temporal que se ha ajustado anteriormente para los datos de consumo (ver Sección 3.3.1.5), se representan a modo comparativo los valores de temperatura y de potencia medidos en las Figuras 3.22 y 3.23, respectivamente.

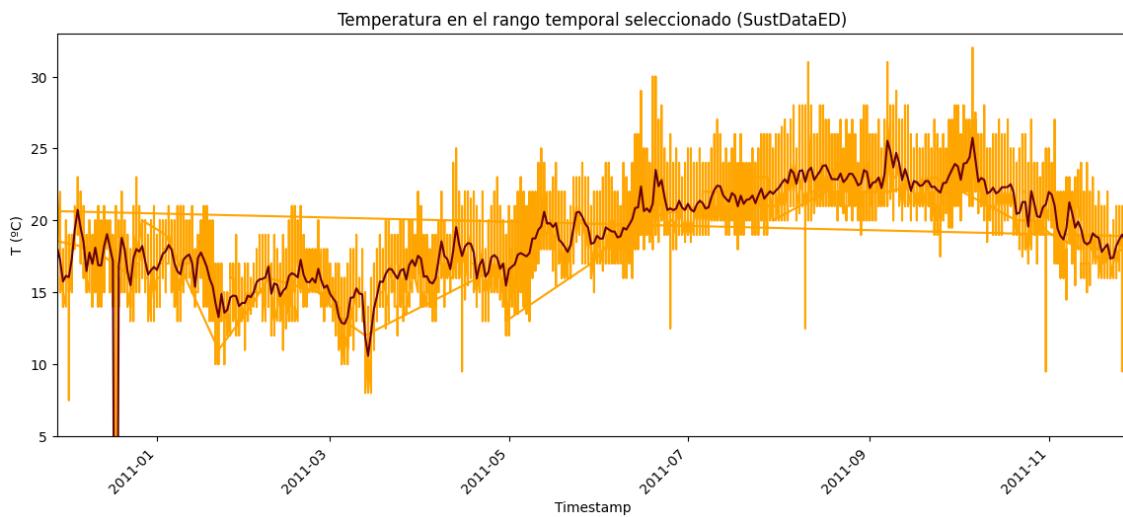


Figura 3.22: Gráfica de temperatura en el rango seleccionado (*SustDataED*)




Figura 3.23: Gráfica de energía solar producida en el rango seleccionado (*SustDataED*)

A priori, se podría apreciar que los valores reflejados de generación energética presentan cierta correlación con la temperatura a partir del mes de enero de 2011 y se encuentran diferencias entre los rangos de valores que se manejan en los meses de invierno y los de verano, a medida que se incrementa la temperatura. El análisis se fija a partir de este mes porque es en este momento cuando crecen las dimensiones del sistema fotovoltaico y se produce un salto en los valores medidos, conllevando un incremento de la potencia que se puede generar.

Por tanto, no sería correcto enfocar la comparación entre la temperatura y la potencia en los meses correspondientes al año 2010, ya que el sistema fotovoltaico no es equivalente al del año posterior. De forma adicional, se muestran de una forma más gráfica en la Figura 3.24 los valores de temperatura y potencia generada en cada instante para la primera semana de agosto.

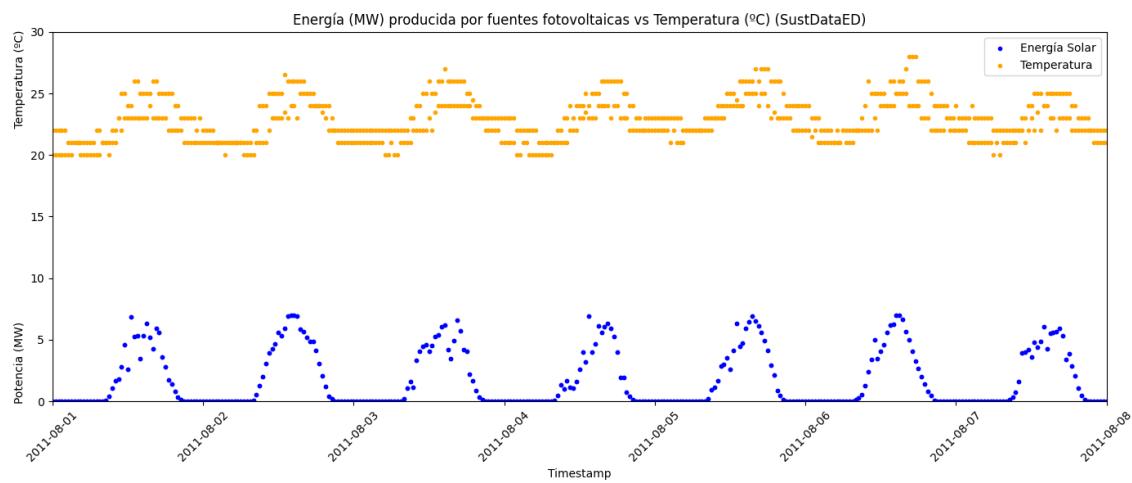


Figura 3.24: Correlación entre temperatura y energía solar producida en el mes de agosto (*SustDataED*)

No obstante, la Figura 3.24 puede dar una perspectiva equivocada sobre la relación directa que realmente se produce entre los valores y, por ello, es preciso centrar el estudio en la matriz de valores de correlación. A continuación, en la Figura 3.25 se representa en forma de mapa de calor la misma y se puede determinar de forma clara que, en conjunto, la temperatura presenta una escasa correlación hacia la potencia generada, suponiendo un valor de 0,279. Para el resto de parámetros tampoco se mejora, lo que dificulta el análisis entre la producción energética y las condiciones climáticas si se emplean los datos de *SustDataED*.

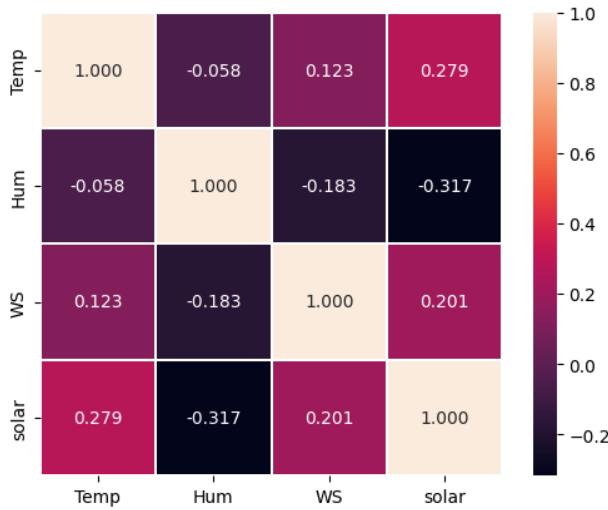


Figura 3.25: Representación de los valores de correlación mediante un mapa de calor (*SustDataED*)

3.3.2.2. Preprocesamiento de datos de *PVWatts*

El preprocesamiento de los datos extraídos de la herramienta *PVWatts* consisten principalmente en el formateo de los mismos y en la adecuación de los valores en cada instante para el posterior cálculo de las cargas. Como motivo de esto, se añaden las operaciones necesarias en el notebook *preprocessing_production.ipynb*.

Como se había expuesto en la Sección 3.2.2.3, además de en las Tablas 3.9 y 3.10, *PVWatts* proporcionaba dos datasets que replicaban un año completo de mediciones. En este caso, el preprocesamiento se va a enfocar en el que contiene las medidas adquiridas por hora para un año completo. Por tanto, teniendo en cuenta esta frecuencia de adquisición, no es necesario a priori sintetizar los datos como se había realizado en el caso de *SustDataED* (ver Sección 3.3.1.3), para el cual se transformaban muestras adquiridas cada minuto a valores promediados por hora.

Tampoco se requiere combinar los datos climáticos y ambientales con los valores de producción fotovoltaica, ya que el dataset los proporciona directamente todos en un mismo fichero (ver Tabla 3.10). No obstante, el paso que sí se debe realizar en esta fase de procesamiento es establecer una marca de tiempo específica a cada una de las filas de datos. Es decir, como la herramienta *PVWatts* genera un dataset a partir de la simulación de un sistema real de producción energética, las medidas dadas hacen referencia a una hora, día y mes, pero no se especifican para un año en concreto, sino que representan valores generalizados.

Considerando lo anterior, se debe añadir al dataset de origen una nueva columna dedicada a los valores de marca de tiempo de cada instante (*timestamp*) para poder indicar el año. Este paso es imprescindible para permitir posteriormente la comparación los datos de consumo con los de producción y establecer las cargas en el algoritmo DEN2NE, como se expondrá en las Secciones 3.3.3 y 3.5.1, respectivamente.

Es importante recordar en este punto que, para el desarrollo de este TFM, se ha seleccionado anteriormente el segundo despliegue de *SustDataED* y se ha reducido el manejo de dicho dataset a un rango temporal especificado entre los años 2010 y 2011. No obstante, en este paso del procesamiento del dataset de *PVWatts*, el fichero que se decide generar a la salida va a abarcar un conjunto de datos de producción con marcas de tiempo comprendidas entre los años 2010 y 2014.

En otros términos, se tienen en cuenta los cuatro despliegues para obtener el rango temporal completo de medidas que proporciona el dataset *SustDataED*. El motivo de realizarlo de esta manera es por si en un futuro se necesitara emplear otro despliegue diferente al seleccionado a priori, aportando así cierta flexibilidad. En la Figura 3.26 se representan los valores de potencia generada obtenidos en la simulación para el rango temporal del segundo despliegue.

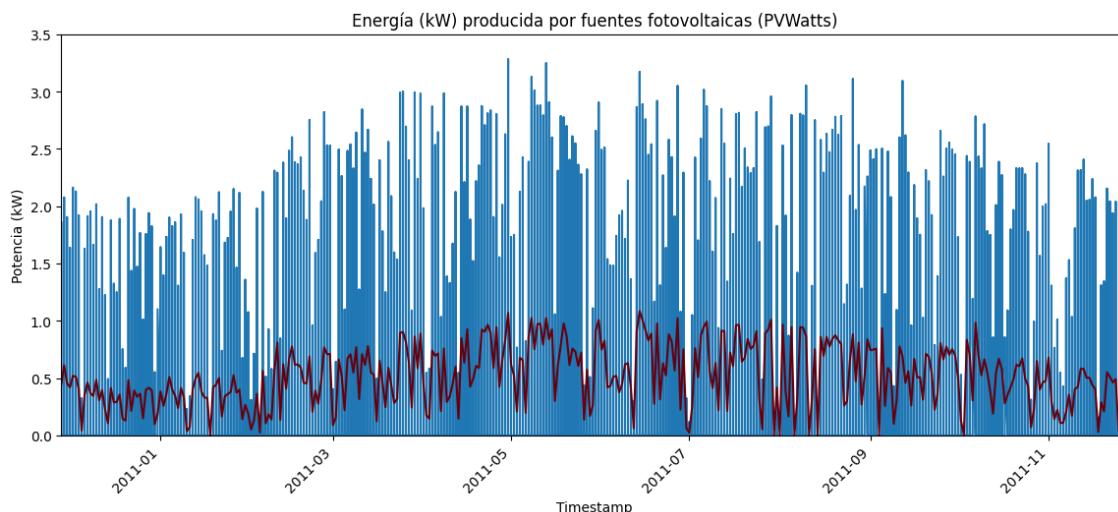


Figura 3.26: Gráfica de energía solar producida en el rango seleccionado (*PVWatts*)

Por otro lado, a modo de simplificar la información y de visualizar de una forma gráfica la correlación existente entre cada uno de los parámetros, se introduce la Figura 3.27 para representar la matriz de valores mediante un mapa de calor. Un valor igual a 1 indica

una correlación positiva perfecta y, como se puede apreciar, la radiación en cada instante incide de una manera directa en la cantidad de potencia generada. Coherentemente, la más destacable a observar es la radiación en el plano del array POA con un valor 0.999. Se pueden observar estas correlaciones también, en las gráficas expuestas en la Figura 3.30.




Figura 3.27: Representación de los valores de correlación mediante un mapa de calor (*PVWatts*)

De la misma forma que se ha realizado en la Sección 3.3.2.1 para los datos de *Sust-DataED*, se representa la primera semana de agosto a modo de ejemplo para observar la correlación entre los valores de potencia en cada instante y los parámetros ambientales y climáticos. En la Figura 3.28 se comparan los valores de temperatura, tanto ambiental como de la célula, con los de potencia generada en órdenes de kW. Se puede apreciar que, a mayores temperaturas adquiridas por la célula fotovoltaica, se incrementa la potencia generada. No obstante, es preciso indicar que la temperatura de las células puede llegar a ser un factor limitante si se supera el máximo recomendado, puesto que perjudicaría gravemente al rendimiento del sistema.

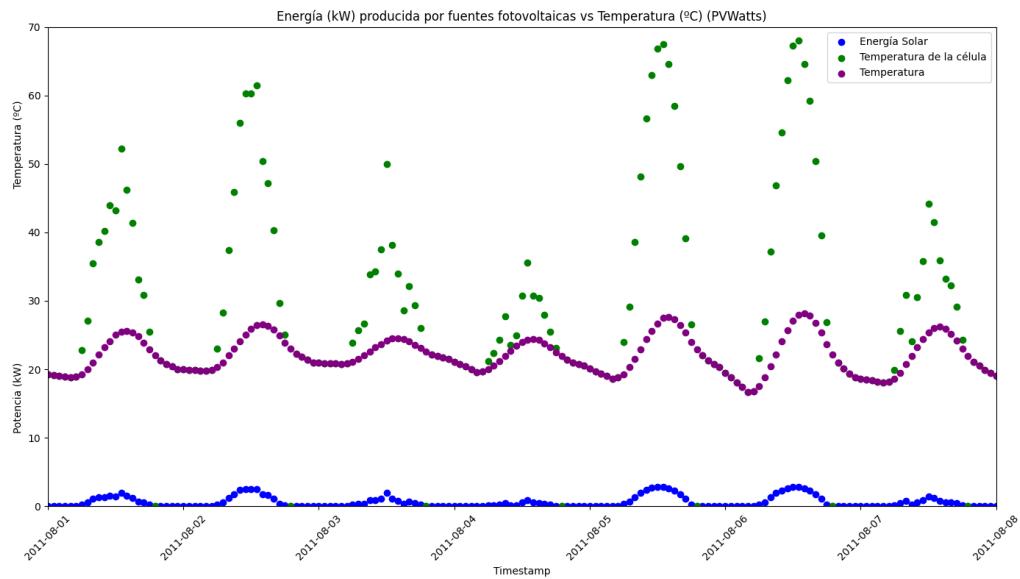


Figura 3.28: Correlación entre temperatura y energía solar producida en el mes de agosto (*PV-Watts*)

Por otro lado, en la Figura 3.29 se representan los valores de índice de radiación en el plano del array (POA) y de radiación difusa (DIF) frente a la potencia en cada instante. Como se expuso en la Sección 3.2.2.3, el primero está directamente relacionado con el índice de radiación directa normal (DNI) y se calcula como el producto del mismo por el ángulo de inclinación de las células. Debido a este motivo y a que el DIF depende de la dispersión introducida por la atmósfera, se observa una mayor correlación entre los valores de energía generada y los de POA.

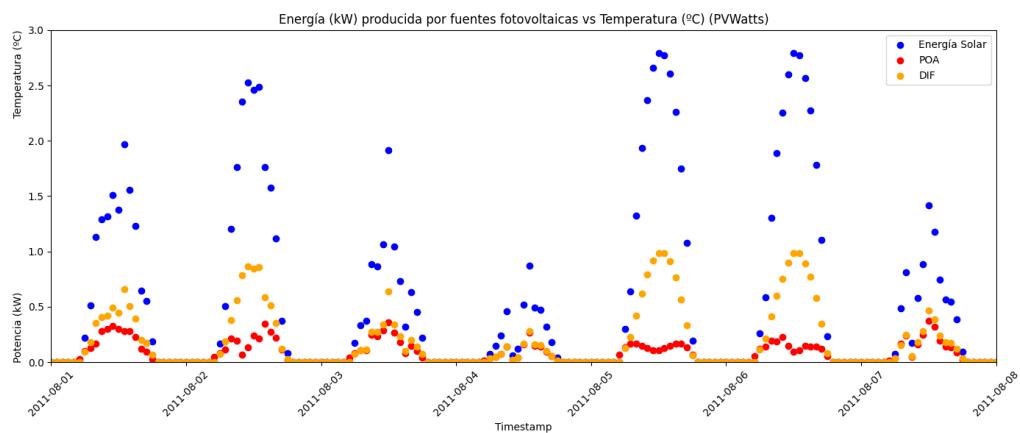


Figura 3.29: Correlación entre radiación y energía solar producida en el mes de agosto (*PVWatts*)

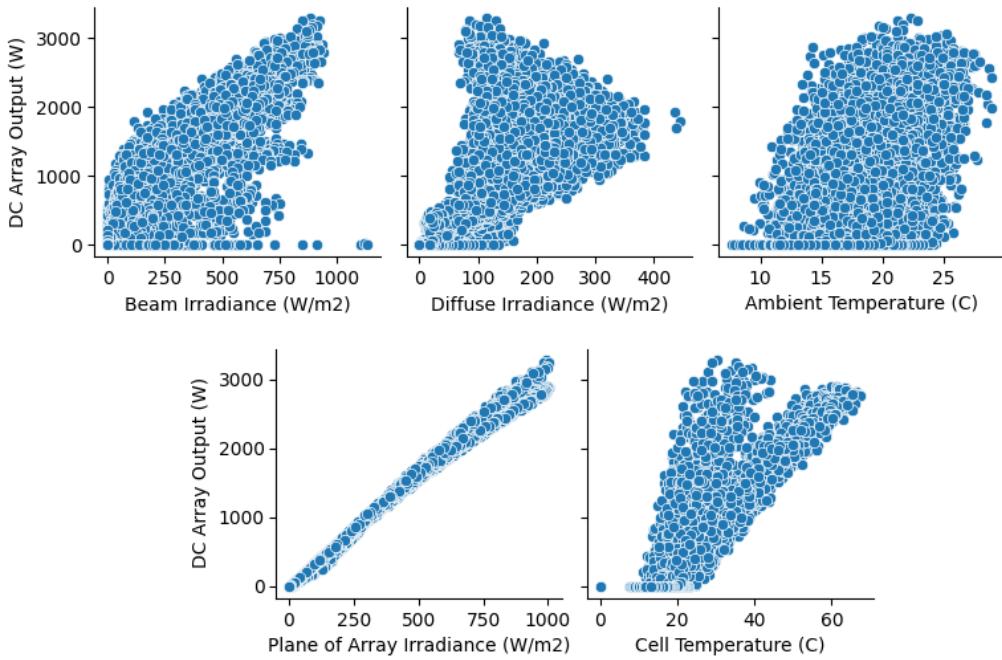


Figura 3.30: Representación de los valores de correlación mediante gráficas (*PVWatts*)

3.3.2.3. Selección de datos de producción

Como se había introducido en la Sección 3.3.2, se requería aplicar un preprocesamiento en relación con los datos de producción energética dados, tanto por el dataset *SustDataED*, como por la herramienta *PVWatts*, para poder llevar a cabo un análisis comparativo de ambos de una forma correcta. Una vez implementados estos pasos, se puede tomar la decisión de seleccionar la fuente de datos más adecuada para el desarrollo de este TFM a partir de las características observadas y las representaciones gráficas expuestas en este documento. Añadiendo también a este análisis, el estudio realizado en las Secciones 3.1.1 y 3.2.2, se determina finalmente, la elección de *PVWatts* como fuente de datos de producción energética.

Esta decisión se rige por la razón principal de la precisión que aportan los datos al tratarse de un dataset generado a partir de la simulación de un sistema real y de la configuración de múltiples parámetros de entrada en referencia a la ubicación y a los requisitos técnicos deseados (ver Sección 3.2.2). Es decir, los resultados proporcionados por la herramienta han sido analizados en profundidad, además de contrastados con el estudio teórico, lo que justifica su precisión respecto a un caso real (ver Sección 3.2.2.3).

Otra ventaja que aporta el empleo de la herramienta *PVWatts*, es la posibilidad de rediseño y de replicación de los datos anuales. En caso de desecharse, se permitiría simular otro tipo de sistema fotovoltaico real y determinar parámetros de entrada diferentes en la configuración, lo que supone un desarrollo mucho más flexible. Además, se aporta una mayor información que *SustDataED* sobre las condiciones climáticas que se dan en cada instante, sobre todo en términos de radiación. Esto es importante, ya que, como se podía apreciar en los mapas de calor expuestos (ver Figuras 3.25 y 3.27), los valores respectivos a los diferentes tipos de radiación presentan una gran correlación con la cantidad de potencia a la salida del sistema fotovoltaico. Así, se permite determinar de forma directa la potencia que se puede generar en cada instante. Sin embargo, no ocurría de la misma forma para los datos de temperatura dados por *SustDataED*, lo que suponía una gran limitación para analizar la información.

Por otro lado, el dataset *SustDataED*, a diferencia de *PVWatts*, sí que se basa en medidas de un despliegue de viviendas real, pero los valores de generación energética que aporta se definen en términos globales a todas los hogares. No se aporta información exacta sobre el número de viviendas a los que se abastece, ni sobre las dimensiones del sistema o sistemas fotovoltaicos de los que se han adquirido los datos en cada instante. En consecuencia, no se puede evaluar su utilidad específicamente en un entorno de SGs como motivo de los objetivos de este TFM y se introducen dificultades para analizar los valores de potencia dados. Por todo esto, se decide reducir el uso del dataset *SustDataED* a los datos de consumo de los hogares.

3.3.3. Combinación de datos de consumo y de producción

Se introduce la programación de un nuevo *notebook*, denominado como *power_selection*, que va a determinar los ficheros con los valores de potencia finales mediante la combinación de los datos de consumo y de producción preprocesados. Es decir, en este punto se parte, por un lado, de los 23 ficheros de consumo (*consum_x.csv*), obtenidos de *SustDataED* y que han sido creados para representar el comportamiento eléctrico de las 23 viviendas que componen el segundo despliegue. Por otro lado, se dispone del dataset final de producción, extraído de la herramienta *PVWatts* y preprocesado para ser aplicado al rango temporal seleccionado.

Por tanto, el objetivo del *notebook* en cuestión se basa en obtener a la salida 23 nuevos ficheros que contengan los valores de cargas netas para cada instante, las cuales se establecerán posteriormente en el algoritmo DEN2NE (ver Sección 3.5.1). Para ello, es necesario combinar cada fichero de consumo con los datos de producción y, después, aplicar la diferencia entre la potencia generada y consumida a partir de la marca de tiempo dada en

cada fila. Se escoge como ejemplo la vivienda con identificador 1 para representar en las Figuras 3.31 y 3.32 los valores de carga resultante a partir de los ficheros de entrada. En el caso de la Figura 3.32, se muestran también de forma continua los valores promedios diarios de carga.

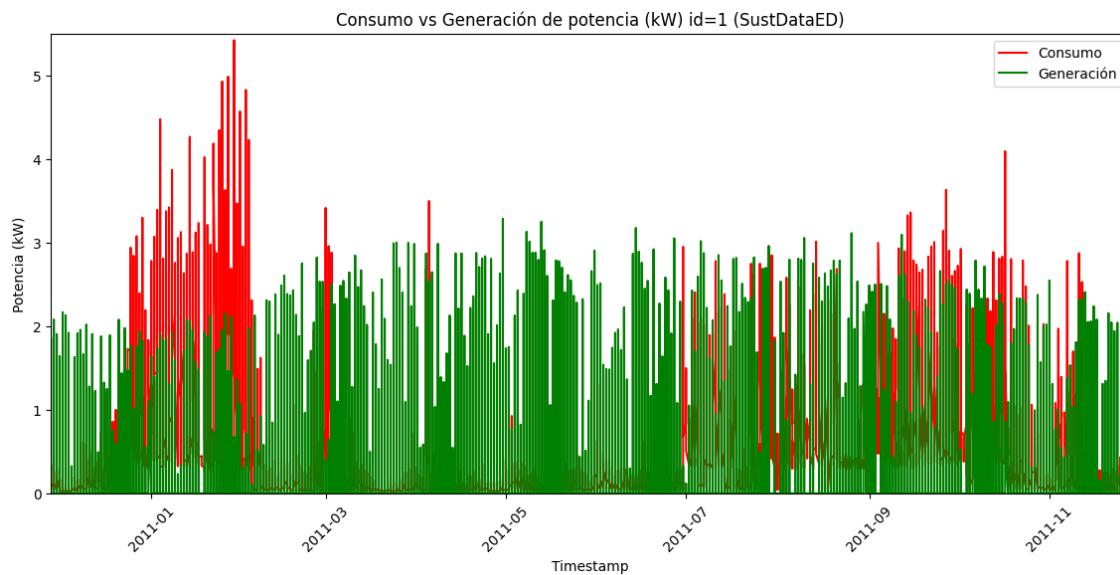


Figura 3.31: Comparación entre el consumo y la generación de potencia en la vivienda 1 en el rango seleccionado

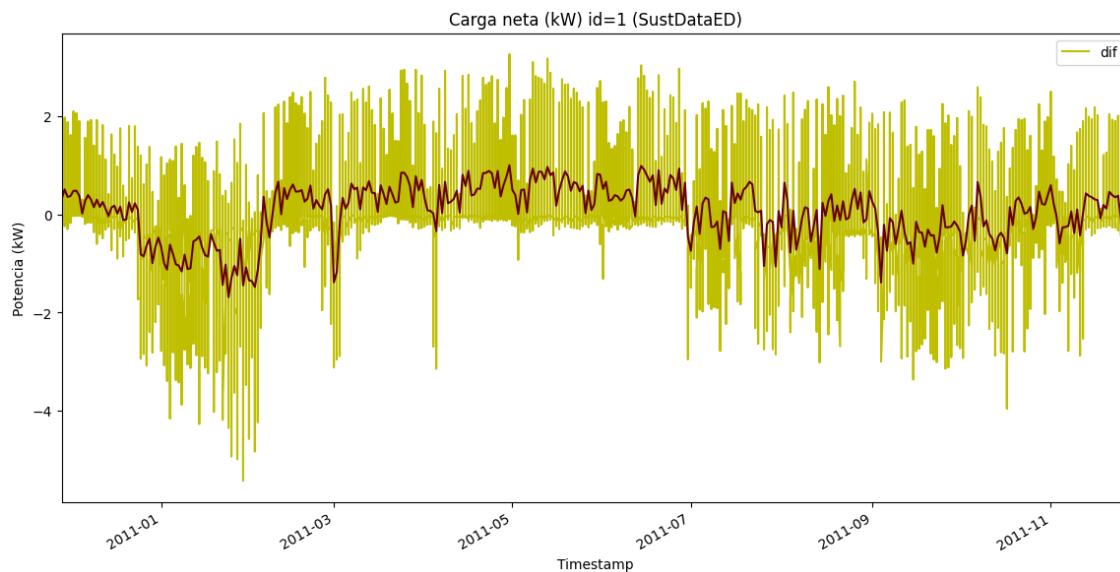


Figura 3.32: Gráfica de la carga neta resultante en la vivienda 1 en el rango seleccionado

Como se realiza una operación de combinación de los datos de consumo y de producción, los campos de los nuevos ficheros de cargas suponen los definidos, tanto en la Tabla 3.14, como en la Tabla 3.10, exceptuando algunos parámetros que se descartan para el desarrollo, como son el albedo o la velocidad del viento. En la Tabla 3.16, se especifican los campos definitivos.

Campo	Descripción	Unidades
<i>timestamp</i>	Instante temporal de medida	datetime
<i>datetime</i>	Fecha del valor promedio	datetime
<i>H</i>	Hora del valor promedio	-
<i>iid</i>	Identificador de vivienda	-
<i>Diffuse Irradiance</i>	Índice de radiación difusa (DIF)	W/m ²
<i>Plane of Array Irradiance</i>	Índice de radiación en el plano del array (POA)	W/m ²
<i>Ambient Temperature</i>	Temperatura ambiente	C
<i>Cell Temperature</i>	Temperatura de las células solares	C
<i>DC Array Output</i>	Potencia de salida DC del array	W
<i>AC System Output</i>	Potencia de salida AC del sistema	W
<i>Pavg</i>	Potencia consumida	W
<i>Dif</i>	Carga neta calculada	W

Tabla 3.16: Dataset resultante de la etapa de procesamiento

Por otro lado, en cuanto a la nomenclatura, cada fichero se nombra como *load_x.csv*, donde x hace referencia al identificador de la vivienda a la que pertenecen las cargas calculadas. Por tanto, se puede expresar que, después de toda la fase de procesado, se consigue el objetivo de obtener un dataset final compuesto por 23 ficheros con cargas, que supondrá la base principal de la operativa del algoritmo DEN2NE para construir el conjunto de datos a entrenar.

3.4. Planteamiento de escenarios y generación de topologías en BRITE

La presente Sección está dedicada al planteamiento de una serie de escenarios de red y a la consecuente generación de topologías mediante el empleo de la herramienta BRITE, cuyo funcionamiento ha sido descrito en la Sección 2.6.1. La importancia de esta fase del diseño viene dada por la necesidad de aplicar la operativa del algoritmo DEN2NE sobre un múltiples topologías para obtener, finalmente, el dataset sobre el que se entrenarán y

desarrollarán los modelos de ML. Se debe tener en cuenta que, para que este conjunto de datos final permita aportar suficiente información útil a los modelos, el número de topologías a generar en BRITE debe de ser relativamente elevado.

3.4.1. Planteamiento de escenarios y configuración de BRITE

Para emplear la herramienta, se deben plantear los escenarios de red sobre los que se desea basar la generación de topologías. Por ello, es preciso definir la configuración de los parámetros de entrada en el script *autogenerador.sh*, tomando en consideración el requerimiento anterior. Como se especificaba en la Sección 2.6.1.3, este script está dedicado a la automatización de la ejecución, tanto de la herramienta, como del *parser*, para obtener a la salida los ficheros finales con las posiciones de los nodos en el plano y con la información relativa a las distancias y a los nodos que se interconectan con cada enlace (*Nodos.txt* y *Enlaces.txt*).

Por ello, se puede expresar que el cálculo del número total de topologías que se pueden generar con BRITE resultará de operar el producto de los siguientes parámetros de entrada configurados:

- Número de modelos de topología a emplear: Como se había introducido en la Sección 2.6.1.2, este TFM se va a basar en el empleo de topologías a nivel de router y, en particular, en los modelos Router Waxman y Router Barabasi-Albert.
- Número de dimensiones: Para las pruebas a simular en el algoritmo DEN2NE, se pretende manejar topologías con una gran cantidad de nodos, pero reduciendo los saltos de incremento del total. Por ello, se configura una generación desde 100 a 200 nodos con un incremento de 50 en 50, suponiendo la configuración de 3 dimensiones de topologías (100, 150 y 200 nodos).
- Número de grados de conectividad: Este parámetro determina el número de enlaces por nodo y se especifican 3 grados m diferentes en el script. Es preciso indicar que, como en DEN2NE se tratarán los enlaces como bidireccionales, realmente cada topología tendrá un grado $2m$.
- Número de semillas de generación: Es importante destacar que para la generación de topologías se aplican 10 ficheros de semillas. Esto tiene como resultado la generación de 10 topologías diferentes para cada uno de los escenarios configurados o, en otros términos, para cada una de las configuraciones posibles de los parámetros de entrada.

Adicionalmente, se deben determinar otros parámetros que hacen referencia a los nodos, como son el modo de introducción al plano y su posicionamiento. Respectivamente, se establece una introducción incremental y un posicionamiento totalmente aleatorio alrededor del plano. También, los parámetros específicos del modelo Router Waxman, α y β , que toman valores de 0.2 y 0.15, respectivamente.

Código 3.10: Configuración de los parámetros de entrada en el script de automatización de BRITE

```

1 topologia_rt_waxman=1 # Empleo de modelo RTWaxman
2 topologia_rt_barabasi=2 # Empleo de modelo RTBarabasi
3 nodos=$((seq 100 50 200)) # Número de nodos por topología (dimensiones)
4 m=(1 2 3) # El grado de conectividad real es 2, 4, 6
5 n_topologias_distintasxnodo=10 # Número de topologías en función del número de semillas
6
7 NodePlacement=1 # Posicionamiento aleatorio de los nodos
8 GrowthType=1 # Modo de introducción incremental
9
10 #parámetros específicos de Waxman
11 alpha=0.2
12 beta=0.15

```

3.4.2. Resultados de la generación de topologías

Considerando los parámetros de entrada configurados anteriormente, se puede cuantificar el número total de topologías que resultará de la ejecución del script *autogenerador.sh* a partir de la siguiente expresión:

$$N_{topos} = N_{modelos} \times N_{dimensiones} \times N_{grados} \times N_{seeds_gen}$$

$$N_{topos} = 2 \times 3 \times 3 \times 10 = 180$$

Es preciso indicar que en el caso de requerirse un mayor número de topologías a simular en DEN2NE, bastaría únicamente con modificar el rango establecido para el número de nodos o el valor del incremento de los mismos. No obstante, puesto que se pretende tener en cuenta para la ejecución del algoritmo el dataset resultante de la etapa de procesamiento (ver Sección 3.3.3), no se precisa aumentar el número de topologías a priori. Estos motivos vendrán justificados detalladamente en la Sección 3.5.2, dedicada a la configuración de los parámetros de entrada de DEN2NE.

3.5. Simulación de las topologías en DEN2NE

Esta Sección viene dada por el objetivo de obtener el conjunto de datos final sobre el que se entrenarán los modelos de ML en el Capítulo 4. Para lograrlo, se necesita emplear el algoritmo DEN2NE para realizar un gran número de simulaciones a partir de las topologías generadas en la herramienta BRITE (ver Sección 3.4).

En primera instancia, es imprescindible implementar una serie de modificaciones en el algoritmo DEN2NE para ajustar su funcionamiento al requerido para obtener el dataset final. La secuencia de acciones que se llevará a cabo se detallará en la Sección 3.5.1. Es importante indicar que es en este punto donde se introducirán las cargas netas resultantes de haber combinado los datos de consumo y de producción en la etapa de procesamiento (ver Sección 3.3.3). De la misma forma, se detallará el método de determinación de errores en las pruebas que servirá de base para después entrenar los modelos de ML.

Por consiguiente, se añade la Sección 3.5.2 donde se especificará cómo se configurarán los parámetros de entrada requeridos para lanzar múltiples simulaciones. Además, se cuantificará el número total de pruebas posibles que se podrían llegar a realizar a partir de la información procesada y de las topologías generadas.

Se comprobará a través de diferentes pruebas que los cambios introducidos en el algoritmo DEN2NE producen una operativa acorde a las necesidades de este TFM. Por último, a partir de los resultados obtenidos en las simulaciones, se concluirá con la Sección 3.5.3 para exponer las características del dataset final que se utilizará para el entrenamiento de los modelos.

3.5.1. Adaptación del algoritmo DEN2NE a las pruebas

3.5.1.1. Cargas y simtest

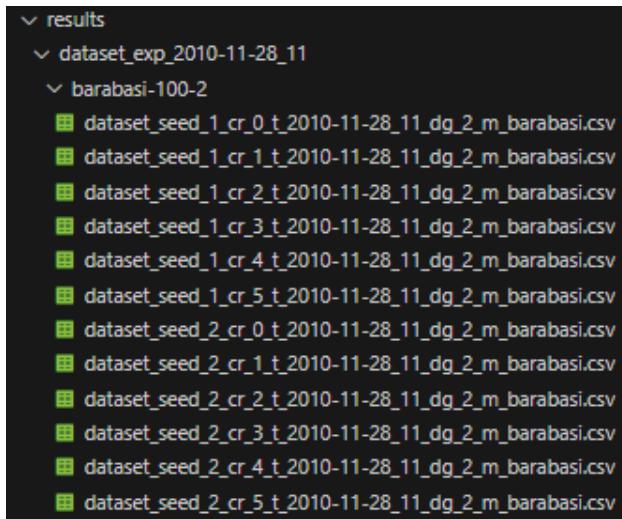


Figura 3.33: nomenclatura de los directorios y ficheros de resultados

3.5.2. Configuración de los parámetros de entrada

Para ejecutar DEN2NE, es preciso definir la configuración de los parámetros de entrada en el script *auto_run.sh*. En la Sección 2.3 se detallaba que este script se había diseñado con el objetivo de automatizar las simulaciones en el algoritmo y, como se ha expuesto en la Sección 3.5.1, ha sido necesario ajustar el mismo a los requerimientos de las pruebas de este TFM. En este punto, se puede expresar que el cálculo de la cantidad total de configuraciones que se podrían llegar a realizar en DEN2NE viene dado por el producto del siguiente conjunto de características:

- El número total de topologías generadas: En la Sección 3.4.2 se especifica una cantidad total de 180 topologías obtenidas a la salida de la herramienta BRITE.
- El número de instantes temporales del dataset: El conjunto de datos resultante de la etapa de procesamiento, detallado en la Sección 3.3.3 y, específicamente, en la Tabla 3.16, abarca una cantidad de filas igual al total de instantes temporales que se han tomado en consideración. En otros términos, al tratarse de muestras tomadas cada hora durante un rango temporal que comprende un año completo, su valor se calcula como $24 \times 365 = 8760$ instantes.
- El número de criterios: Como se detallaba en la Sección 2.3, DEN2NE presenta 6

criterios de selección de los mejores caminos hacia el nodo raíz. En este caso, se implementan a las pruebas los 6 tipos.

- El número de tipos de escenarios de red: En la Sección 2.3, también se exponían los 4 tipos de escenarios que permite configurar el algoritmo. Teniendo en cuenta que las simulaciones deben acercarse a un entorno de SG real y que el objetivo se basa en encontrar las transacciones energéticas entre nodos que superen la capacidad del enlace, se determina únicamente el escenario de pérdidas y límite de capacidad.
- Modo de limitación de carga: Se especifica únicamente el modo que determina valores de carga ilimitados.
- El número de semillas de ejecución: De la misma manera que se ha especificado anteriormente para BRITE (ver Sección 3.4.1), se aplica al algoritmo DEN2NE un conjunto de archivos de semillas para obtener simulaciones diferentes a partir de una misma topología a la entrada. En este caso, debido a la cantidad de datos que ya se maneja y para no introducir latencias considerables en el lanzamiento de las pruebas, se especifican 5 semillas por topología.

Por otro lado, en el caso de los parámetros de entrada referentes a las topologías, como son el número de nodos por topología, los modelos a simular y el número de semillas de generación, se sigue la misma configuración especificada en la ejecución de BRITE (ver Sección 3.4.1). No obstante, para el grado de conectividad se determinan directamente los valores reales, suponiendo enlaces bidireccionales.

Código 3.11: Configuración de los parámetros de entrada en el script de automatización de DEN2NE

```

1 TOPO_CRITERIONS=(0 1 2 3 4 5) # Criterios de selección de IDs
2 TOPO_BEHAVIORAL=3 # Tipo de escenario de red = modo Losses and Capacity (3)
3 TOPO_LOAD_LIMIT=0 # Sin límite de carga
4 TOPO_RUNS=5 # Seeds de ejecución de DEN2NE
5
6 TOPO_NAMES=('barabasi' 'waxman') # Empleo de modelos RTWaxman y RTBarabasi (igual que BRITE)
7 TOPO_NUM_NODES=$((seq 100 50 200)) # Número de nodos por topología (igual que BRITE)
8 TOPO_DEGREES=(2 4 6) # El grado de conectividad real (en BRITE 1, 2, 3)
9 TOPO_SEEDS=(1 2 3 4 5 6 7 8 9 10) # Seeds de generación de BRITE

```

Por tanto, teniendo en cuenta la configuración implementada para los parámetros de entrada, se puede determinar el número total de simulaciones únicas posibles a partir de la siguiente expresión:

$$N_{sim} = N_{topos} \times N_{instantes} \times N_{criterios} \times N_{escenarios} \times N_{Nlimit} \times N_{sem_ejec}$$

$$N_{sim} = 180 \times 8760 \times 6 \times 1 \times 1 \times 5 = 47304000$$

3.5.3. Creación del dataset final y conclusiones de las pruebas

Teniendo en cuenta lo anterior, se decide crear un nuevo *notebook*, *datafinal.ipynb*, con el fin de conseguir a la salida un conjunto de datos final por cada instante temporal especificado en las pruebas. Como se podía apreciar en la Figura 3.33, cada experimento creaba un directorio con la fecha y hora determinadas (ej. *dataset_exp_2011-04-28_11*) y, en su interior, se generaban los diferentes ficheros de resultados, organizados por carpetas en función del modelo y el grado de conectividad al que hacían referencia (ej. *barabasi-200-6*).

Por ello, a modo de simplificar el tratamiento de los resultados del algoritmo, el primer paso que se implementa en el *notebook* se basa en el agrupamiento en un mismo *dataframe* de todos los ficheros que se han generado para un instante determinado. Después, es importante comprobar que el porcentaje total de error u *overflow* dado para el instante en cuestión no es nulo. Es decir, para cada instante temporal que se pruebe, se debe conseguir un conjunto de datos que contenga algunas filas el valor *overflow* activo para después, entrenar de forma precisa los modelos de ML y poder predecir cuándo se producirán estos errores.

El siguiente paso consiste en combinar los datos obtenidos de los resultados con la información de las viviendas aportada en el fichero de test. Es importante recordar que este fichero de test (ej. *test_2010-11-28_11.csv*) se creaba a partir de filtrar en el dataset resultante del procesamiento las medidas de las viviendas para un instante temporal determinado y se aplicaba a la entrada de DEN2NE para definir los valores de carga (ver Sección 3.5.1.1). Por ello, en este punto es combinar cada fila del *dataframe* de resultados con la información real de cada vivienda en función del identificador del nodo al que se hace referencia.

Código 3.12: Combinación de resultados y test

```
1 df_merged = pd.merge(df, df_sim, left_on='origen_id', right_on='iid', how='outer') # Operación ←
    ↘ de merge
```

Tras esta operación, el nuevo *dataframe* se constituye por todas las columnas necesarias, aunque antes estas se deben revisar y eliminar si vienen replicadas, como ocurre en el caso del identificador y la fecha. Finalmente, se almacena el *dataframe* limpio en un fichero con formato .csv, tratándose del dataset final que se empleará en la etapa de desarrollo. Este fichero contiene los campos definidos en la Tabla 3.17 y sigue una nomenclatura formada

por la marca de tiempo a la que hace referencia (ej. *2010-12-28_11.csv*).

Campo	Descripción	Unidades
<i>timestamp</i>	Instante temporal de medida	datetime
<i>datetime</i>	Fecha del valor promedio	datetime
<i>H</i>	Hora del valor promedio	-
<i>overflow</i>	Etiqueta binaria de superación de carga	-
<i>cap</i>	Capacidad del enlace	kW
<i>load</i>	Carga neta (<i>Dif</i>)	kW
<i>dist</i>	Distancia	m
<i>origen_id</i>	Identificador de nodo origen	-
<i>dest_id</i>	Identificador de nodo destino	-
<i>len_origen_tag</i>	Longitud de la etiqueta del nodo origen	-
<i>len_dest_tag</i>	Longitud de la etiqueta del nodo destino	-
<i>modelo</i>	Modelo de topología	-
<i>criterion</i>	Criterio de selección de IDs	-
<i>degree</i>	Grado de conectividad	-
<i>total_balance</i>	Balance de carga global	-
<i>abs_flux</i>	Flujo total de carga en el nodo raíz	-
<i>Diffuse Irradiance</i>	Índice de radiación difusa (DIF)	W/m ²
<i>Plane of Array Irradiance</i>	Índice de radiación en el plano del array (POA)	W/m ²
<i>Ambient Temperature</i>	Temperatura ambiente	C
<i>Cell Temperature</i>	Temperatura de las células solares	C
<i>DC Array Output</i>	Potencia de salida DC del array	W
<i>AC System Output</i>	Potencia de salida AC del sistema	W
<i>Pavg</i>	Potencia consumida	W
<i>Dif</i>	Carga neta calculada	W

Tabla 3.17: Dataset final obtenido por cada instante temporal probado en DEN2NE

Con la obtención de este conjunto de datos se finaliza la etapa de diseño y, por ende, el presente Capítulo. A partir de los resultados obtenidos, se puede expresar de forma concluyente que se cumple el objetivo principal de generar el dataset final que suponga la base del entrenamiento y el desarrollo de los modelos de ML que se plantearán en el Capítulo 4. Adicionalmente, a modo de simplificar la compresión de la secuencia de acciones que se han llevado a cabo durante este Capítulo, se representa la Figura 3.34. En el diagrama se exponen los ficheros creados en cada paso, el tratamiento de los datos y los procesos ejecutados.




Figura 3.34: Diagrama completo de diseño del dataset final

4. Desarrollo y evaluación del modelo

4.1. Selección de modelos

4.1.0.1. Random Forest (RF)

<https://www.analyticsvidhya.com/blog/2021/10/an-introduction-to-random-forest-algorithm-for-beginners/>

4.2. Support Vector Machines (SVM)

4.2.0.1. Red Neuronal Artificial (ANN)

5. Conclusiones y trabajo futuro

Bibliografía

- [1] “¿Qué son las Smart Grids o redes inteligentes? | Repsol,” <https://www.repsol.com/es/energia-futuro/tecnologia-innovacion/smart-grids/index.cshtml>, [Accessed 27-10-2023].
- [2] “El impacto de las Smart Grids y la evolución de la Inteligencia Artificial en las redes eléctricas,” <https://es.linkedin.com/pulse/el-impacto-de-las-smart-grids-y-la-evolucion-de-la-inteligencia-artificial-en-las-redes-electricas>, 2023, [Accessed 27-10-2023].
- [3] D. Carrascal, E. Rojas, J. A. Carral, I. Martinez-Yelmo, and J. Alvarez-Horcajo, “Topology-aware scalable resource management in multi-hop dense networks [Unpublished],” 2023.
- [4] A. Medina, A. Lakhina, I. Matta, and J. Byers, “BRITE: an approach to universal topology generation,” in *MASCOTS 2001, Proceedings Ninth International Symposium on Modeling, Analysis and Simulation of Computer and Telecommunication Systems*, 2001, pp. 346–353.
- [5] T. Vijayapriya, “Smart grid: An overview,” *Smart Grid and Renewable Energy*, vol. 02, pp. 305–311, 01 2011.
- [6] I. S. Grid, “IEEE Smart Grid 2015 Annual Report,” <https://smartgrid.ieee.org/about-ieee-smart-grid>, 2015, [Accessed 10-01-2024].
- [7] U. D. of Energy, “2009 Smart Grid System Report (July 2009),” <https://www.energy.gov/oe/articles/2009-smart-grid-system-report-july-2009>, 2009, [Accessed 14-01-2024].
- [8] “Smartgrids, transacciones de energía basadas en blockchain,” <https://iotfutura.com/2018/12/smargrid-basada-en-iot-y-blockchain/>, 2018, [Accessed 10-01-2024].
- [9] H.-P. c. Roy Pratt, “Resisting Temptation: the Seven Sins of Smart Grid,” <https://www.power-grid.com/news/resisting-temptation-the-seven-sins-of-smart-grid/#gref>, 2010, [Accessed 10-01-2024].

- [10] “Referente mundial en ‘smart grids,’” <https://www.iberdrola.com/conocenos/nuestra-actividad/smart-grids>, [Accessed 26-02-2024].
 - [11] P. Gyasi, “Smart grids and demand response: Conceptual review,” 09 2019.
 - [12] W. Lou, S. Zhu, J. Ding, T. Zhu, M. Wang, L. Sun, F. Zhong, and X. Yang, “Transactive demand–response framework for high renewable penetrated multi-energy prosumer aggregators in the context of a smart grid,” *Applied Sciences*, vol. 13, p. 10083, 09 2023.
 - [13] Iberdrola, “DSO, ¿cómo transformar la gestión de redes hacia un modelo más inteligente?” <https://www.iberdrola.com/innovacion/operadores-de-sistemas-de-distribucion>, [Accessed 14-01-2024].
 - [14] G. Sun, S. Shen, S. Chen, Y. Zhou, and Z. Wei, “Bidding strategy for a prosumer aggregator with stochastic renewable energy production in energy and reserve markets,” *Renewable Energy*, vol. 191, pp. 278–290, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0960148122005274>
 - [15] J. Iria and F. Soares, “An energy-as-a-service business model for aggregators of prosumers,” *Applied Energy*, vol. 347, p. 121487, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0306261923008516>
 - [16] Z. M. Bakare Mutiu Shola, Abdulkarim Abubakar, “A comprehensive overview on demand side energy management towards smart grids: challenges, solutions, and future direction,” *Energy Informatics*, vol. 6, 03 2023.
 - [17] L. Tao and Y. Gao, “Real-time pricing for smart grid with distributed energy and storage: A noncooperative game method considering spatially and temporally coupled constraints,” *International Journal of Electrical Power & Energy Systems*, vol. 115, p. 105487, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0142061519317867>
 - [18] A.-H. Mohsenian-Rad, V. Wong, J. Jatskevich, R. Schober, and A. Leon-Garcia, “Autonomous demand-side management based on game-theoretic energy consumption scheduling for the future smart grid,” *Smart Grid, IEEE Transactions on*, vol. 1, pp. 320 – 331, 01 2011.
 - [19] “Overview of CHP (Combined Heat & Power),” <https://www.alenergy.net/blogs/post/Overview-of-CHP-Combined-Heat-Power>, 2021, [Accessed 12-01-2024].
-

- [20] P. Wolfrum, M. Kautz, and J. Schäfer, “Smart operation of chp units,” *IFAC Proceedings Volumes*, vol. 45, no. 21, pp. 61–66, 2012, 8th Power Plant and Power System Control Symposium. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1474667016319450>
- [21] J. Moore and B. Shabani, “A critical study of stationary energy storage polices in australia in an international context: The role of hydrogen and battery technologies,” *Energies*, vol. 9, p. 674, 08 2016.
- [22] K. Sayed and H. Gabbar, “Chapter 18 - scada and smart energy grid control automation,” in *Smart Energy Grid Engineering*, H. A. Gabbar, Ed. Academic Press, 2017, pp. 481–514. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/B9780128053430000188>
- [23] B. T. Rolf Grünbaum, Mojtaba Noroozian, “FACTS, poderosos sistemas para una transmisión flexible de la energía,” https://library.e.abb.com/public/89318066821a283ec1256fda003b4d40/5_1999s.pdf, 1999, [Accessed 04-01-2024].
- [24] M. Donsion, J. Guemes, and J. Rodriguez, “Power quality. benefits of utilizing facts devices in electrical power systems,” in *2007 7th International Symposium on Electromagnetic Compatibility and Electromagnetic Ecology*, 2007, pp. 26–29.
- [25] M. A. Masoum and E. F. Fuchs, “Chapter 9 - the roles of filters in power systems and unified power quality conditioners,” in *Power Quality in Power Systems and Electrical Machines (Second Edition)*, second edition ed., M. A. Masoum and E. F. Fuchs, Eds. Boston: Academic Press, 2015, pp. 779–886. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/B9780128007822000099>
- [26] E. Csanyi, “Using HVDC Technology For Transmitting Electricity,” <https://electrical-engineering-portal.com/using-hvdc-technology-for-transmitting-electricity>, 2012, [Accessed 18-01-2024].
- [27] S. Cuthrell, “Offshore Wind Needs Major HVDC Transmission Expansion,” <https://eepower.com/news/offshore-wind-needs-major-hvdc-transmission-expansion/>, 2023, [Accessed 18-01-2024].
- [28] N. Mostafa, H. S. M. Ramadan, and O. Elfarouk, “Renewable energy management in smart grids by using big data analytics and machine learning,” *Machine Learning with Applications*, vol. 9, p. 100363, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2666827022000597>
-

- [29] D. Wang, X. Guan, T. Liu, Y. Gu, Y. Sun, and Y. Liu, “A survey on bad data injection attack in smart grid,” 12 2013, pp. 1–6.
- [30] J. Jiménez, “Suplantación de ARP: qué es y cómo afecta a nuestra red,” <https://www.redeszone.net/tutoriales/redes-cable/ataques-arp-spoofing-evitar/>, 2023, [Accessed 15-01-2024].
- [31] “Descubrimiento seguro de vecino de IPv6,” <https://www.juniper.net/documentation/mx/es/software/junos/neighbor-discovery/topics/topic-map/ipv6-secure-neighbor>, 2021, [Accessed 15-01-2024].
- [32] “¿Qué es la Internet de las cosas? Definición y explicación,” <https://www.kaspersky.es/resource-center/definitions/what-is-iot>, [Accessed 24-01-2024].
- [33] “¿Qué es IoT (Internet de las cosas)?” <https://aws.amazon.com/es/what-is/iot/>, [Accessed 24-01-2024].
- [34] S. Violino, S. Figorilli, C. Costa, and F. Pallottino, “Internet of beer: A review on smart technologies from mash to pint,” *Foods*, vol. 9, p. 950, 07 2020.
- [35] H. Shahinzadeh, J. Moradi, G. B. Gharehpetian, H. Nafisi, and M. Abedi, “Internet of energy (ioe) in smart power systems,” 02 2019, pp. 627–636.
- [36] E. Rojas, “DEN2NE - Distributed ENergy ENVironments and NETworks,” <https://github.com/NETSERV-UAH/den2ne-Alg>, [Accessed 10-11-2023].
- [37] “Las 7 V del Big data: Características más importantes,” <https://www.iic.uam.es/innovacion/big-data-caracteristicas-mas-importantes-7-v/>, 2019, [Accessed 12-01-2024].
- [38] Telefónica, “Las 5 V del Big Data. ¿Cómo pueden beneficiar a las empresas?” <https://www.telefonica.com/es/sala-comunicacion/blog/5-v-big-data-beneficios/>, 2020, [Accessed 13-01-2024].
- [39] B. Bhattacharai, S. Paudyal, Y. Luo, M. Mohanpurkar, K. Cheung, R. Tonkoski, R. Hovsapián, K. Myers, R. Zhang, P. Zhao, M. Manic, S. Zhang, and X. Zhang, “Big data analytics in smart grids: State-of-the-art, challenges, opportunities, and future directions,” *IET Smart Grid*, vol. 2, 03 2019.
- [40] “Diferencias entre la nube y la virtualización,” <https://www.redhat.com/es/topics/cloud-computing/cloud-vs-virtualization>, 2023, [Accessed 13-01-2024].
- [41] “Qué es la Inteligencia Artificial,” <https://planderecuperacion.gob.es/noticias/que-es-inteligencia-artificial-ia-prtr>, 2023, [Accessed 23-02-2024].

- [42] “Qué es la Inteligencia Artificial,” <https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-is-artificial-intelligence>, 2023, [Accessed 23-02-2024].
- [43] O. Sanseviero, “Ai en 3 minutos: Tipos de machine learning,” <https://medium.com/ai-learners/ai-en-3-minutos-tipos-de-machine-learning-945b708ac78>, [Accessed 23-02-2024].
- [44] “Difference Between Artificial Intelligence vs Machine Learning vs Deep Learning,” <https://www.geeksforgeeks.org/difference-between-artificial-intelligence-vs-machine-learning-vs-deep-learning/>, 2023, [Accessed 23-02-2024].
- [45] “Tipos de aprendizaje en machine learning: supervisado y no supervisado,” <https://telefonicatech.com/blog/que-algoritmo-elegir-en-ml-aprendizaje>, 2021, [Accessed 26-02-2024].
- [46] “Los conceptos de machine learning y deep learning en la industria,” <https://www.interempresas.net/MetalMecanica/Articulos/347471-Los-conceptos-de-Machine-Learning-y-Deep-Learning-en-la-industria.html>, 2021, [Accessed 26-02-2024].
- [47] R. Yehoshua, “Random forests,” <https://medium.com/@roiyeho/random-forests-98892261dc49>, 2023, [Accessed 28-02-2024].
- [48] S. Ronaghan, “The mathematics of decision trees, random forest and feature importance in scikit-learn and spark,” <https://towardsdatascience.com/the-mathematics-of-decision-trees-random-forest-and-feature-importance-in-scikit-learn-and-spark-f28> 2018, [Accessed 28-02-2024].
- [49] “Unlocking the ideas behind of svm (support vector machine),” <https://medium.com/@sachinsoni600517/unlocking-the-ideas-behind-of-svm-support-vector-machine-1db47b025376>, 2023, [Accessed 26-02-2024].
- [50] J. A. Rodrigo, “Máquinas de vector soporte (svm) con python,” <https://cienciadedatos.net/documentos/py24-svm-python>, 2020, [Accessed 26-02-2024].
- [51] “Support vector machines explained with python examples,” <https://towardsdatascience.com/support-vector-machines-explained-with-python-examples-cb65e8172c85>, 2020, [Accessed 26-02-2024].

- [52] “Introducción a support vector machine (svm),” <https://es.mathworks.com/discovery/support-vector-machine.html>, [Accessed 26-02-2024].
- [53] C. Liu, “Svm hyperparameter tuning using gridsearchcv,” <https://www.vebuso.com/2020/03/svm-hyperparameter-tuning-using-gridsearchcv/>, 2020, [Accessed 27-02-2024].
- [54] S. Saxena, “The gaussian rbf kernel in non linear svm,” <https://medium.com/@suvigya2001/the-gaussian-rbf-kernel-in-non-linear-svm-2fb1c822aae0>, 2020, [Accessed 27-02-2024].
- [55] “Dlops: Mlops for deep learning,” <https://valohai.com/blog/dlops/>, [Accessed 26-02-2024].
- [56] F. Bre, J. Gimenez, and V. Fachinotti, “Prediction of wind pressure coefficients on building surfaces using artificial neural networks,” *Energy and Buildings*, vol. 158, 11 2017.
- [57] E. Zegura, K. Calvert, and S. Bhattacharjee, “How to model an internetwork,” *Proceedings - IEEE INFOCOM*, vol. 2, 02 2002.
- [58] J. Figueras, “¿Conoces NILM? Aplica Inteligencia Artificial en la gestión energética,” <https://www.linkedin.com/pulse/conoces-nilm-aplica-inteligencia-artificial-en-la-gesti%C3%B3n-figueras/>, 2018, [Accessed 23-01-2024].
- [59] A. Monacchi, D. Egarter, W. Elmenreich, S. D’Alessandro, and A. M. Tonello, “Greend: An energy consumption dataset of households in italy and austria,” in *2014 IEEE International Conference on Smart Grid Communications (SmartGridComm)*, 2014, pp. 511–516.
- [60] Y. Himeur, A. Alsalemi, F. Bensaali, and A. Amira, “Building power consumption datasets: Survey, taxonomy and future directions,” *Energy and Buildings*, vol. 227, p. 110404, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S037877882030815X>
- [61] S. Makonin, B. Ellert, I. V. Bajić, and F. Popowich, “Electricity, water, and natural gas consumption of a residential house in canada from 2012 to 2014,” *Scientific data*, vol. 3, no. 1, pp. 1–12, 2016.
- [62] K. Anderson, A. Ocneanu, D. Benitez, D. Carlson, A. Rowe, and M. Berges, “Blued: A fully labeled public dataset for event-based non-intrusive load monitoring research,”

- Proceedings of the 2nd KDD Workshop on Data Mining Applications in Sustainability (SustKDD)*, pp. 1–5, 01 2012.
- [63] C. Beckel, W. Kleiminger, R. Cicchetti, T. Staake, and S. Santini, “The eco data set and the performance of non-intrusive load monitoring algorithms,” in *Proceedings of the 1st ACM Conference on Embedded Systems for Energy-Efficient Buildings*, ser. BuildSys ’14. New York, NY, USA: Association for Computing Machinery, 2014, p. 80–89. [Online]. Available: <https://doi.org/10.1145/2674061.2674064>
 - [64] S. Makonin, “Hue: The hourly usage of energy dataset for buildings in british columbia,” *Data in Brief*, vol. 23, p. 103744, 03 2019.
 - [65] N. Batra, M. Gulati, A. Singh, and M. Srivastava, “It’s different: Insights into home energy consumption in india,” 11 2013.
 - [66] J. Kolter and M. Johnson, “Redd: A public data set for energy disaggregation research,” *Artif. Intell.*, vol. 25, 01 2011.
 - [67] S. Barker, A. Mishra, D. Irwin, E. Cecchet, P. Shenoy, and J. Albrecht, “Smart*: An open data set and tools for enabling research in sustainable homes,” *Proc. SustKDD.*, 01 2012.
 - [68] L. Pereira, F. Quintal, R. Gonçalves, and N. J. Nunes, “Sustdata: A public data-set for ict4s electric energy research,” *Proceedings of the 2014 conference ICT for Sustainability*, 2014.
 - [69] J. Kelly and W. Knottenbelt, “The uk-dale dataset, domestic appliance-level electricity demand and whole-house demand from five uk homes,” *Scientific Data*, vol. 2, no. 150007, 2015.
 - [70] D. P. B. Renaux, F. Pottker, H. C. Ancelmo, A. E. Lazzaretti, C. R. E. Lima, R. R. Linhares, E. Oroski, L. d. S. Nolasco, L. T. Lima, B. M. Mulinari, J. R. L. d. Silva, J. S. Omori, and R. B. d. Santos, “A dataset for non-intrusive load monitoring: Design and implementation,” *Energies*, vol. 13, no. 20, 2020. [Online]. Available: <https://www.mdpi.com/1996-1073/13/20/5371>
 - [71] K. Hühne, “Nilm datasets,” <https://github.com/k-nut/nilm-datasets/blob/master/nilm-datasets.csv>, [Accessed 23-01-2024].
 - [72] “Clasificación climática de köppen,” https://es.wikipedia.org/wiki/Clasificaci%C3%B3n_clim%C3%A1tica_de_K%C3%B6ppen, [Accessed 30-01-2024].
 - [73] “Global solar atlas info,” <https://globalsolaratlas.info/>, [Accessed 30-01-2024].
-

- [74] “Energy data info,” <https://energydata.info/>, [Accessed 30-01-2024].
- [75] “Epsg - georepository,” https://epsg.org/crs_4326/WGS-84.html, [Accessed 30-01-2024].
- [76] “Global solar atlas 2.0 technical report,” <https://solargis.com/maps-and-gis-data/download/world>, [Accessed 30-01-2024].
- [77] “Fundamentos energía solar y fotovoltaica,” <https://www.sfe-solar.com/noticias/articulos/energia-fotovoltaica-radiacion-geometria-recorrido-optico-irradiancia-y-hsp/>, [Accessed 31-01-2024].
- [78] “Pvwatts calculator,” <https://pvwatts.nrel.gov/pvwatts.php>, [Accessed 02-02-2024].
- [79] “Poa beam,” <https://pvpmc.sandia.gov/modeling-guide/1-weather-design-inputs/plane-of-array-poa-irradiance/calculating-poa-irradiance/poa-beam/>, [Accessed 03-02-2024].
- [80] A. Prakash, “Threading vs multiprocessing in python: A comprehensive guide,” <https://medium.com/@arjunprakash027/threading-vs-multiprocessing-in-python-a-comprehensive-guide-cae3ce0ca6c1>, [Accessed 06-02-2024].

Lista de Acrónimos y Abreviaturas

AMI	Advanced Metering Infrastructure.
ANN	<i>Artificial Neural Network.</i>
API	<i>Application Programming Interface.</i>
ARP	<i>Address Resolution Protocol.</i>
BRITE	<i>Boston University Representative Internet Topology Generator.</i>
CHP	<i>Combined Heat and Power.</i>
DDoS	<i>Distributed Denial of Service.</i>
DEN2NE	<i>Distributed ENergy ENvironments and Networks.</i>
DIF	<i>Diffuse Irradiance Fraction.</i>
DL	<i>Deep Learning.</i>
DNI	<i>Direct Normal Irradiation.</i>
DSM	<i>Demand Side Management.</i>
DSO	<i>Distribution System Operator.</i>
EPSG	<i>European Petroleum Survey Group.</i>
ESMAP	<i>Energy Sector Management Assistance Program.</i>
FACTS	<i>Flexible AC Transmission System.</i>
FDI	<i>False Data Injection.</i>
GHI	<i>Global Horizontal Irradiation.</i>
GTI	<i>Global Irradiation at Optimum Tilt.</i>
HMAC	<i>Hash Message Authentication Code.</i>
HVAC	<i>High Voltage Alternating Current.</i>
HVDC	<i>High Voltage Direct Current.</i>
IA	<i>Inteligencia Artificial.</i>
IEEE	Institute of Electrical and Electronics Engineers.
IoE	<i>Internet of Energy.</i>
IoT	<i>Internet of Things.</i>
IPFC	<i>Interline Power Flow Controller.</i>
LPWAN	<i>Low Power Wide Area Networks.</i>

ML	<i>Machine Learning.</i>
NILM	<i>Non-Intrusive Load Monitoring.</i>
NLP	<i>Natural Language Processing.</i>
NREL	<i>National Renewable Energy Laboratory.</i>
P2G	<i>Power-to-Gas.</i>
PAR	<i>Peak-to-Average Ratio.</i>
PMU	<i>Phasor Measurement Unit.</i>
POA	<i>Plane of Array Irradiance.</i>
PVOUT	<i>Photovoltaic Power Potential.</i>
PVT	<i>Photovoltaic Thermal.</i>
RBF	<i>Radial Basis Function.</i>
RF	<i>Random Forest.</i>
RSA	<i>Rivest, Shamir y Adleman.</i>
RTP	<i>Real Time Pricing.</i>
SCADA	<i>Supervisory Control and Data Acquisition.</i>
SEND	<i>Secure Neighbor Discovery.</i>
SG	<i>Smart Grid.</i>
SHA	<i>Secure Hash Algorithm.</i>
SINAIS	<i>Sustainable Interactions with Social Networks, context Awareness and Innovative Services.</i>
SSL	<i>Secure Sockets Layer.</i>
SSSC	<i>Static Synchronous Series Compensator.</i>
STATCOM	<i>Static Synchronous Compensator.</i>
SVC	<i>Static Var Compensator.</i>
SVM	<i>Support Vector Machine.</i>
TCSC	<i>Thyristor-Controlled Series Capacitor.</i>
TES	<i>Thermal Energy Storages.</i>
TFM	Trabajo Fin de Máster.
TLS	<i>Transport Layer Security Protocol.</i>
TOU	<i>Time-of-Use Pricing.</i>
UAH	<i>Universidad de Alcalá.</i>
UPFC	<i>Unified Power Flow Controller.</i>
VMs	Máquinas Virtuales.

A. Anexo I - Pliego de condiciones

B. Anexo II - Presupuesto

C. Anexo III - Manuales de usuario e instalación

A modo de facilitar al lector el acceso y el uso de las herramientas empleadas en este TFM, se dedicará este anexo a la creación de un manual de usuario. Se desarrollarán de forma detallada los procedimientos de instalación y configuración del software empleado, además de exponer su funcionamiento completo. De la misma forma, se incluirá la información necesaria para comprender conceptualmente los scripts que se han empleado con el fin de automatizar y optimizar el desarrollo de los casos prácticos.

C.1. Herramienta BRITE

El objetivo de incluir esta sección es exponer al lector la información de instalación y configuración de la plataforma de generación de topologías de red BRITE, descrita previamente en la Sección 2.6.1.

C.1.1. Virtualización del sistema operativo Linux

Previamente a exponer los pasos de instalación del BRITE, es preciso indicar que se ha empleado una máquina virtual con un sistema operativo Linux para soportar las funcionalidades de la herramienta. En este caso, se ha utilizado como plataforma VMWare¹ y una versión del sistema operativo Ubuntu 20.04.1 LTS como se puede visualizar en la Figura C.1.

C.1.2. Compilación e instalación de BRITE

Para proceder a instalar la herramienta, se accede al repositorio del equipo de investigación NetIS de la UAH² y se descarga y se descomprime el fichero .zip con todos los contenidos necesarios. Después, se realiza un *make* desde el directorio raíz de la herramienta. Se pueden producir errores por la falta de paquetes *g++* o *openjdk++*, que se soluciona con los comandos dados en el Código C.1.

¹<https://www.vmware.com/es/products.html>

²<https://github.com/NETSERV-UAH/BRITE>

Device Name	ubuntu >
Memory	1.9 GiB
Processor	AMD® Ryzen 5 3400g with radeon vega graphics × 2
Graphics	SVGA3D; build: RELEASE; LLVM;
Disk Capacity	21.5 GB
OS Name	Ubuntu 20.04.1 LTS
OS Type	64-bit
GNOME Version	3.36.3
Windowing System	X11
Virtualization	VMware

Figura C.1: Características del sistema operativo

Código C.1: Instalación de paquetes

```
1sudo apt install g++
2sudo apt install openjdk-11-jdk
```

C.1.3. Ejecución de BRITE

Se puede ejecutar BRITE mediante la interfaz gráfica (GUI) (ver Código C.2) o por comandos. En el caso de los comandos se da la posibilidad de utilizar los ejecutables programados en C++ o en Java (ver Código C.3), obteniéndose los mismos resultados a partir de una misma entrada.

Código C.2: Ejecución de la interfaz gráfica de BRITE

```
1$ ./britegui &
```

Código C.3: Ejecución de BRITE por la línea de comandos

```
1$bin/brite <archivo de entrada .conf> <archivo de salida .brite> <seed_file>
2$C++/cppgen <archivo de entrada .conf> <archivo de salida .brite> <seed_file>
```

Como se especifica en el Código C.3, se requiere un archivo de configuración de entrada (.conf), en el cual se determinen los parámetros de la topología, y otro de salida, especificado en formato .brite. Como se ha expuesto en el Capítulo referente al Estado del Arte (ver Sección 2.6.1.3), para facilitar el uso de BRITE se aportan en el repositorio una serie de ficheros de Python y scripts dedicados a la automatización del proceso de creación de los ficheros de configuración y del tratamiento de la salida.

Universidad de Alcalá
Escuela Politécnica Superior



ESCUELA POLITECNICA
SUPERIOR

